

中山大学人工智能学院
研究生学位论文

面向出行位置点预测的大小模型协同学习研究

Collaborative Learning of Large and Small Models for Next POI Prediction in
Mobility Scenarios

学 位 申 请 人： 刘钊

专 业 名 称： 人工智能

导 师 姓 名 及 职 称： 刘威（副教授）

答辩委员会主席（签名）： _____

委员（签名）： _____

论文原创性声明

本人郑重声明，所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究作出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名

日期 年 月 日

学位论文使用授权声明

本人完全了解中山大学有关保留、使用学位论文的规定，即学校有权保留学位论文并向国家主管部门或其指定机构送交论文的电子版和纸质版；有权将学位论文用于非赢利目的的少量复制并允许论文进入学校图书馆、院系资料室被查阅；有权将学位论文的内容编入有关数据库进行检索；可以采用复印、缩印或其他方法保存学位论文；可以为建立了馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。

保密论文保密期满后，适用本声明。

学位论文作者签名

导师签名

日期 年 月 日

日期 年 月 日

论文题目：面向出行位置点预测的大小模型协同学习研究

专 业：人工智能

硕 士 生：刘钊

指导教师：刘威（副教授）

摘要

随着位置服务与移动互联网的发展，下一个兴趣点（Point-of-Interest, POI）预测已成为智能出行与个性化推荐的重要问题。现有方法在该任务上面临三方面不足。其一，传统序列与图模型通常采用统一转移机制，难以刻画同一 POI 在不同时段的行为差异，且仅建模”当前点去哪里”而忽略”目标点从哪里来”的方向性信息，导致路径预测存在偏置；其二，大语言模型（Large Language Model, LLM）将经纬度作为文本 token 处理，地理上相邻的坐标在离散 token 空间中可能被映射为差异较大的符号序列，致使空间连续性被破坏，容易产生地理不一致的预测；其三，POI 之间的高阶转移关系蕴含在图结构中，仅依赖文本上下文难以将这类结构先验有效注入 LLM 语义空间，制约了模型对未显式出现候选的推断能力。针对上述问题，本文围绕”大小模型协同学习”展开研究，构建融合时空结构先验与语义推理能力的统一框架。

方法上，针对时间异质性与转移方向性不足，本文在小模型侧构建时间增强序列动态图与双向转移建模，按时段划分转移子图并同时学习”转出-转入”关系；针对 LLM 空间连续性缺失，设计地理坐标注入模块（Geographic Coordinate Injection Module, GCIM），通过层级离散编码与连续频域编码的融合将地理约束以结构化方式注入语义空间；针对转移先验难以注入 LLM，设计 POI 对齐模块（POI Alignment Module, PAM），建立从图结构表征到 LLM 语义空间的可学习映射通道，使高阶转移关系在语义侧可被读取和利用；在训练策略上采用”先对齐、后协同”的两阶段流程，以参数高效微调控制开销。在公开签到数据及其城市子集上的实验表明，所提方法在 Acc@1、MRR 等核心指标上均优于现有序列、图与大语言模型基线；其中，TSPM 在 Gowalla 上的 Acc@1 相对最强非本文基线提升 5.49%，GA-LLM 在 NYC 上的 Acc@1 提升 18.27%。消融实验与诊断分析进一步验证了各模块的独立贡献，并显示该框架在精度提升与工程可部署性之间取得了稳定平衡。

关键词：下一个兴趣点推荐；大小模型协同；时空建模；大语言模型；参数高效
微调

Title: Collaborative Learning of Large and Small Models for Next POI Prediction in Mobility Scenarios

Major: Artificial Intelligence

Name: Zhao Liu

Supervisor: Wei Liu (Associate Professor)

Abstract

Next point-of-interest (POI) prediction is a key task for intelligent mobility and personalized recommendation. Existing methods suffer from three limitations. First, conventional sequential and graph-based models adopt a unified transition mechanism that fails to capture the behavioral differences of the same POI across time periods, and model only “where the current point leads to” while ignoring “where the target point is typically reached from,” introducing directional bias in path prediction. Second, large language models (LLMs) tokenize geographic coordinates as plain text, so that spatially adjacent locations may be mapped to dissimilar token sequences, breaking spatial continuity and causing geographically inconsistent predictions. Third, high-order transition patterns are embedded in graph structures and cannot be effectively injected into the LLM semantic space through text context alone, limiting the model’s ability to infer candidates that do not explicitly appear in the input. To address these issues, this thesis develops a unified small-large collaborative learning framework that integrates spatio-temporal structural priors with semantic reasoning.

On the methodology side, to address temporal heterogeneity and insufficient transition directionality, a time-enhanced sequence-based dynamic graph with bidirectional transfer modeling is introduced on the small-model branch, which partitions transition sub-graphs by time slot and jointly learns outgoing and incoming preferences. To tackle the lack of spatial continuity in LLMs, a Geographic Coordinate Injection Module (GCIM) is designed to fuse hierarchical discrete encoding with continuous Fourier encoding and inject geographic constraints into the semantic space in a structured manner. To bridge the gap in transfer-prior injection, a POI Alignment Module (PAM) establishes a learnable mapping from graph-based structural representations to the LLM

semantic space, enabling high-order transition knowledge to be accessed and utilized on the semantic side. A two-stage training strategy (“alignment first, collaboration second”) with parameter-efficient fine-tuning is adopted to control computational overhead. Experiments on public check-in datasets and their city-level subsets show that the proposed method consistently outperforms sequential, graph-based, and LLM baselines on Acc@1, MRR, and related metrics. In particular, TSPM improves Acc@1 by 5.49% on Gowalla, and GA-LLM improves Acc@1 by 18.27% on NYC over the strongest non-ours baselines. Ablation and diagnostic studies further verify the independent contribution of each module and confirm a stable trade-off between predictive accuracy and deployment cost.

Keywords: Next POI Recommendation; Collaborative Learning; Spatio-temporal Modeling; Large Language Models; Parameter-efficient Fine-tuning

目录

摘 要	I
ABSTRACT	III
本文常用缩写对照表	IX
第 1 章 绪论	1
1.1 研究背景与研究意义	1
1.2 国内外研究现状与评述	2
1.3 研究问题与核心挑战	4
1.4 研究思路与主要贡献	5
1.5 论文组织结构	6
第 2 章 问题定义与建模原则	8
2.1 任务定义与符号约定	8
2.2 建模边界与评价协议	9
2.3 研究空白与建模原则	10
2.4 研究问题映射	11
第 3 章 大小模型协同学习方法	13
3.1 本章引言	13
3.2 总体框架与设计动机	13
3.3 关键模块设计	15
3.3.1 小模型分支, TSPM	15
3.3.2 大模型分支, GA-LLM	21
3.4 对齐与协同训练策略	28
3.5 方法对照与讨论	33
3.6 本章小结	33
第 4 章 实验设计与结果分析	35
4.1 本章引言	35
4.2 实验目标与研究问题	35

4.3	实验设置	35
4.4	主结果与双路线模型基线对比 (RQ1)	38
4.5	机制验证与诊断分析 (RQ2–RQ4)	41
4.6	效率与可扩展性分析 (RQ5)	48
4.7	本章小结	50
结论		52
参考文献		57
附录		62
后记		64

Contents

Abstract (In Chinese)	I
Abstract (In English)	III
List of Abbreviations	IX
Chapter 1 Introduction	1
Section 1.1 Research Background and Significance	1
Section 1.2 Domestic and International Research Status	2
Section 1.3 Research Questions and Core Challenges	4
Section 1.4 Research Route and Main Contributions	5
Section 1.5 Thesis Organization	6
Chapter 2 Problem Definition and Modeling Principles	8
Section 2.1 Task Definition and Notation	8
Section 2.2 Modeling Boundaries and Evaluation Protocol	9
Section 2.3 Research Gaps and Modeling Principles	10
Section 2.4 Research Question Mapping	11
Chapter 3 Collaborative Learning Method of Large and Small Models	13
Section 3.1 Chapter Introduction	13
Section 3.2 Overall Framework and Design Motivation	13
Section 3.3 Key Module Design	15
Subsection 3.3.1 Small-model Branch, TSPM	15
Subsection 3.3.2 Large-model Branch, GA-LLM	21
Section 3.4 Alignment and Collaborative Training Strategy	28
Section 3.5 Method Comparison and Discussion	33
Section 3.6 Chapter Summary	33
Chapter 4 Experimental Design and Result Analysis	35
Section 4.1 Chapter Introduction	35
Section 4.2 Experimental Objectives and Research Questions	35
Section 4.3 Experimental Setup	35
Section 4.4 Main Results and Dual-route Baseline Comparison (RQ1)	38
Section 4.5 Mechanism Verification and Diagnostic Analysis (RQ2–RQ4)	41
Section 4.6 Efficiency and Scalability Analysis (RQ5)	48
Section 4.7 Chapter Summary	50
Conclusion	52
References	57

Appendix	62
Postscript	64

本文常用缩写对照表

英文缩写	英文全称	中文释义
POI	Point of Interest	兴趣点
LBSN	Location-Based Social Network	基于位置的社交网络
LLM	Large Language Model	大语言模型
GNN	Graph Neural Network	图神经网络
RNN	Recurrent Neural Network	循环神经网络
MLP	Multilayer Perceptron	多层感知器
LoRA	Low-Rank Adaptation	低秩适配微调
TSPM	Time-enhanced Sequential Prediction Model	时间增强序列预测模型
GA-LLM	Geography-Aware Large Language Model	地理感知大语言模型
TSDG	Time-enhanced Sequence-based Dynamic Graph	时间增强序列动态图
BTM	Bidirectional Transformation Modeling	双向转移建模
GCIM	Geographic Coordinate Injection Module	地理坐标注入模块
PAM	POI Alignment Module	POI 对齐模块
CSE	Continuous Spatial Encoding	连续空间编码
HDE	Hierarchical Discrete Encoding	层级离散编码
GAL	Geodesic Alignment Loss	测地对齐损失
TiRNN	Time-aware Recurrent Neural Network	时间感知循环神经网络
MRR	Mean Reciprocal Rank	平均倒数排名
NDCG	Normalized Discounted Cumulative Gain	归一化折损累积增益

第 1 章 绪论

随着位置服务、移动社交网络和城市智能应用的发展，下一兴趣点（Next POI）预测逐渐成为推荐系统与城市计算交叉领域中的重要问题。该任务需要根据用户历史签到、时间上下文、地理位置和 POI 语义信息预测用户下一步可能访问的地点，其核心难点在于同时处理行为序列、空间可达性和活动意图之间的耦合关系。

1.1 研究背景与研究意义

在数字经济和移动互联网持续发展的背景下，推荐系统已经从平台的辅助功能演进为连接用户、内容、商品和线下服务的重要基础设施^[1,2,3,4,5]。传统推荐更多回答“用户可能喜欢什么”，而位置服务、本地生活和城市出行场景进一步要求系统判断“用户此刻可能去哪里、下一步能否到达、推荐结果是否符合真实地理规律”^[6,7,8,9,10]。因此，下一兴趣点（Point-of-Interest, POI）推荐不仅是推荐系统问题，也是时空行为建模、地理信息理解和城市计算交叉形成的典型任务。

与普通物品推荐相比，Next POI 受到时间节律、空间可达性、活动语义和行为路径连续性的共同约束^[11,12,13,14,15]。签到轨迹中记录的并非孤立偏好，而是一组带顺序、地点、时间和语义标签的行为片段，同一商圈在午间和夜间具有不同访问规律，同一交通枢纽在工作日与周末连接的目的地也可能明显不同。若模型只学习历史访问频率，容易把高频近邻点误判为下一目标；若只依赖语义文本，可能生成语义合理但地理上不可达的地点。因此，该任务的核心难点在于同时处理“局部时序规律”“全局转移结构”和“语义泛化能力”。从实际系统角度看，Next POI 预测还具有明显的“决策前置”特点。线上内容推荐允许用户快速跳过不感兴趣的条目，而出行位置推荐往往会影响用户对路线、时间和活动安排的判断，错误推荐带来的成本更高。例如在早高峰通勤场景中，候选点之间可能只相隔数百米，但对应的通勤目的却完全不同；在旅游或本地生活场景中，模型给出的地点即便类别相近，若距离过远或不符合当前时间段，也很难被用户采纳。这使得 Next POI 模型不能只依赖传统推荐系统中的点击概率思路，而需要更细致地刻画地理距离、路径连通性、访问顺序和活动语义之间的关系。本文选择大小模型协同路线，也正是因为单一路线往往只能覆盖其中一部分约束。进一步看，Next POI 预测中的“下一点”并不是一个单纯的标签，而是用户当前状态、城市空间结

构和候选地点可达性共同作用后的结果。用户在同一 POI 停留后的下一步行为，可能受当前时间、前序访问目的、所在区域功能和个人习惯影响；而同一个候选 POI 是否合理，也取决于它与当前点之间是否存在常见迁移路径、是否符合该时段的活动规律、是否与用户近期序列中的语义主题连续。若模型只把任务看作 ID 分类问题，容易忽略这些约束之间的相互作用；若只把轨迹转写为自然语言提示，又可能把坐标、距离和转移概率压缩成模糊描述，导致预测结果语义上合理但空间上偏离。本文的研究价值就在于把这些约束拆解为可学习的结构表示、地理表示和语义表示，并通过协同训练使它们在同一预测目标下相互补充。本文工作的意义体现在三个层面。理论上，Next POI 位于时空序列建模、图结构学习和大语言模型语义推理的交叉区域^[4,16,17,18,19]，能够用于检验结构先验如何与语言模型表示空间协同。方法上，现有序列方法擅长短期局部模式^[20,21,22,23,24]，图方法擅长高阶关系传播^[25,26,27,28,29]，LLM 方法擅长语义迁移和复杂上下文理解^[30,31,32,33,34]，但三者很少在可部署框架中被统一组织。应用上，本地生活、文旅推荐和城市出行服务均要求推荐结果既“像用户会去的地方”，又“在时间和空间上走得通”^[6,9,10,35,36]。

1.2 国内外研究现状与评述

国内外关于推荐系统的研究经历了从协同过滤、序列推荐到生成式推荐的持续演进。早期协同过滤和排序学习工作，如矩阵分解^[1]、BPR^[2]和FPMC^[37]等，为用户偏好和短期转移建模提供了基础。随后，GRU4Rec^[20]、NARM^[21]、STAMP^[22]、SASRec^[38]、BERT4Rec^[39]等序列推荐模型将循环网络、注意力机制和双向表示学习引入行为序列建模。这些研究证明了序列上下文对推荐排序的重要性，但多数方法面向普通物品序列，缺少对地理距离、时间节律和出行可达性的直接刻画。

在 Next POI 方向，研究重心逐渐从“访问序列预测”转向“时空约束下的路径预测”。FPMC^[37]、PRME^[11]等方法将个体偏好与连续转移结合，ST-RNN^[12]、HST-LSTM^[13]、LSTPM^[40]、STAN^[14]进一步纳入时间间隔、空间距离和注意力机制。这类序列模型的优点是结构清晰、训练成本可控，能够细致刻画短期访问惯性；不足是对长距离跳转和跨用户共享迁移的表达较弱，当历史轨迹稀疏或候选分布发生变化时，模型容易退化为局部高频点排序。因此，单纯加深序列编码器并不能自然解决高阶转移和空间可达性问题。图学习方法试图弥补上述不足。GETNext^[15]、GraphFlashback^[41]、STHGCN^[42]、SNPM^[43]、ROTAN^[44]、MTNet^[45]

等工作通过 POI 图、异构图或动态图学习高阶关系，并在稀疏监督场景中取得较好表现。图方法能够把“哪些地点经常相互连接”显式编码到结构空间中，对转移关系和区域联系更敏感；但其代价是动态图维护、邻居采样和异构信息融合成本较高，而且图表示与语言模型语义空间之间缺乏天然对齐。换言之，图模型能学到有用结构，却不容易直接让 LLM 稳定读取这些结构知识。进一步比较序列方法与图方法可以看到，二者并不是简单的替代关系。序列模型更像是在用户个人轨迹上做局部外推，适合捕捉“刚刚去了哪里、下一步通常接着去哪里”的短期惯性；图模型则把大量用户的访问行为汇总为全局结构，适合捕捉“哪些地点之间存在稳定迁移关系”的群体规律。真实出行预测往往同时需要这两类信息。如果只看个体序列，模型容易忽视其他用户形成的可迁移路径；如果只看全局图结构，模型又可能弱化当前用户的个性化计划。因此，本文的小模型分支并不是单纯选择序列或图中的一种，而是通过时间增强序列动态图把二者结合起来，使局部历史、时间分槽和转移结构能够共同参与表示学习。近两年，大语言模型推动推荐研究进入生成式阶段。从 P5^[46]、TALLRec^[47]、GenRec^[48] 到 CID^[49]、Tiger^[50]、IDGenRec^[51] 和 A-LLMRec^[52]，研究重点逐步从“能否把推荐写成生成任务”转向“生成结果是否可控、ID 表达是否可学习、协同信号能否进入语言空间”。在 Next POI 领域，LLM4POI^[53] 验证了将轨迹预测转化为生成任务的可行性，SeCor^[54]、Geo-LLMRec^[35] 和 POI-LLM^[36] 相关研究进一步指出，纯文本坐标输入容易导致空间连续性破坏，模型可能给出语义通顺但地理上偏移较大的预测。近期工作开始引入检索增强、地理重排、多智能体推断或隐私保持反思机制^[55,56,57]，说明研究前沿已经从“让 LLM 参与推荐”推进到“让 LLM 遵守地理和结构约束”。LLM 路线带来的变化值得单独讨论。传统推荐模型通常输出候选分数，模型内部的 ID 表示不要求具备自然语言解释能力；而 LLM 推荐把历史轨迹、POI 名称、类别和坐标组织成文本输入，再生成目标 POI，这使模型可以利用类别语义、区域描述和上下文常识。但这种优势也带来新的问题：语言模型擅长处理符号和语义关联，却不擅长天然理解经纬度之间的连续距离，更难直接学习“坐标相近但 token 差异大”的几何事实。若不引入专门的地理表示，LLM 可能把坐标当作普通字符串处理；若不引入结构对齐，LLM 又难以利用图模型中已经学到的 POI 迁移关系。本文的 GCIM 和 PAM 正是围绕这两个缺口设计，而不是简单增加提示词长度。从研究发展趋势看，Next POI 任务正在从单纯的“下一点分类”转向“带约束的行为推理”。传统序列模型能够较好利用短期历史，但在跨区域、长尾 POI 和语义稀疏场景中容易受限；图模型能够补充群体层面的迁

移关系，却需要面对动态图噪声、边权更新和跨空间对齐问题；LLM 能够理解文本语义和复杂上下文，但必须通过专门机制获得地理连续性与结构先验。三类方法的能力边界决定了本文不能只沿着单一路线扩展，而需要把结构先验、地理编码和语言语义放在同一预测目标下联合考虑。中文学术界在推荐系统、序列推荐、图推荐和城市时空智能方面也形成了较系统的研究脉络^[5,58,59,60,7,8,61,62]。相关工作强调真实业务中的可解释性、工程可用性和实时响应能力^[63,64,65,66,67]，这对本文具有直接启示，Next POI 模型不能只追求离线指标，还必须说明结构约束从何而来、如何进入模型、推理成本是否可接受。综合已有研究可以看到，序列模型、图模型和 LLM 模型各有优势，但仍缺少一个在训练阶段吸收结构先验、在推理阶段保持简洁输出的统一方案。这正是本文选择“大小模型协同学习”路线的原因。

1.3 研究问题与核心挑战

本文关注的问题在于给定用户历史签到轨迹及其时间、空间和语义上下文，预测用户下一时刻最可能访问的 POI，并输出 Top- K 候选列表。该问题既包含序列预测，也包含结构约束下的转移判断，模型不仅要判断候选“像不像用户会去”，还要判断“在当前时间和路径上是否合理”。完整的符号体系和评价指标将在第2章统一给出，本章仅从研究问题角度明确本文要解决的关键矛盾。

具体而言，本文将总体目标分解为五个可验证问题。第一，同一 POI 在不同时段具有不同转移规律，模型需要以较低额外成本显式建模时段异质性；第二，下一跳预测不仅取决于“当前点通常去哪里”，也取决于“目标点通常从哪里来”，因此需要同时表达转出与转入偏好；第三，LLM 语义空间不天然保持地理邻近关系，经纬度若被当作普通文本 token 处理，空间连续性会被破坏；第四，POI 图中的高阶转移关系需要从结构空间映射到 LLM 语义空间，否则语言模型难以利用这些先验；第五，在效果提升之外，协同框架必须控制训练成本、推理时延和参数规模，避免只在离线实验中成立。

上述问题对应四类核心挑战。其一是时间异质性挑战，同一 POI 在早晚高峰、工作日和周末的转移模式差异显著，统一转移机制容易造成偏差^[12,68,14,69,45]。其二是空间连续性挑战，经纬度与语义表示空间之间缺乏天然同构，直接把坐标写成文本会使相邻地点在 token 空间中被切分为差异较大的符号序列^[70,71,53,72]，如图1-1所示。其三是转移先验注入挑战，POI 图中蕴含的高阶迁移关系并不会自动出现在语言模型输入中，单靠上下文共现很难稳定恢复^[41,43,42,54,73]。其四是




图 1-1 空间连续性挑战示意，(a) 预测误差分布与平均地理误差对比，显示纯文本 LLM 更易产生远距离偏移；(b) 坐标文本 token 化示例，显示地理上邻近的坐标在离散 token 空间中可能被映射为差异较大的符号序列。

Fig. 1-1 Illustration of the spatial continuity challenge, (a) comparison of error distribution and mean geographic error distance; (b) a tokenization example showing that geographically close coordinates may become distant in discrete token space.

协同优化挑战，小模型的结构归纳偏置与大模型的语义泛化能力需要在训练阶段形成稳定接口，否则容易变成简单堆叠或推理期高成本融合^[74,32,75,76,77]。




图 1-2 转移先验注入挑战示意，仅依赖 token 语义难以恢复 POI 图中的高阶迁移关系。

Fig. 1-2 Illustration of transfer-prior injection challenge, token-level semantics alone are insufficient to recover high-order transitions in the POI graph.

如图1-2所示，若缺少结构化对齐路径，模型对“未显式出现但高转移概率”的候选点识别能力不足。该现象说明 POI 关系先验需要以可学习方式注入语义空间，而非完全依赖隐式文本学习。基于以上分析，本文在第3章分别设计 TSPM、GCIM 和 PAM 模块，并在第4章通过主结果、消融和误差分析验证这些模块是否真正缓解上述挑战。

1.4 研究思路与主要贡献

针对上述挑战，本文采用“大小模型协同学习”的总体路线，在小模型侧构建时间增强序列动态图与双向转移机制，学习稳定的时空结构先验^[43,15,41,78,79]；在大模型侧设计地理坐标注入模块与 POI 对齐模块，增强 LLM 的空间一致性与转移感知能力^[53,35,36,17]；在训练策略上通过嵌入对齐和参数高效微调，将结构知识

迁移到 GA-LLM 侧，使推理阶段仍由 GA-LLM 单路输出，以控制时延和工程复杂度^[30,31,33,80,81]。




图 1-3 研究思路与技术路线总览图。
Fig. 1-3 Overview of research logic and technical roadmap.

根据图1-3所示技术路线，本文主要贡献如下。第一，提出面向 Next POI 任务的大小模型协同框架，将时空结构建模、地理语义增强和跨空间对齐训练纳入统一流程；第二，设计时间增强序列动态图与双向转移建模机制，使小模型能够表达不同时段、不同方向的出行规律；第三，设计地理坐标注入模块（Geographic Coordinate Injection Module, GCIM）与 POI 对齐模块（POI Alignment Module, PAM），分别缓解 LLM 空间连续性不足和转移先验注入困难；第四，构建围绕研究问题的实验评估流程，从总体性能、模块贡献、协同有效性和效率开销四个维度验证方法有效性。需要强调的是，本文所称“协同学习”主要发生在训练阶段，结构知识通过 PAM 和对齐损失迁移到 GA-LLM 侧，推理阶段由 GA-LLM 单路输出，而不是让 TSPM 与 GA-LLM 在线共同打分。这些贡献共同指向同一核心判断，即 Next POI 预测中的性能提升不应只来自更大的模型规模或更长的提示文本，而应来自对任务约束的显式建模。TSPM 通过时间分槽和双向转移刻画结构先验，GA-LLM 通过 GCIM 和 PAM 把地理连续性与转移关系注入语义空间，二者分别对应轻量结构建模与生成式语义推理中的关键缺口。

1.5 论文组织结构

全文共五章。第 1 章介绍研究背景、国内外研究现状、核心挑战、技术路线与主要贡献。第 2 章给出全文统一的任务定义、符号体系、评价指标与建模原则，为后续方法设计提供问题边界。第 3 章详细阐述大小模型协同学习方法，包

括 TSPM、GCIM、PAM 和训练推理流程。第 4 章按研究问题组织实验设置、主结果、消融诊断、互补性分析和效率评估。第 5 章总结全文工作，提炼主要结论，并讨论研究局限和后续方向。

本章从应用背景、文献现状和任务挑战三个层面说明了本文研究的必要性。可以看到，Next POI 预测并不是简单的序列外推，而是要求模型同时满足时间、空间、结构和语义约束。下一章将在本章评述基础上给出统一的问题定义与符号约定，并将研究空白进一步收敛为可执行的建模原则。

第2章 问题定义与建模原则

Next POI 预测需要在统一任务定义下同时处理用户历史、时间上下文、地理位置和候选 POI 集合。给定用户按时间排序的历史访问序列，模型需要估计下一时刻最可能访问的 POI，并在 Top- K 候选中尽可能靠前地排列真实目标。由于不同研究路线在输入、输出和评价口径上存在差异，本章首先明确符号体系、建模边界和评价指标，再归纳本文采用的建模原则。

2.1 任务定义与符号约定

设用户集合为 $\mathcal{U} = \{u_1, u_2, \dots, u_M\}$ ，POI 集合为 $\mathcal{P} = \{\ell_1, \ell_2, \dots, \ell_N\}$ 。用户 u 的第 i 条签到定义为

$$x_i = (u, \ell_i, t_i, g_i, c_i), \quad (2-1)$$

其中， u 表示用户 ID； ℓ_i 表示第 i 次签到对应的 POI ID； t_i 表示签到时间戳； $g_i = (lat_i, lon_i)$ 表示经纬度坐标； c_i 表示 POI 类别语义标签。

用户轨迹可表示为

$$\mathcal{T}_u = \{x_1, x_2, \dots, x_n\}, \quad t_1 < t_2 < \dots < t_n, \quad (2-2)$$

其中， $\mathcal{T}_u$ 表示用户 u 的时间有序签到序列； n 表示轨迹长度； $t_1 < t_2 < \dots < t_n$ 表示轨迹按时间严格递增排序。Next POI 任务可表示为学习映射

$$f : \mathcal{T}_u \mapsto \hat{\ell}_{n+1}, \quad \hat{\ell}_{n+1} \in \mathcal{P}, \quad (2-3)$$

其中， f 表示预测函数； $\hat{\ell}_{n+1}$ 表示模型预测的下一 POI； $\mathcal{P}$ 表示候选 POI 全集。模型目标是使真实下一 POI ℓ_{n+1} 在候选排序中尽可能靠前。若输出 Top- K 列表，记为 $\hat{\mathbf{y}}_u = [\hat{\ell}^{(1)}, \dots, \hat{\ell}^{(K)}]$ 。这一表述同时覆盖小模型的候选打分范式和大模型的 POI ID 生成范式，后文所有实验均以该任务定义为基准。为减少符号歧义，表2-1给出全文高频符号及含义。第3章会在此基础上补充实现级变量，但不会改变本章给出的核心定义。上述符号体系的设计遵循两个原则。第一，任务层符号尽量保持简洁，只保留用户、POI、时间、坐标和类别等必要字段，避免在问题定义阶段过早引入模型内部变量。这样做可以使小模型路线和大模型路线共享

表 2-1 核心符号说明
Table 2-1 Description of core notations.

符号	含义
$\mathcal{U}, \mathcal{P}$	用户集合与 POI 集合
$\mathcal{T}_u$	用户 u 的时间有序签到轨迹
$x_i = (u, \ell_i, t_i, g_i, c_i)$	第 i 次签到记录 (用户、POI、时间、坐标、类别)
T_z	第 z 个时间槽 (Time Slot)
ξ^{out}, ξ^{in}	小模型中 POI 转出/转入表示
$\mathbf{E}_{gps}, \mathbf{E}_{poi}$	大模型侧地理编码与 POI 对齐表示
$\hat{\mathbf{y}}_u$	模型输出的 Top- K 推荐列表
r_n	测试样本中真实 POI 的排序位次
$\mathcal{L}_{small}, \mathcal{L}_{align}, \mathcal{L}_{llm}$	小模型损失、跨空间对齐损失、大模型任务损失

同一任务入口。第二，模型层符号只在后续章节按需展开，例如小模型分支中的转出/转入表示、大模型分支中的地理编码和 POI 对齐表示，均在第3章结合具体模块解释。通过这种分层定义，本文避免了同一符号在不同章节含义不一致的问题，也使实验章能够直接引用统一指标和变量。

2.2 建模边界与评价协议

本文采用如下边界设置。第一，训练与测试数据均包含可解析时间戳，允许划分统一时间槽；第二，POI 具备经纬度坐标，允许构建地理约束与距离相关特征；第三，每个测试样本至少保留最小历史长度，以支持序列和结构建模；第四，本文主实验聚焦离线 Top- K 评估，不直接讨论在线 A/B 系统收益。上述边界并不削弱问题价值，而是保证不同模型在同一信息条件下比较。对于极短轨迹、无坐标输入、实时概念漂移等超出边界的场景，本文在第4章效率与可扩展性分析以及第4.7章展望中讨论扩展路径。

这些边界也对应了本文不做的事情。本文不把 POI 预测扩展成完整导航问题，因此不直接建模道路限行、实时拥堵和交通工具选择；本文也不把用户画像作为主要研究对象，因此不依赖年龄、职业等隐私敏感属性，而是主要利用轨迹中已经包含的时间、空间和类别信息。这样的取舍使实验比较更清晰。如果模型获得提升，主要应归因于时空结构建模、地理编码和跨空间对齐，而不是额外侧信息带来的隐性优势。明确边界比无限扩展任务更重要，因为只有边界清楚，后续实验的公平性和可复现性才有基础。本文采用 Acc@ K 、MRR 与 NDCG@ K 评价排序质量。设第 n 个测试样本中真实 POI 的排序位次为 r_n ，测试样本集合为

$\mathcal{D}$ ，则

$$\text{Acc@K} = \frac{1}{|\mathcal{D}|} \sum_{n=1}^{|\mathcal{D}|} \mathbf{1}(r_n \leq K), \quad (2-4)$$

其中， $\mathcal{D}$ 表示测试样本集合； $|\mathcal{D}|$ 表示测试样本总数； r_n 表示第 n 个样本中真实 POI 的排序位次； $\mathbf{1}(\cdot)$ 表示指示函数，条件满足时取 1，否则取 0。

$$\text{MRR} = \frac{1}{|\mathcal{D}|} \sum_{n=1}^{|\mathcal{D}|} \frac{1}{r_n}, \quad (2-5)$$

其中， r_n 表示越小表示真实 POI 排名越靠前； $\frac{1}{r_n}$ 表示第 n 个样本的倒数排名得分。

$$\text{NDCG@K} = \frac{1}{|\mathcal{D}|} \sum_{n=1}^{|\mathcal{D}|} \frac{\mathbf{1}(r_n \leq K)}{\log_2(r_n + 1)}, \quad (2-6)$$

其中， $\log_2(r_n + 1)$ 表示位置折损项； $\mathbf{1}(r_n \leq K)$ 表示真实 POI 是否进入 Top- K 。

不同指标对应不同系统目标。 Acc@1 反映第一推荐是否可直接使用； Acc@5/10 反映候选列表覆盖能力； MRR 强调正确答案能否前移； NDCG@K 则对头部排序质量更敏感。因此，本文不以单一指标支撑结论，而是从首位可用性、候选覆盖和排序质量三个维度综合判断方法有效性。数据划分、负采样、显著性检验和实现细节统一在第4章说明。在解释实验结果时，本文尤其关注指标之间是否同向变化。若 Acc@1 上升但 MRR 下降，说明模型可能只改善少数首位样本，排序整体并不稳定；若 Acc@5 上升但 Acc@1 不变，说明模型扩大了候选覆盖，但仍没有把真实目标推到最前；若地理误差下降而命中率变化有限，则说明模型至少减少了不可达或远跳错误。基于这一考虑，第4章不会只给出单张主结果表，而会结合消融、跨城冷启动、平均地理误差和困难样本分析共同判断模型是否真正改善了 Next POI 任务的关键问题。

2.3 研究空白与建模原则

结合第1章的文献评述，本文将研究空白归纳为三点。第一，小模型强结构、弱语义，能够学习时间分槽、图邻接和转移方向等规律，但对复杂意图表达与跨场景泛化支持不足。第二，大模型强语义、弱空间，具备文本理解和生成能力，但对经纬度连续性、可达性约束和 POI 图先验缺少天然建模机制。第三，已有研究缺少面向工程部署的统一协同训练方案，常见做法要么只做离线结构模型，

要么让 LLM 承担全部推理压力，难以同时兼顾效果、解释性和成本。

据此，本文提出三条建模原则。其一是结构先验显式化，在小模型侧显式建模时间异质性和双向转移关系，而不是让模型从稀疏序列中隐式猜测所有规律。其二是空间语义对齐，在大模型侧引入地理编码与 POI 结构对齐模块，使坐标和图先验能以可学习表示进入 LLM 输入空间。其三是协同训练可部署，通过先对齐、后协同的训练流程和参数高效微调控制成本，使结构知识在训练阶段被吸收，推理阶段保持单路输出。这三条原则之间存在明确的递进关系。结构先验显式化解决“哪些规律值得学习”的问题，空间语义对齐解决“这些规律如何进入大模型”的问题，协同训练可部署则解决“模型能否在真实资源约束下使用”的问题。若缺少第一步，大模型只能从文本中猜测结构关系；若缺少第二步，小模型学到的图结构难以被 LLM 利用；若缺少第三步，协同框架可能退化为推理期多模型堆叠，虽然离线指标提升，但线上时延、系统复杂度和长期运行成本都难以控制。因此，本文后续方法设计始终围绕“先学习结构、再对齐语义、最后保持推理简洁”这一主线展开。相应地，本文统一目标可概括为

$$\mathcal{L} = \mathcal{L}_{\text{small}} + \lambda_1 \mathcal{L}_{\text{align}} + \lambda_2 \mathcal{L}_{\text{llm}} + \lambda_3 \mathcal{L}_{\text{reg}}, \quad (2-7)$$

其中， $\mathcal{L}_{\text{small}}$ 表示小模型时空结构学习损失（第3章中具体化为 $\mathcal{L}_{\text{TSPM}}$ ）； $\mathcal{L}_{\text{align}}$ 表示跨空间对齐损失（含地理一致性损失 $\mathcal{L}_{\text{geo}}$ ）； $\mathcal{L}_{\text{llm}}$ 表示大模型任务损失（第3章中具体化为生成损失 $\mathcal{L}_{\text{gen}}$ ）； $\mathcal{L}_{\text{reg}}$ 表示正则化项； $\lambda_1, \lambda_2, \lambda_3$ 表示各损失项的权重系数。该式用于统一描述整体目标组成；在实现层面，第3章采用“先训练并冻结 TSPM，再进行语义侧两阶段协同优化”的顺序流程，而非端到端联合反向训练。

2.4 研究问题映射

研究空白、建模原则和第4章的研究问题之间具有如下对应关系。Gap-1 对应结构先验显式化原则，并在 RQ2 中通过小模型消融验证；Gap-2 对应空间语义对齐原则，并在 RQ3 中通过 GCIM、PAM 和跨城冷启动实验验证；Gap-3 对应协同训练可部署原则，并在 RQ4、RQ5 中通过双路线互补性和效率评估验证。该映射关系用于约束后续模块设计和实验诊断，使每个方法组件都对应明确的任务缺口。

本章完成了全文问题分析的收束工作。首先给出统一任务定义和符号约定，其次明确评价指标与实验边界，最后将第1章的文献评述转化为三类研究空白和

三条建模原则。下一章将按照这些原则展开具体模型设计与训练机制说明。

第3章 大小模型协同学习方法

3.1 本章引言

本文方法面向 Next POI 预测中的时间异质性、空间连续性和转移先验注入问题，构建“双路线并行、训练协同、推理独立”的研究框架。小模型分支采用时间增强序列预测模型（Time-enhanced Sequential Prediction Model, TSPM）学习时空结构先验，大模型分支采用地理感知大语言模型（Geography-Aware Large Language Model, GA-LLM）吸收地理编码和 POI 结构对齐信息，二者通过训练期表示对齐完成协同，而推理阶段保持 GA-LLM 单路输出^[82,83]。

3.2 总体框架与设计动机

基于第2章的问题分析，本文方法由三个部分构成。

- 1) 小模型分支 TSPM 用于学习时间敏感的时空转移结构^[82];
- 2) 大模型分支 GA-LLM 用于增强地理连续性建模与 POI 先验注入^[83];
- 3) 对齐/协同训练分支通过嵌入对齐与两阶段训练实现协同优化。

设计动机是将小模型的时空结构先验（如时间分槽、转移方向和邻域关系）与大模型的语义推理能力进行互补融合，避免单一路线在精度、鲁棒性或泛化能力上的短板。序列/图模型在局部转移建模上具有优势^[15,42,44,45]，而 LLM 在语义迁移与复杂上下文理解上更强^[53,33,54]；本文的关键是构建一条低损耗的信息通道，使二者不再相互替代，而是协同增益。

如图3-1所示，图示聚焦“语义分支如何吸收结构先验并完成推理输出”的关键路径，轨迹输入先经 GCIM 形成地理编码，再由 PAM 注入结构侧关系信息，随后由 GA-LLM 完成下一 POI 生成。该结构并不表示 TSPM 直接参与在线推理，而是强调 PAM 作为跨分支接口承接协同信息。该设计对应第4章 RQ1 与 RQ4，用于验证结构信息注入带来的整体收益与互补性。在实现层面，本文将同一条签到轨迹整理为三类并行输入流，使序列关系、结构关系和语义上下文分别进入最适合的模型空间。

- 1) **序列流**由时间有序 POI 序列构成，用于 TSPM 提取局部与短期迁移模式；
- 2) **结构流**由动态图邻接关系构成，用于建模高阶转移与区域约束；
- 3) **语义流**由轨迹文本、POI 语义 token 与地理 token 构成，用于 GA-LLM 进




图 3-1 大小模型协同框架示意，图中重点展示 GA-LLM 主推理链路，以及 GCIM 与 PAM 在输入侧的注入流程；其中 PAM 用于承接结构侧（含小模型）学习到的 POI 关系信息并映射到 LLM 语义空间，最终 Top-K 由 GA-LLM 单路输出。

Fig. 3-1 Illustration of the collaborative framework, the figure emphasizes the GA-LLM inference path and the input-side injection of GCIM and PAM. PAM bridges structure-side knowledge (including small-model learned POI relations) into the LLM semantic space, while final Top-K predictions are generated by GA-LLM only.

行语义推理。

三类输入在特征层保持相对独立，在损失层进行耦合，在推理层保持 GA-LLM 单路输出。该设计可避免“早期强融合导致互相干扰”，并降低训练初期梯度不稳定风险。从实现角度看，三类输入流并不是三套互不相关的数据。它们都来自同一条签到轨迹，只是在不同模型空间中承担不同职责，序列流保留访问顺序，结构流强调 POI 之间的迁移关系，语义流负责把时间、类别、位置等信息组织成 LLM 可读取的上下文。本文没有在输入端直接把三类特征拼成一个大向量，是因为早期强融合容易让模型在训练初期过度依赖某一类信号。例如，若 LLM 侧直接接收未经对齐的图嵌入，注意力层可能难以判断这些向量与文本 token 的对应关系；若小模型侧过早混入文本语义，又会削弱其对结构规律的专门建模。因此，本文先让每条路径在自身空间中形成稳定表示，再通过 PAM 和对齐损失建立跨空间通道。在核心符号与问题映射方面，本文沿用第2章给出的统一符号体系，并补充实现级新增变量，包括 ξ^{out}, ξ^{in} （双向转移表示）、 ξ_{seq} （序列聚合表示）、 E_{gps} （地理编码表示）、 E_{poi} （POI 对齐表示）、 $\mathcal{L}_{time}, \mathcal{L}_{seq}, \mathcal{L}_{geo}, \mathcal{L}_{align}, \mathcal{L}_{gen}$ （各模块损失项）。其余符号均与第2章定义保持一致。在协同设计原则上，本文在框架层遵循三条工程原则。

- 1) 先对齐后协同先保证不同空间表示可互相读取，再进行语义侧协同优化；
- 2) 模块可插拔 GCIM、PAM 与 TSPM 均可独立启停，便于消融诊断；

3) 训练资源可控

大模型侧以参数高效微调为主，避免全参更新带来的成本激增。

这些原则对应了本文对“协同”的具体理解。协同不是把所有模块端到端放在一起训练，也不是推理阶段把多个模型的分数的简单加权，而是在训练阶段让不同模型空间中的信息完成可控迁移。小模型更擅长从稀疏签到中学习稳定结构，LLM 更擅长在长上下文和语义标签中完成泛化，两者的结合点应当是可学习表示，而不是人工规则拼接。基于这一点，本文在后续设计中始终保持两个限制，TSPM 不直接参与 GA-LLM 在线推理，GA-LLM 也不反向改变 TSPM 的基础训练目标。这样可以使每个分支的作用边界清楚，便于消融实验解释。从信息流角度看，这种协同方式还可以降低不同模态之间的冲突。签到序列中的时间与 POI ID 适合由序列模型和图模型吸收，因为这些模型能够直接在离散节点、边权和转移方向上优化；POI 名称、类别描述和区域语义则更适合进入 LLM，因为语言模型能够利用上下文语义和长距离依赖完成泛化。若把所有信息无差别地送入同一模型，模型需要同时学习节点结构、坐标连续性和文本语义，训练目标会变得混杂；若完全分离两条路线，又无法让结构知识帮助语义推理。本文选择先在各自空间内形成稳定表示，再用 PAM 和对齐损失建立跨空间联系，实质上是在“专门建模”和“协同利用”之间取得折中。在参数更新层面，这种折中还可以降低训练不稳定风险。TSPM 先独立学习结构表示，避免 LLM 早期梯度直接扰动动态图表示；GCIM 和 PAM 先在输入侧提供可学习注入通道，再由 LoRA 微调适配语义生成目标。这样做虽然增加了训练流程中的阶段划分，但能够把结构学习、地理对齐和生成优化拆分为更可控的子问题。对于 Next POI 这种监督稀疏、候选空间大且城市分布差异明显的任务，稳定的中间表示往往比端到端强行联合更容易获得可复现的收益。

3.3 关键模块设计

3.3.1 小模型分支，TSPM

TSPM 分支的设计初衷是先把“轨迹中的确定性结构规律”学扎实，再把这些规律通过对齐模块迁移给大模型。这里的结构规律主要包括三类，不同时段的行为差异、POI 之间的转入/转出方向性，以及局部邻域中的可达路径关系。换言之，TSPM 承担的是“结构先验提供者”角色。它不追求生成自然语言，而是输出可迁移、可约束的时空表示，为后续 PAM 注入提供稳定来源。

在初始嵌入构建阶段，TSPM 分支首先构建可训练的 POI 初始表示，以保证后续时间分槽与动态图计算有稳定输入。本文采用“关系旋转表示 + 局部拓扑保持”的组合初始化，前者建模转移关系方向性，后者保持近邻几何结构^[84,85]。

$$\mathbf{e}_t^{(0)} \approx \mathbf{e}_h^{(0)} \circ \mathbf{r}_{(h,t)}, \quad (3-1)$$

其中， $\mathbf{e}_h^{(0)}, \mathbf{e}_t^{(0)}$ 表示初始阶段的头/尾 POI 向量； $\mathbf{r}_{(h,t)}$ 表示 POI 转移关系向量； $\circ$ 表示复向量旋转对应的逐元素组合运算。

$$\mathbf{e}_i^{(0)} = \text{EigenMap}(\mathcal{N}(i)), \quad (3-2)$$

其中， $\mathbf{e}_i^{(0)}$ 表示 POI i 的拓扑保持初始化向量； $\mathcal{N}(i)$ 表示 POI i 的局部邻接结构。

该初始化的作用是减少“随机初始化导致的早期训练震荡”，并为后续 TSDG 边权学习提供更平滑的优化起点；在实现上，本文将关系建模与局部几何保持联合使用，以兼顾转移方向性与邻域结构稳定性。在 Next POI 任务中，POI 嵌入的初始状态会明显影响后续动态图学习。如果所有 POI 都从完全随机的位置开始，模型需要先花费较多训练轮数区分“地理邻近但语义不同”“语义相似但路径不连通”等复杂关系，早期梯度容易受到高频 POI 主导。关系旋转表示提供了一个方向敏感的初始约束，使“从 A 到 B”和“从 B 到 A”不被简单视为同一关系；局部拓扑保持则让邻域结构在初始空间中更平滑，避免模型把空间上相近、访问上相关的 POI 分散到完全无关的位置。二者结合后，TSPM 可以更快进入有效的转移建模阶段，而不是先进行大量无结构的嵌入校正。时间增强序列动态图（Time-enhanced Sequential Dynamic Graph, TSDG）中的双向转移部分记为双向转移建模（Bidirectional Transformation Modeling, BTM）。其核心目标是同时学习“转出偏好”和“转入偏好”，与第4章 *w/o BTM* 消融设置一一对应。为刻画不同时段的迁移差异，将一天划分为 z 个时间槽 $\{T_1, \dots, T_z\}$ ，并在各时间槽内构建 POI 转移子图。对当前 POI 嵌入 $\mathbf{e}_i$ 与时间槽嵌入 $\mathbf{t}_i$ ，时间感知转出表示定义为

$$\boldsymbol{\xi}_{i,T_i}^{out} = \sigma([\mathbf{e}_i \parallel \mathbf{t}_i] \mathbf{W}_{out}^t + \mathbf{b}_{out}^t), \quad (3-3)$$

其中， $\boldsymbol{\xi}_{i,T_i}^{out}$ 表示 POI i 在时间槽 T_i 的转出表示； $[\mathbf{e}_i \parallel \mathbf{t}_i]$ 表示 POI 向量与时间槽向量拼接； $\mathbf{W}_{out}^t, \mathbf{b}_{out}^t$ 表示转出分支参数； $\sigma(\cdot)$ 表示非线性激活函数。时间感知转

入表示定义为

$$\xi_{j,T_i}^{in} = \sigma \left([\mathbf{e}_j \| \mathbf{t}_i] \mathbf{W}_{in}^t + \mathbf{b}_{in}^t \right), \quad (3-4)$$

其中， ξ_{j,T_i}^{in} 表示 POI j 在时间槽 T_i 的转入表示； $\mathbf{W}_{in}^t, \mathbf{b}_{in}^t$ 表示转入分支参数。其余符号与式(3-3)一致。




图 3-2 传统序列与时间增强序列的建模对比。

Fig. 3-2 Modeling comparison between the conventional sequential setting and the time-enhanced sequential setting.

如图3-2所示，传统序列将不同时间段的迁移关系混合建模，而时间增强序列能显式区分时段特征。该现象说明“同一 POI 在不同时段具有不同转移分布”是必须建模的结构事实。该结论直接回扣本节 TSDG 设计，并将在第4章 RQ2 中通过消融实验验证。

设计假设 H1，显式时间分槽可提升模型对时段异质行为的建模能力（对应第4章 RQ2 验证）。

对于时间分槽策略，时间分槽粒度过粗会掩盖行为差异，过细会造成样本稀疏。本文采用更直观的分槽原则，先按一天中常见活动时段做初始划分，再检查每个时段样本量是否充足，最后用验证集微调分槽数量。该策略相比固定等距切分更稳健，也更容易解释。时间分槽并不是为了人为增加模型复杂度，而是为了把轨迹中真实存在的生活节律暴露给模型。以城市签到数据为例，早餐、午餐、晚餐、通勤和夜间休闲通常对应不同类别和不同半径的 POI 转移；如果将这些行为放在同一个转移图中统计，模型会得到一个平均化的迁移关系，既不符合早高峰，也不符合深夜场景。本文采用验证集选择分槽数量，是为了在表达能力和样本密度之间取得平衡。分槽越细，模型越能区分时段；但每个子图中的边数也会减少，稀疏区域更容易产生不可靠估计。因此，TSDG 的设计重点不在于“分得越细越好”，而在于找到能够稳定反映行为节律的粒度。在双向转移建模中，仅建模“转出”（当前点通常去哪里）在若干场景下会出现歧义。以工作日早高峰为例，用户从地铁站出发时，候选目的地可能同时包含写字楼、早餐店与便利店；

如果模型只看“地铁站的常见去向”，容易被高频近邻点吸引而忽略真实通勤目的地。反过来看“转入”特性可提供额外判别信息，写字楼在该时段通常承接大量来自交通枢纽的入流，而便利店的入流更分散且短停留。再如晚间场景，商场与住宅区可能共享相似语义标签，但住宅区在夜间具有更稳定的“被到达”模式。基于上述现象，本文同时建模“从哪里来”和“将去哪里”，即联合学习转出表示与转入表示，并通过双向对比损失约束二者的一致性

$$\mathcal{L}_{time} = - \sum_t \log \sigma (\|\xi_{i,T}^{out} - \xi_{-,T}^{in}\|_2^2 - \|\xi_{i,T}^{out} - \xi_{+,T}^{in}\|_2^2), \quad (3-5)$$

其中， $\mathcal{L}_{time}$ 表示时间转移损失； $\xi_{+,T}^{in}, \xi_{-,T}^{in}$ 分别表示正样本与负样本的转入表示； $\|\cdot\|_2^2$ 表示平方欧氏距离；+ 与 - 分别表示正负样本 POI。

设计假设 H2，双向转移优于单向转移，可减少路径偏置并提升下一跳预测稳定性（对应 RQ2 验证）。

从损失函数的直观含义看，式(3-5)的核心是将“当前点到真实下一点”的距离压缩，同时将“当前点到负样本点”的距离拉开。与单向建模相比，双向表示可同时约束“出边合理性”和“入边合理性”，前者回答“当前点一般指向哪些候选”，后者回答“目标点通常由哪些来源到达”。这种双侧约束可显著减少“高频近邻误吸附”与“语义相似点混淆”，尤其在通勤、跨区跳转与晚高峰回流等方向性强的轨迹中更稳定。双向转移建模的另一个作用是缓解候选点语义相近时的排序不稳定。许多城市 POI 具有相似类别标签，例如多个咖啡店、商场入口或地铁站出口在文本上非常接近，但它们在真实轨迹图中的入流来源和出流方向并不相同。仅靠当前点的转出概率，模型容易把这类候选视为同质目标；加入转入表示后，模型会进一步判断候选点是否经常由当前路径到达，从而在语义相似的候选之间建立更细粒度的差异。这也是本文在实验中同时关注 Acc@1 和 MRR 的原因在于双向建模的收益往往体现在把正确候选向前移动，而不仅仅是扩大 Top-K 覆盖。在序列偏好建模与动态图权重计算中，将最近 k 个访问拼接得到序列表示

$$\xi_{seq} = \sigma ([\mathbf{e}_t \| \mathbf{e}_{t-1} \| \cdots \| \mathbf{e}_{t-k}] \mathbf{W}^s + \mathbf{b}^s), \quad (3-6)$$

其中， ξ_{seq} 表示历史序列聚合表示； k 表示历史窗口长度； $\mathbf{W}^s, \mathbf{b}^s$ 表示序列映射参数。并使用序列对比损失

$$\mathcal{L}_{seq} = - \sum_t \log \sigma (\|\xi_{seq} - \mathbf{e}_t^-\|_2^2 - \|\xi_{seq} - \mathbf{e}_{t+1}^+\|_2^2), \quad (3-7)$$

其中, $\mathcal{L}_{seq}$ 表示序列对比损失; $\mathbf{e}_{t+1}^+$ 表示真实下一 POI 嵌入; $\mathbf{e}_t^-$ 表示负样本 POI 嵌入。综合损失写为

$$\mathcal{L}_{TSPM} = \alpha \mathcal{L}_{time} + \beta \mathcal{L}_{seq}, \quad (3-8)$$

其中, $\mathcal{L}_{TSPM}$ 表示小模型总损失; α, β 表示两部分损失权重。据此定义动态图边权

$$s_{i,j}^d = \exp \left(-\rho_1 \|\boldsymbol{\xi}_{seq} - \mathbf{e}_j\|_2^2 - \rho_2 \|\boldsymbol{\xi}_{i,T}^{out} - \boldsymbol{\xi}_{j,T}^{in}\|_2^2 \right), \quad (3-9)$$

其中, $s_{i,j}^d$ 表示动态图从 POI i 到 POI j 的边权; ρ_1, ρ_2 表示两类距离项的平衡系数; $\exp(\cdot)$ 表示指数映射函数。

设计假设 H3, 动态图权重可提升复杂迁移场景下的区分能力 (对应 RQ2、RQ4 验证)。

对于负采样策略, 为避免训练信号过于简单, 本文采用“同区域困难负样本 + 跨区域随机负样本”的混合策略, 前者提升局部细粒度区分难度, 后者维持全局判别边界。该设计沿用并扩展了 TSPM 原始工作中的负采样思路^[82], 有助于提升模型在近邻候选上的排序精度, 并降低模型仅记忆区域标签的风险。需要说明的是, 本文主实验未单独展开“负采样比例/来源”的独立消融, 后续可作为补充实验进一步细化。在位置预测中, 负样本选择比普通推荐任务更敏感。若负样本全部来自远距离区域, 模型很容易通过粗粒度地理差异完成判别, 却未必学会在同一商圈内区分真实目标; 若负样本全部来自近邻区域, 训练又可能过度关注局部细节, 削弱跨区域迁移能力。混合负采样的作用是在两类错误之间取得平衡: 同区域困难负样本迫使模型学习更细的时间和路径差异, 跨区域随机负样本则维持全局空间边界。本文将该策略写入方法实现, 是因为它直接影响 TSPM 输出结构嵌入的质量, 进而影响 PAM 注入给 GA-LLM 的先验是否可靠。在 TiRNN 预测头中, 为建模多步历史依赖, 本文在预测头引入时间感知循环神经网络 (Time-aware Recurrent Neural Network, TiRNN)。其结构如图3-3所示, 右侧为历史隐状态序列 $\{\mathbf{h}_{t-1}, \dots, \mathbf{h}_{t-k}\}$, 左侧为关系向量 $\{\mathbf{r}_1, \dots, \mathbf{r}_k\}$; 二者先通过逐步旋转交互, 再由注意力模块选择关键依赖, 最后与当前输入的全连接映射结果做加和, 得到当前隐状态 $\mathbf{h}_t$ 。其中, 关系向量 $\mathbf{r}_k$ 用于编码“第 $t-k$ 次访问与当前预测时刻之间的转移关系”。它不是随机向量, 而是由历史 POI 与当前上下文之间的相对关系计算得到, 可写为

$$\mathbf{r}_k = \text{RelEnc}(\ell_{t-k}, \ell_t, \Delta t_k, \Delta g_k), \quad (3-10)$$

其中， $\text{RelEnc}(\cdot)$ 表示关系编码函数； ℓ_{t-k}, ℓ_t 表示历史 POI 与当前时刻关联 POI； Δt_k 表示时间间隔特征； Δg_k 表示地理距离/方向特征。因此， $\mathbf{r}_k$ 可理解为“从历史点到当前决策点的关系描述子”，用于调节对应历史隐状态在预测中的作用强度。




图 3-3 TiRNN 预测头结构示意图。
Fig. 3-3 Architecture of the TiRNN prediction head.

该结构的核心作用是把“历史关系建模”和“当前输入建模”分开处理后再融合。注意力分支负责筛选有效历史信号，FC 分支负责保留当前时刻的即时偏好，二者相加后可在短期惯性与中期计划之间做自适应平衡。基于该流程，TiRNN 对过去 K 个隐状态加权融合：

$$\mathbf{c}_t = \sum_{k=1}^K \alpha_k (\mathbf{h}_{t-k} \circ \mathbf{r}_k), \quad (3-11)$$

其中， $\mathbf{c}_t$ 表示时刻 t 的历史上下文向量； K 表示回看步数； α_k 表示第 k 步历史权重； $\mathbf{h}_{t-k}$ 表示第 $t-k$ 时刻隐状态； $\circ$ 表示 Hadamard 逐元素乘。

$$\mathbf{h}_t = \sigma(\kappa \mathbf{v}_t + \mathbf{c}_t), \quad \hat{\mathbf{y}}_t = \text{Softmax}(\mathbf{W}_f [\hat{\mathbf{h}}_t \| \mathbf{E}_u]), \quad (3-12)$$

其中， $\mathbf{h}_t$ 表示当前隐状态； κ 表示当前输入权重； $\mathbf{v}_t$ 表示当前访问表示； $\hat{\mathbf{y}}_t$ 表示候选 POI 概率分布； $\mathbf{W}_f$ 表示预测层参数； $\mathbf{E}_u$ 表示用户嵌入。

从预测头设计动机看，TiRNN 并非替代前述结构模块，而是作为“时序聚合终端”整合动态图编码结果。通过显式聚合多步隐状态，模型可以在“短期活动

惯性”和“中期出行计划”之间动态权衡，从而减少单步过拟合问题。更具体地说，TiRNN 处理的是动态图表示进入最终预测前的时间聚合问题。用户最近一次访问对下一点通常影响最大，但并不总是唯一决定因素。通勤路线可能由早晨多个连续地点共同决定，周末出行也可能由较早的休闲活动埋下线索。普通 RNN 容易把历史压缩成单一隐状态，注意力机制虽然能选择关键步，但若缺少关系向量调节，仍可能把时间间隔和地理跨度不同的历史访问混为一谈。TiRNN 通过关系向量对历史状态进行调制，使模型能够区分“刚刚经过的中转点”和“真正反映目的的历史点”，从而为下一 POI 排序提供更稳定的上下文。

3.3.2 大模型分支，GA-LLM

结合图3-1中的 GA-LLM 信息流，右侧语义分支可拆解为四步。第一步，轨迹事件被组织为统一模板文本；第二步，GCIM 将坐标字段编码为地理 token 并注入输入序列；第三步，PAM 将结构侧 POI 表示映射为语义 token 并注入同一序列；第四步，LLM 直接输出候选分布与 Top- K 结果。该流程对应图3-1中的“语义流 → 对齐 → 输出”路径。

在 GCIM 地理坐标注入模块中，GCIM 采用“层级离散 + 连续频域”双分支编码。为与实验消融项保持一致，本文将连续频域分支记为连续空间编码（Continuous Spatial Encoding, CSE），将层级离散分支记为层级离散编码（Hierarchical Discrete Encoding, HDE）。其中，CSE 定义为

$$\mathbf{E}_{fourier} = \frac{1}{\sqrt{M}} [\cos(\mathbf{g}\mathbf{W}_s^\top) \parallel \sin(\mathbf{g}\mathbf{W}_s^\top)], \quad (3-13)$$

其中， $\mathbf{E}_{fourier}$ 表示 Fourier 频域编码向量； $\mathbf{g}$ 表示坐标输入向量； $\mathbf{W}_s$ 表示频域投影矩阵； M 表示归一化维度系数。融合地理表示定义为

$$\mathbf{E}_{gps} = \mathbf{W}_{gps}[\mathbf{E}_{quad} \parallel \mathbf{E}_{fourier}], \quad (3-14)$$

其中， $\mathbf{E}_{gps}$ 表示最终地理编码； $\mathbf{E}_{quad}$ 表示 Quadkey 层级编码； $\mathbf{W}_{gps}$ 表示融合投影参数。为进一步约束地理表示与真实测地距离的一致性，本文在训练阶段引入测地对齐损失（Geodesic Alignment Loss, GAL）

$$\mathcal{L}_{geo} = \frac{1}{|\mathcal{P}|} \sum_{(i,j) \in \mathcal{P}} |\text{dist}_{geo}(i,j) - \text{dist}_{emb}(i,j)|, \quad (3-15)$$

其中, $\mathcal{L}_{geo}$ 表示地理一致性损失, 对应实验中的 GAL 项; $\mathcal{P}$ 表示批内 POI 对集合; $\text{dist}_{geo}(i, j)$ 表示 POI i, j 的真实测地距离; $\text{dist}_{emb}(i, j)$ 表示编码空间中的距离。针对第1章图1-1所示的空间错位问题, GCIM 在实现层面通过 Quadkey 分支编码层级区域结构, 通过 Fourier 分支编码连续距离变化, 并在投影层完成统一融合。该设计使地理关系以结构化方式进入 LLM 输入空间, 为后续地理一致性约束提供可优化的表示基础。对应图3-1, GCIM 位于 GA-LLM 分支的输入侧, 直接作用于轨迹事件中的坐标字段, 其输出 $\mathbf{E}_{gps}$ 将作为后续结构化提示中的 <GPS> 语义载体, 而不是在 LLM 输出后再做后处理。

设计假设 H4, GCIM 可显著改善地理一致性并降低远跳错误 (对应 RQ3、RQ4 验证)。

对于 Quadkey 与 Fourier 组合编码, Quadkey 适合表达“区域层级归属”, Fourier 适合表达“连续坐标变化模式”^[70,69,83]。前者提供离散空间结构, 后者提供连续距离敏感性, 二者互补后可同时保留地理分区稳定性与局部变化分辨率。该设计可避免仅离散编码导致的边界不连续, 也避免仅连续编码导致的区域语义缺失。选择双分支地理编码还有一个实际原因, 城市空间既有连续距离, 又有层级区域。两个 POI 相距很近时, 连续坐标变化能够反映局部可达性; 但当 POI 跨越行政区、商圈或功能区时, 单纯距离并不足以解释用户行为, 因为不同区域可能具有完全不同的活动语义。Quadkey 分支把坐标映射到层级网格, 使模型能够识别“同一区域、相邻区域、跨区域”等空间层次; Fourier 分支则保留坐标变化的平滑性, 使模型不至于只记住离散网格 ID。二者融合后, GA-LLM 接收的不再是脆弱的坐标字符串, 而是经过结构化处理的地理表示。在具体注入方式上, GCIM 并不改变 LLM 的自回归生成目标, 而是改变输入层对地理字段的表示方式。传统文本坐标输入通常把经纬度拆分为数字、标点和子词片段, 模型需要从这些离散片段中重新学习距离关系; GCIM 则先在模型外部完成坐标到地理表示的变换, 再把结果放入对应的 <GPS> 位置。这样做的好处是, 地理连续性不再完全依赖语言模型从字符串中归纳, 而是通过可训练编码器直接体现在输入嵌入中。换言之, LLM 仍负责整合上下文和生成下一 POI, 但“坐标如何表达”这一部分由专门模块承担, 从而降低了任务对通用 tokenizer 的依赖。GCIM 还为错误分析提供了可解释入口。若模型在启用 GCIM 后命中率提升但平均距离不变, 说明它可能只是改善了候选排序而没有真正学习空间约束; 若平均距离下降但 Acc@1 变化有限, 说明模型虽然仍未总能命中真实 POI, 但错误位置更接近真实活动范围。本文在第4章同时报告坐标注入对比、误差距离分布和平均地理误差,

正是为了避免只用一个指标概括 GCIM 作用。对位置预测而言，“错得更近”本身也有意义，因为它说明模型对城市空间的理解更加稳定。在 PAM POI 对齐模块中，轨迹语义、地理坐标与图结构表示属于不同模态，轨迹文本位于离散 token 语义空间，坐标经 GCIM 后形成地理编码空间，而小模型/图模型输出位于结构表征空间。三类表示若直接拼接，常出现“可用信息无法被同一注意力层稳定读取”的问题，具体表现为结构先验在生成阶段贡献不稳定、跨城迁移时增益波动较大。PAM 的关键并不在于简单增加一个可训练投影层，而在于把“POI 之间如何转移”转换成 LLM 能够在注意力计算中利用的语义侧提示。对于 Next POI 任务，图结构嵌入通常包含两类重要信息，一类是局部可达性，例如当前商圈中的高频下一站、交通枢纽到办公区的常见流向；另一类是高阶关系，例如两个 POI 虽然地理距离不近，但在用户活动链中经常通过中间节点相连。LLM 如果只读取文本模板，很难稳定获得这类关系；而 PAM 通过对齐目标把结构嵌入映射到语义空间，使这些关系以连续向量形式进入生成过程。这样一来，LLM 在生成候选时不只依赖名称和类别，也能利用由小模型或图模型学习到的迁移先验。因此，在将结构信息注入 LLM 之前，需要先建立“结构空间 $\rightarrow$ 语义空间”的可学习映射通道，使 POI 关系先验在语义侧具备可比较、可聚合、可反向优化的表示形式。基于这一需求，本文引入 POI 对齐模块 (POI Alignment Module, PAM)，其核心变换定义为

$$\mathbf{E}_{poi} = \text{PAM}(\mathbf{e}_{poi}) = \mathbf{W}_p \mathbf{e}_{poi} + \mathbf{b}_p, \quad (3-16)$$

其中， $\mathbf{e}_{poi}$ 表示图模型侧 POI 嵌入； $\mathbf{E}_{poi}$ 表示映射后的语义空间 POI 表示； $\mathbf{W}_p, \mathbf{b}_p$ 表示 PAM 映射参数。针对第1章图1-2所示的转移先验缺失问题，PAM 在实现层面构建“结构表征到语义表征”的线性映射通道，并将图模型中的迁移知识注入 LLM 语义空间。该路径避免了仅靠 token 共现学习关系的局限，使模型在候选稀疏和目标未显式出现时仍可利用结构先验进行推断。对应图3-1，PAM 承接小模型/结构侧输出并注入到语义侧输入，承担“跨分支桥接”角色；因此它不是独立预测器，而是连接双分支信息流的关键接口。

设计假设 H5，PAM 可提升目标 POI 未显式出现时的预测能力（对应 RQ3、RQ4 验证）。

对于对齐目标，PAM 的目标不是“替代 LLM 语义”，而是建立一条可学习映射，使图模型中可迁移的结构关系能够在 LLM 空间中被读取和利用。换言之，PAM 承担的是“知识通道”角色，核心价值在于降低跨空间信息损失。如果没有 PAM，结构侧和语义侧之间只能通过文本描述间接交互。例如，可以在提示词中

写入“该 POI 附近还有哪些候选”或“历史路径中出现过哪些转移”，但这种做法会显著增加输入长度，也会把原本连续的结构关系离散化为自然语言片段。PAM 采用可学习投影的原因在于，POI 图嵌入本身已经包含迁移关系和邻域信息，直接把它映射到 LLM 嵌入空间，比把所有关系重新写成文本更紧凑、更稳定。这样既保留了结构模型的归纳偏置，又不破坏 LLM 的生成接口。PAM 的设计也体现了本文对大小模型关系的取舍。小模型不是大模型的附属预处理器，也不是推理阶段的第二个打分器，而是在训练前先独立学习结构嵌入，再通过 PAM 提供给语义侧。这样处理有两个优点。第一，结构嵌入可以来自 TSPM，也可以来自其他时空图模型，因此 PAM 具备接口兼容性；第二，GA-LLM 最终仍以统一生成目标训练和推理，不需要维护两套候选排序逻辑。这种设计比“把两个模型分数相加”更具可解释性，因为它明确回答了结构知识在何处产生、如何迁移、何时参与计算。从失败样本角度看，PAM 尤其适合处理“目标未在输入中显式出现”的场景。纯文本 LLM 往往依赖历史中出现过的 POI、类别或名称线索，当真实目标没有直接出现时，模型容易回到最近访问点或高频相似点；而结构图中可能已经记录了从当前路径到该目标的高阶转移关系。PAM 把这种关系映射为语义空间中的可读向量，使 LLM 在生成时能够感知候选之间的迁移先验。第4章中 PAM 在缺失目标场景的相对提升，正是这一机制的实证表现。在结构化提示构造中，为避免“只有 token 占位符、缺少可学习语义上下文”的问题，本文将每条轨迹组织为“自然语言事件描述 + 结构化专用 token”的混合输入。核心思路是把签到序列转写为按时间递增的事件流，并在每个事件中显式提供时间、POI 语义与地理编码。对于事件文本化规则，设用户 u 在时刻 t_i 访问 POI p_i ，将该事件标准化为

$$\mathcal{E}_i = \text{At } t_i, \text{ user } u \text{ visited } \langle \text{POI } p_i \rangle \text{ with location } \langle \text{GPS } g_i \rangle, \quad (3-17)$$

其中， $\mathcal{E}_i$ 表示第 i 条轨迹事件的文本化表示； $\langle \text{POI } p_i \rangle$ 表示由 PAM 注入的 POI 结构语义 token； $\langle \text{GPS } g_i \rangle$ 表示由 GCIM 注入的地理编码 token。给定历史轨迹 $\{\mathcal{E}_1, \dots, \mathcal{E}_n\}$ ，训练与推理均使用同一字段顺序，以减少模板漂移造成的分布偏差。在微调问答样本格式上，训练阶段采用“Instruction-Input-Output”监督格式，使模型学习从轨迹事实到下一 POI 的映射。模板如下

Prompt Template

Instruction

Predict the next POI based on the user's chronological trajectory.

Input

User ID U_104.

Trajectory events

- 1) At 2024-06-03 08:12, user U_104 visited <POI CoffeeShop_183> with location <GPS 22.2731,113.5728>.
- 2) At 2024-06-03 08:47, user U_104 visited <POI Office_592> with location <GPS 22.2765,113.5881>.
- 3) At 2024-06-03 12:06, user U_104 visited <POI Canteen_74> with location <GPS 22.2748,113.5850>.
- 4) At 2024-06-03 18:21, user U_104 visited <POI Gym_231> with location <GPS 22.2713,113.5794>.

Task Predict the next POI for user U_104.

Output

<POI Supermarket_406>

上述格式的关键在于输入中保留完整时序线索（谁、何时、访问了什么、位于哪里），输出仅监督“下一 POI 标签”，从而使模型将生成能力集中到下一跳判别任务本身。在推理阶段模板中，在线推理时保持与微调同构的模板，仅移除监督答案

Prompt Template

Instruction Predict the next POI based on the user's chronological trajectory.

Input User ID + ordered trajectory events (with <POI> and <GPS> tokens).

Task Predict the next POI for this user.

Output [Model prediction]

其中，<GPS> 由 GCIM 编码、<POI> 由 PAM 编码。该模板在训练与推理阶段字段一致，可有效降低提示分布漂移并提升生成稳定性。从图3-1的角度看，结构化提示就是把“GCIM 地理编码结果”和“PAM 对齐结果”在输入层做显式合并，使 GA-LLM 在同一上下文内同时读取地理约束与转移先验。需要注意的是，结构化提示的作用是保持训练和推理格式一致。若训练阶段使用详细字段而推理阶段只给简短历史，模型会遇到明显的输入分布偏移；若训练阶段只给自然语言

描述，GCIM 和 PAM 得到的结构表示又缺少明确注入位置。本文采用事件流模板，是因为每个签到事件都能以相同顺序包含时间、POI 和坐标字段，便于对齐模块稳定定位。输出端只监督下一 POI 标签，也避免模型把能力浪费在生成解释性文本上，使优化目标集中于候选排序。对于生成目标与解码策略，GA-LLM 的训练目标为标准自回归负对数似然

$$\mathcal{L}_{gen} = - \sum_{t=1}^m \log p(y_t \mid y_{<t}, \mathbf{X}_{traj}, \mathbf{E}_{gps}, \mathbf{E}_{poi}), \quad (3-18)$$

其中， y_t 表示第 t 个生成 token； $\mathbf{X}_{traj}$ 表示轨迹文本序列输入； $\mathbf{E}_{gps}$ 表示 GCIM 注入的地理表示； $\mathbf{E}_{poi}$ 表示 PAM 注入的 POI 先验表示。为与“下一 token 预测”机制保持一致，时刻 t 的输出分布可写为

$$p(y_t \mid y_{<t}, \mathbf{X}) = \text{Softmax}(\mathbf{W}_o \mathbf{h}_t + \mathbf{b}_o), \quad (3-19)$$

其中， $\mathbf{X}$ 表示融合了轨迹文本、地理编码与 POI 先验的输入序列； $\mathbf{h}_t$ 表示解码器在位置 t 的隐藏状态； $\mathbf{W}_o, \mathbf{b}_o$ 表示词表投影参数。在实现层面，融合输入先构造为

$$\mathbf{H}^{(0)} = \text{Embed}(\mathbf{X}_{traj}) + \mathbf{M}_{gps} \odot \mathbf{E}_{gps} + \mathbf{M}_{poi} \odot \mathbf{E}_{poi}, \quad (3-20)$$

其中， $\mathbf{H}^{(0)}$ 表示输入层隐藏表示； $\text{Embed}(\cdot)$ 表示 token 嵌入查表； $\mathbf{M}_{gps}, \mathbf{M}_{poi}$ 表示注入位置掩码 (mask)； $\odot$ 表示逐元素乘。随后每层 Transformer 采用标准“注意力 + 前馈”更新。单头缩放点积注意力写为

$$\text{Attn}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right) \mathbf{V}, \quad (3-21)$$

其中， $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ 表示查询、键、值矩阵； d_k 表示键向量维度。多头注意力与前馈层定义为

$$\text{MHA}(\mathbf{H}) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) \mathbf{W}^O, \quad \text{head}_j = \text{Attn}(\mathbf{H}\mathbf{W}_j^Q, \mathbf{H}\mathbf{W}_j^K, \mathbf{H}\mathbf{W}_j^V), \quad (3-22)$$

$$\text{FFN}(\mathbf{H}) = \phi(\mathbf{H}\mathbf{W}_1 + \mathbf{b}_1) \mathbf{W}_2 + \mathbf{b}_2, \quad (3-23)$$

其中， h 表示注意力头数； $\mathbf{W}_j^Q, \mathbf{W}_j^K, \mathbf{W}_j^V$ 表示第 j 个头的投影参数； $\mathbf{W}^O$ 表示多头输出投影参数； $\phi(\cdot)$ 表示非线性激活函数（如 SiLU/GELU）。当采用 LoRA 进

行参数高效微调时，线性层权重更新可写为

$$\mathbf{W}' = \mathbf{W} + \Delta\mathbf{W}, \quad \Delta\mathbf{W} = \frac{\alpha}{r}\mathbf{BA}, \quad (3-24)$$

其中， $\mathbf{W}$ 表示冻结主干权重； $\Delta\mathbf{W}$ 表示低秩增量参数； r 表示 LoRA 秩； α 表示缩放系数； $\mathbf{A}, \mathbf{B}$ 表示可训练低秩矩阵。GA-LLM 训练与推理过程可概括为以下伪代码。

Algorithm 3-1 GA-LLM Branch with GCIM/PAM Injection

Input trajectory batch $\mathcal{B}$, structure embeddings $\mathbf{e}_{poi}$, coord set $\mathbf{g}$
Output Top- K prediction list for each trajectory

1. Build event-text sequence $\mathbf{X}_{traj}$ from $\mathcal{B}$
2. Compute $\mathbf{E}_{gps} \leftarrow \text{GCIM}(\mathbf{g})$, $\mathbf{E}_{poi} \leftarrow \text{PAM}(\mathbf{e}_{poi})$
3. Fuse input by Eq. (3-20) to obtain $\mathbf{H}^{(0)}$
4. For each Transformer layer, apply Eq. (3-22) and Eq. (3-23)
5. Compute next-token distribution by Eq. (3-19)
6. Train with Eq. (3-18) and LoRA update Eq. (3-24)
7. In inference, run beam search and return Top- K POI IDs

推理阶段采用 beam search 直接生成候选并输出 Top- K 。在本文设定中，不引入候选约束解码、不引入在线重排序、不引入 TSPM 推理打分，即由 GA-LLM 单路完成最终预测输出。核心模块与研究问题之间的对应关系如表3-1所示，该映射使后续实验能够直接检验各模块的作用来源。

表 3-1 模块设计与研究问题映射
Table 3-1 Mapping between module design and research questions.

模块	主要目标	对应 RQ
TSDG + 时间分槽	捕获时段异质迁移	RQ2
双向转移建模	降低方向偏置、提升下一跳稳定性	RQ2, RQ4
动态图权重	强化复杂邻域区分能力	RQ2, RQ4
GCIM	提升地理一致性、抑制远跳错误	RQ3, RQ4
PAM	注入 POI 转移先验，改善缺失目标推断	RQ3, RQ4
LoRA 协同训练	平衡性能与训练成本	RQ5
GA-LLM 直推机制	在保持时延可控前提下输出稳定候选排序	RQ1, RQ5

3.4 对齐与协同训练策略

在两阶段训练流程中，在进入两阶段协同前，先独立训练 TSPM 并固定其参数，导出结构嵌入供 PAM 读取。随后，阶段一冻结 LLM 主体，仅训练 GCIM/PAM 与映射层，建立稳定对齐；阶段二采用 LoRA 微调注意力层，优化大模型生成与对齐目标

$$\mathcal{L}_{total}^{(2)} = \lambda_1 \mathcal{L}_{gen} + \lambda_2 \mathcal{L}_{geo} + \lambda_3 \mathcal{L}_{align}, \quad (3-25)$$

其中， $\mathcal{L}_{total}^{(2)}$ 表示阶段二训练损失； $\mathcal{L}_{gen}$ 表示生成任务损失； $\mathcal{L}_{geo}$ 表示地理一致性损失； $\mathcal{L}_{align}$ 表示跨空间对齐损失； $\lambda_1, \lambda_2, \lambda_3$ 表示对应权重系数。

需要特别说明的是，本文不是“LLM 与 TSPM 端到端联合反向训练”。实际流程是顺序优化，先独立训练 TSPM 并最小化 $\mathcal{L}_{TSPM}$ ，得到结构嵌入；再通过 PAM 把结构嵌入映射到 LLM 语义空间，并在阶段二仅优化 GA-LLM 侧参数。这样写可以避免把“协同”误解为“在线分数融合或全参联训”。对于训练稳定性，联合训练中，不同损失尺度差异会导致优化不稳定。本文采用以下策略缓解，先进行 warm-up 对齐训练，再逐步提高联合损失权重；对梯度范数进行裁剪；采用早停与验证集监控防止过拟合。上述策略在不增加模型复杂度的情况下提升了收敛稳定性。对应图3-1的训练路径，阶段一主要优化“结构流 → 语义流”的对齐通道（Geographic Coordinate Injection Module, GCIM / POI Alignment Module, PAM），阶段二在 GA-LLM 任务目标上进行参数高效微调，避免一开始就全链路联训导致梯度相互干扰。在耦合路径与参数更新机制上，尽管推理阶段仅保留 GA-LLM 单路输出，训练阶段仍通过 $\mathcal{L}_{align}$ 与 $\mathcal{L}_{geo}$ 把结构先验注入语义空间。具体耦合路径为，TSPM 分支先离线产生结构表示（如 ξ_{seq} 、POI 结构嵌入）；PAM 将其投影为语义空间向量 $\mathbf{E}_{poi}$ ；GCIM 提供地理编码 $\mathbf{E}_{gps}$ ；最终在统一生成目标下更新 GA-LLM 侧可训练参数。该流程实质上是“训练期对齐注入”，而非“推理期分数融合”。需要说明的是，本文标题中的“协同学习”特指训练阶段的知识协同，即小模型通过结构化损失提供时空归纳偏置，大模型通过对齐模块吸收这些先验并在语义空间中内化。这种协同体现在三个层面。（1）表示层——PAM 将 TSPM 的结构嵌入映射到 LLM 语义空间；（2）目标层—— $\mathcal{L}_{align}$ 与 $\mathcal{L}_{geo}$ 在训练中同时约束两侧表示的一致性；（3）能力层——训练完成后，GA-LLM 已将结构先验内化为自身参数的一部分，因此推理时无需 TSPM 在线参与即可受益于结构知识。这一设计在保持推理效率的同时实现了跨模型的知识迁移。

从梯度回传角度看，Stage-2 中， $\mathcal{L}_{gen}$ 与 $\mathcal{L}_{align}$ 的梯度只回传到 LoRA、GCIM

表 3-2 两阶段训练中的参数冻结与更新策略
Table 3-2 Parameter freezing and updating strategy in two-stage training.

阶段	主要优化目标	更新参数集合	冻结参数集合
Stage-1 对齐 预热	$\mathcal{L}_{geo} + \mathcal{L}_{align}$	GCIM 投影层、PAM 投影层、对齐映射层	LLM 主干参数、TSPM 主干参数
Stage-2 协同 训练	$\mathcal{L}_{gen} + \lambda_2 \mathcal{L}_{geo} + \lambda_3 \mathcal{L}_{align}$	LoRA 适配参数、 GCIM/PAM 参数、对 齐映射层	LLM 全参数主干（非 LoRA 部分）、TSPM 分支参数

与 PAM。TSPM 在阶段二不参与梯度更新，其作用是提供已训练好的结构嵌入作为 PAM 输入。共享的是“对齐后的表示空间与训练目标”，而非在线推理分数。这种冻结策略看似保守，但更适合本文的研究目标。一方面，TSPM 已经通过结构损失学习了时间和转移先验，若在大模型训练阶段继续被生成损失反向更新，可能会破坏其原有的结构解释性；另一方面，LLM 参数规模远大于小模型，若允许全链路同时更新，训练不稳定时很难判断问题来自结构分支、对齐模块还是语言模型本身。本文将 TSPM 固定为结构先验提供者，把可训练压力集中在 PAM、GCIM 和 LoRA 上，可以使消融实验更清楚，也使工程复现更容易。训练流程中的“先对齐、后协同”并不意味着两阶段在所有数据集上必然优于单阶段，而是提供一种稳定默认路径。阶段一相当于让 GCIM 和 PAM 先学会在 LLM 输入空间中表达地理和结构信息，避免生成损失一开始就主导所有参数；阶段二再让生成目标、地理一致性和跨空间对齐共同优化，使模型在完成预测任务的同时保持结构约束。若数据量很大且分布集中，单阶段训练可能也能收敛到较好结果；但在数据稀疏或跨城迁移场景中，预热对齐通常能降低训练波动。本文在实验章如实报告这一差异，并把两阶段作为更稳健的默认方案。还需要说明的是，协同训练并不会改变 Next POI 任务本身的评价口径。无论训练阶段使用多少辅助损失，测试阶段仍然只评价模型输出的 Top- K 候选是否命中真实 POI，以及错误位置是否更加合理。因此，辅助损失的价值必须通过最终排序、空间误差和效率指标体现，而不能只看训练损失下降。因此，辅助损失只有在最终排序、空间误差和效率指标中体现收益时才具有实际意义。从实现视角看，为便于复现实验，协同训练可归纳为以下步骤。

- 1) 离线训练 TSPM 并导出 POI 结构嵌入，作为后续 PAM 输入；
- 2) 构建轨迹样本并并行生成序列流、结构流与语义流输入；
- 3) 在阶段一中最小化 $\mathcal{L}_{geo} + \mathcal{L}_{align}$ ，得到稳定空间映射；
- 4) 在阶段二中最小化 $\mathcal{L}_{gen} + \lambda_2 \mathcal{L}_{geo} + \lambda_3 \mathcal{L}_{align}$ ，仅更新 LoRA 与 GCIM/PAM

参数（不更新 TSPM）；

- 5) 每个 epoch 后在验证集监控 Acc@1、Acc@5、MRR@5 与平均地理误差；
- 6) 保存最优 checkpoint 并输出可复现实验配置。

在推理阶段，推理时，先由 GCIM 与 PAM 将地理与转移信息注入提示，再由 LLM 输出候选分布并生成最终 Top- K 结果。这一路径与图3-1的语义分支箭头对应，输入轨迹经编码注入后由 GA-LLM 直接完成下一 POI 预测。这里容易产生的疑问是“推理时 TSPM 是否还在工作”。答案是不在线工作。TSPM 的作用发生在训练期与离线准备期，具体包括。

- 1) 先离线训练 TSPM，得到 POI 结构嵌入；
- 2) 再用 PAM 把该嵌入映射到 LLM 语义空间并完成协同训练；
- 3) 推理时仅使用已训练好的 GA-LLM（含 PAM 参数），不再调用 TSPM 分支实时打分。

因此，“TSPM 的中间产物是否作用于 LLM”的准确表述是作用于训练阶段并被 GA-LLM 参数吸收，不在推理阶段显式参与计算。在分支并行与结果对照方面，TSPM 分支用于验证时空结构机制，GA-LLM 分支用于验证地理注入与语义推理机制。最终报告分别基于各自分支的独立输出，不进行显式分数融合或在线重排序。关键超参数与默认配置见表3-3。结合前期实验设置^[82,83]，核心配置如表3-3。其中大模型侧采用统一长上下文微调设置，小模型侧采用与 TSPM 一致的搜索区间并在验证集确定最优值。

表 3-3 关键超参数与默认配置
Table 3-3 Key hyperparameters and default settings.

参数	默认值	说明
基座 LLM	Llama-2-7b-longlora-32k	大模型主干 ^[83]
学习率（LLM 侧）	2×10^{-5}	常数学习率，20 步 warm-up
训练轮数（LLM 侧）	3 epochs	各数据集统一设置
最大序列长度	32768	支持长轨迹输入
Batch Size / GPU	1	与长上下文显存预算匹配
Quadkey 层级 L	25	城市场景下兼顾精度与效率
时间槽数量 z	验证集选择	典型候选为 [4, 6, 8, 12]
Beam size b	验证集选择	控制生成式解码分支数
输出 Top- K	验证集选择	生成结果截断规模
LoRA 秩 r	验证集选择	控制可训练参数规模

对于复杂度与可扩展性，训练成本主要来自三部分，TSPM 动态图更新、LLM 前向计算与跨模型对齐。相较于全参数微调，LoRA 将可训练参数控制在低秩子

空间，显著降低显存与训练时间开销。需要强调的是，推理阶段仅采用 GA-LLM 语义直推；TSPM 仅用于离线对照、机制验证与诊断分析，不参与线上推理输出。在时间复杂度分析中，设批大小为 B ，序列长度为 L ，隐藏维度为 d ，动态图平均邻居数为 K_n ，LLM 层数为 H 。则主要计算量可近似写为

- 1) TSPM 编码 $\mathcal{O}(B \cdot L \cdot d^2 + B \cdot L \cdot K_n \cdot d)$;
- 2) GCIM/PAM 注入 $\mathcal{O}(B \cdot L \cdot d^2)$;
- 3) LLM 前向 (LoRA) $\mathcal{O}(B \cdot L \cdot H \cdot d^2)$ (主导项)。

因此总体瓶颈仍在 LLM 前向，参数高效微调的价值在于显著减少反向传播所需的可训练参数与显存开销。在空间复杂度分析中，空间开销由三部分组成，模型参数、激活缓存与动态图索引。相较全参微调，LoRA 将可训练参数限制在低秩矩阵，显著降低优化器状态占用；动态图仅保留 Top- K_n 邻居，避免全图稠密存储。该组合使模型更易在单机多卡或中等算力环境下训练。为提升结果复现概率，本文采用以下实践。

- 1) 固定随机种子并记录数据切分索引；
- 2) 保存每轮最优检查点与关键超参数配置；
- 3) 将评估脚本与训练脚本解耦，避免指标实现漂移；
- 4) 对核心实验进行多次重复并报告平均趋势而非单次最优值。

在工程实现细节与落地策略上，除理论模块外，完整方法还需要形成“可运行”的工程闭环。本节补充数据管线、训练调度与线上部署细节，以体现方法的可实施性。需要说明的是，本节部分内容属于工程化可选策略，用于超大 POI 空间下的时延控制与服务兜底，不构成本文主实验的必要前提。本文主实验保持 GA-LLM 直接生成 Top- K 的推理口径，不采用 TSPM 召回或在线约束重排。在数据管线与样本构造中，对于轨迹切片规则，本文统一采用前缀预测范式，给定用户轨迹 $\mathcal{T}_u = \{x_1, \dots, x_n\}$ ，构造监督样本为

$$(\{x_1, \dots, x_t\}, x_{t+1}), \quad t \in [1, n-1], \quad (3-26)$$

其中， $\{x_1, \dots, x_t\}$ 表示历史前缀轨迹； x_{t+1} 表示监督目标下一点； $t \in [1, n-1]$ 表示切片索引范围。该范式与真实推荐流程一致，可避免后缀信息泄露，并便于在离线与在线阶段共享样本定义。

在时间槽映射方面，对时间戳先进行本地时区对齐，再映射为时间槽索引。为减少节律冲突，工作日与休息日使用统一分槽规则，并附加二值指示位。该设计可在不增加大量参数的情况下增强周内与周末差异建模能力。

关于解码规模控制，主实验推理采用 beam search 生成并输出 Top- K ，通过 Beam size 与 Top- K 两个参数平衡时延与命中率；不引入候选约束解码、logit mask 或在线重排序。

在分支接口与调度机制中，TSPM 分支输入由 POI 索引序列、时间槽序列与用户索引组成，输出包括候选打分与中间结构表示。该分支主要用于验证时空结构机制与提供对照结果，不直接改写 GA-LLM 推理输出。GCIM/PAM 流水线方面，GCIM 执行“坐标归一化-层级编码-频域编码-投影融合”；PAM 执行“结构嵌入读取-线性投影-语义空间对齐”。两条流水线在训练时共享批内样本索引，可减少跨模块数据搬运开销。对于动态图更新策略，本文优先采用“按 epoch 离线更新图权重”的稳定策略，而非按 batch 增量更新。前者虽牺牲部分即时性，但可显著减少训练震荡并提升复现实验一致性，更适合作为主实验设置。在两阶段训练的工程化约束上，阶段一仅优化对齐相关参数，目标是建立跨空间可读表示；阶段二引入 $\mathcal{L}_{gen} + \mathcal{L}_{geo} + \mathcal{L}_{align}$ 进行语义侧协同优化（TSPM 参数保持冻结）。为保证稳定性，本文采用以下调度约束，对齐阶段较大学习率、联合阶段较小学学习率；按验证集 Acc@1 与 MRR@5 双指标早停；保存“最优检查点 + 最近检查点”双副本，便于回滚与复盘。在推理服务化与异常回退方面，在线部署时，主链路保持“GA-LLM 直推”，并通过 Beam size、Top- K 与提示长度控制时延。当出现地理字段缺失、模板解析失败或模型超时时，系统回退到基础语义模板与规则过滤路径以保证服务可用性。为保证方法实现具有可检查的工程闭环，交付物按表3-4统一整理。

表 3-4 方法实现交付清单
Table 3-4 Implementation delivery checklist of the proposed method.

交付项	说明
数据清洗与切分脚本 训练配置文件	固定过滤规则、切分索引与版本哈希，确保实验可复验 记录学习率、损失权重、随机种子、LoRA 参数与时间槽设置
评估脚本与指标单测 模型检查点规范	统一 Acc/MRR/NDCG 计算逻辑，避免实现漂移 保留最优与最近检查点，支持恢复训练与结果回溯
日志与可视化面板 部署回退策略文档	监控损失曲线、梯度范数与验证指标，支撑异常定位 定义失败条件、回退路径与服务降级流程

3.5 方法对照与讨论

为突出本文协同路线的必要性，表3-5从“时间异质建模、地理连续约束、转移先验注入、跨城泛化、部署成本可控”等维度对比代表方法能力边界。可以看出，单一路线通常只能覆盖局部能力，而协同设计能够在多个关键维度上同时满足要求。

表 3-5 代表方法能力边界对照（“✓”表示具备主能力）
Table 3-5 Capability boundary comparison of representative methods (✓ indicates core capability).

方法	时间异质	地理连续	转移先验	跨城泛化	成本可控
PRME / FPMC			✓		✓
ST-RNN / STAN	✓				✓
GETNext / STHGCN	✓	✓	✓		
LLM4POI				✓	
TSPM	✓	✓	✓		✓
GA-LLM	✓	✓	✓	✓	✓
本文协同框架	✓	✓	✓	✓	✓

该对照表对应两个结论。第一，传统方法和纯 LLM 方法的短板具有互补性；第二，协同框架并非“叠加模块”，而是围绕关键能力缺口做最小闭环补齐。第4章将通过 RQ1–RQ5 逐项验证这种能力补齐是否转化为可测量收益。主实验设定与工程可选策略需要保持边界清楚。主实验保持 GA-LLM 直接生成 Top- K 的口径，不引入候选约束解码、在线重排序或 TSPM 实时打分；工程讨论部分只说明在真实系统中可以如何做缓存、回退和部署调度。因此，本文方法的核心收益来自训练期对齐注入，而不是推理期规则修补。整体来看，本章给出的框架可以理解为三层闭环。底层是 TSPM 学习结构表示，中间层是 GCIM 和 PAM 完成地理与结构注入，上层是 GA-LLM 执行统一生成预测。三层之间既有信息传递，也有边界约束。TSPM 不负责生成，GA-LLM 不直接重建动态图，PAM 和 GCIM 不单独输出推荐结果。这样的模块分工使结构建模、地理注入、对齐通道和推理成本都能够被单独诊断，而不是把所有现象混在一个不可解释的大模型中。

3.6 本章小结

本章完成了协同方法的结构化设计。首先构建了统一框架并明确双分支信息流；其次在小模型侧设计 TSDG、双向转移与动态图权重机制，以增强时空结

构表达；再次在大模型侧设计 GCIM 与 PAM，以注入地理连续性与 POI 转移先验；最后给出两阶段训练与推理流程，并讨论复杂度与可扩展性。新增的符号表、模块-RQ 映射与参数配置表使方法定义更具可复现性，也为下一章按 RQ 组织的实验验证提供了明确的模块级假设与实现接口。

第4章 实验设计与结果分析

4.1 本章引言

本章围绕第3章提出的双路线研究框架开展系统实验，重点评估 TSPM 与 GA-LLM 在总体性能、模块贡献、误差类型、跨城泛化和效率开销上的表现。实验结果需要同时说明模型是否有效、收益来自哪些机制以及推理代价是否可接受。

4.2 实验目标与研究问题

本章围绕“双路线方法是否有效、为何有效、代价如何”展开评估，定义如下研究问题。

- 1) RQ1 (总体有效性) 比较 TSPM 与 GA-LLM 相对于序列、图和 LLM 基线的总体性能提升。
- 2) RQ2 (小模型机制) 验证 TSDG、双向转移与动态图权重等设计的独立增益。
- 3) RQ3 (大模型机制) 验证 GCIM 与 PAM 对空间一致性、冷启动和跨城泛化的影响。
- 4) RQ4 (互补有效性) 分析两条路线在误差类型上的互补关系及关键错误改善情况。
- 5) RQ5 (效率与部署) 评估该框架在时间、显存与参数开销上的可部署性。

4.3 实验设置

在数据集与预处理方面，为避免“母数据集”和“城市子集”混用造成理解混乱，本文先给出统一口径。原始公开数据源包括 Gowalla^① 与 Foursquare^②。其中，Gowalla 时间跨度为 2009 年 2 月至 2010 年 10 月；Foursquare 时间跨度为 2012 年 4 月至 2014 年 1 月。两者均包含用户 ID、POI ID、时间戳、经纬度与类别信息。

对于两条模型路线的数据使用差异，TSPM 路线，使用母数据集 Gowalla 与

^① <http://snap.stanford.edu/data/loc-gowalla.html>

^② <https://sites.google.com/site/yangdingqi/home>

Foursquare 进行训练与评估，侧重验证“时间分槽 + 双向转移 + 动态图”在通用 Next POI 场景下的有效性。

GA-LLM 路线，使用城市/区域子集 NYC、TKY、CA，其中 NYC 即 New York City，TKY 即 Tokyo 由 Foursquare 按城市切分得到，CA 即 California，由 Gowalla 按区域切分得到；其时间范围分别继承对应母数据集的原始时间跨度^[53]。该设置主要用于评估大模型在“跨城市分布差异、长尾与地理泛化”条件下的表现。预处理遵循统一 Next POI 协议，过滤签到次数少于 10 的用户与 POI、按时间排序构造轨迹，并采用时间顺序的 80%/10%/10% 训练-验证-测试划分，避免信息泄露^[53,15,42]。表4-1给出三组城市/区域级数据统计，体现了“NYC 高密度、TKY 多样结构、CA 稀疏广域”三种典型难度场景。

表 4-1 GA-LLM 实验数据集统计
Table 4-1 Statistics of datasets used in GA-LLM experiments.

数据集	用户数	POI 数	类别数	签到数
NYC	1,048	4,981	318	103,941
TKY	2,282	7,833	290	405,000
CA	3,957	9,690	296	238,369

在数据清洗策略上，为保证不同方法比较公平，本文在预处理阶段统一执行以下清洗步骤，异常时间戳剔除、重复签到合并、经纬度缺失样本过滤、低频噪声 POI 裁剪。对于同一用户连续短时间重复签到，按规则合并为单次访问，以避免对短周期“刷点行为”过拟合。

对于轨迹构造原则，轨迹切片采用时间有序滑窗方式构造监督样本，以前缀历史预测下一点。该构造方式与真实推荐流程一致，可避免随机打乱导致的时间泄露。对于超长轨迹，采用固定窗口与可变窗口结合策略，兼顾长期信息保留与训练稳定性。

在评价指标与计算协议上，指标采用 Acc@1、Acc@5、Acc@10、MRR 与 NDCG@K。设第 i 个测试样本中真实 POI 排名为 $rank_i$ ，对应指标定义为

$$\text{Acc}@k = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(\text{rank}_i \leq k), \quad \text{MRR} = \frac{1}{N} \sum_{i=1}^N \frac{1}{\text{rank}_i}, \quad (4-1)$$

其中， N 表示测试样本总数； $rank_i$ 表示第 i 个样本中真实 POI 的排名位置； $\mathbb{I}(\text{rank}_i \leq k)$ 表示是否命中 Top- k 的指示函数； $\frac{1}{\text{rank}_i}$ 表示该样本的倒数排名得分。NDCG@K 与第2章定义一致。对于 LLM 路线，另报告 MRR@5 评估前五候

选排序质量，以适配生成式推荐的输出机制。需要说明的是，传统基线按全候选列表报告标准 **MRR**；GA-LLM 路线按生成式输出口径报告 **MRR@5**。为保证比较公平，本文在对应表格中显式标注指标口径，不将二者混写为同一指标。对于统计显著性与稳健性，除主指标外，本文对关键对比结果进行显著性检验，并在不同随机种子下重复实验，以避免“单次最优偶然性”。具体地，每个核心模型在每个数据集上使用 5 个随机种子重复训练与评测，报告 **mean±std**；显著性采用 **paired t-test**，对 **Acc@1**、**Acc@5** 与 **MRR@5** 做成对检验，阈值设为 $p < 0.05$ 。对于方差较大的设置，报告平均趋势并结合误差分析解释波动来源，而非仅展示最优结果。对比方法按任务路线分为三组。

- 1) **序列方法** FPMC、PRME、LSTM、ST-RNN、STAN 等^[37,11,86,12,14];
- 2) **图与时空方法** STGCN、GETNext、MTNet、STHGCN、ROTAN、Graph-Flashback 等^[15,42,45,44,41];
- 3) **LLM 方法** LLM4POI、E4SRec 与本文 GA-LLM^[53,87]。

主比较对象分别为 TSPM 与 GA-LLM 主模型；小模型与大模型分支结果分别用于回答 RQ2 与 RQ3。在实现细节与统计检验方面，训练阶段采用两阶段策略，先对齐后协同；LLM 侧使用 LoRA 进行参数高效微调。核心设置为，学习率 2×10^{-5} 、warm-up 20 steps、batch size=1/GPU、最大长度 32768、训练 3 epochs、Quadkey 层级 $L = 25$ 。小模型侧采用第3章给出的统一训练协议。每组实验重复多次并报告平均结果；显著性分析用于验证相对提升的稳定性。对于超参数搜索范围，本文对关键超参数采用分层搜索，先粗粒度确定可行区间，再细粒度搜索最优点。重点搜索参数包括时间槽数量、beam size、输出 Top- K 规模、负采样比例、LoRA 秩与学习率。该流程保证“模型改进来源于机制设计”而非超参数偶然命中。在训练资源与复现实务方面，实验统一在固定软硬件环境下运行，记录依赖版本、随机种子和数据切分索引。对可复现实验提供统一脚本入口，确保主结果、消融结果与诊断结果由同一评估代码生成，避免评估实现差异引入偏差。实验设置部分还需要强调一个容易被忽略的问题，即 TSPM 路线和 GA-LLM 路线使用的数据粒度不同，并不意味着二者不可比较。TSPM 在母数据集上验证结构建模的普适有效性，GA-LLM 在城市/区域子集上验证大模型面对复杂城市分布时的地理泛化能力。本文没有把两类结果强行合并到同一张表中，而是分别报告对应任务口径，再通过 RQ4 讨论二者的互补关系。这样组织可以避免“不同数据集上的绝对指标直接相加比较”的问题，也更符合两条路线各自的研究目的。实验解释需要区分“模型机制差异”和“评价口径差异”。传统序列和图模型通常对候

选全集打分，生成式 LLM 路线则通过输出 POI ID 形成候选列表，两者的输出形式不同。如果直接混用 MRR、MRR@5 或不同 Top-K 截断，会造成指标含义不一致。GA-LLM 路线在表格中标注 MRR@5，LLM4POI 原文未报告的指标以缺失值处理。这种处理虽然使表格不如统一指标整齐，但可以避免不恰当补全或二次实现带来的偏差。此外，实验解释还需要避免把所有提升都归结为模型规模或训练轮数。TSPM 的主要变量是时间分槽、双向转移和动态图权重，GA-LLM 的主要变量是地理编码、结构对齐和参数高效微调；二者的比较意义不在于谁替代谁，而在于它们分别验证不同层面的假设。小模型路线回答“显式结构是否仍然有价值”，大模型路线回答“语义模型能否通过地理与结构注入变得更可靠”，消融实验回答“具体收益来自哪个模块”，效率实验回答“这种设计是否会造成不可接受的部署成本”。只有把这些问题分开讨论，实验章的结论才不会停留在单张主结果表上，也更能说明本文方法的整体可信度。从数据集差异看，Gowalla、Foursquare 母数据集和 NYC、TKY、CA 城市子集对应的难度并不相同。母数据集覆盖用户和 POI 范围更广，更适合检验 TSPM 这类结构模型在通用签到预测中的稳定性；城市子集则更突出地理密度、区域功能和跨城分布差异，更适合检验 GA-LLM 在生成式场景下的空间泛化能力。因此，本文分别报告两条路线的主结果，并通过消融与诊断实验解释各自收益来源，而不是把不同粒度数据上的绝对数值直接混合比较。

4.4 主结果与双路线模型基线对比（RQ1）

小模型路线主结果见表 4-2，该表展示了 TSPM 在 Gowalla 与 Foursquare 上的核心结果。可见 TSPM 相较代表性序列/图基线取得稳定增益，说明时间增强与双向转移设计有效。以最强基线 Graph-Flashback 为参照，TSPM 在 Gowalla 上取得 **Acc@1 +5.49%**、**MRR +3.59%**；在 Foursquare 上取得 **Acc@1 +4.53%**、**MRR +3.99%**。这说明改进不仅提升“是否命中”，也提升“命中的排序位置”。

大模型路线主结果见表 4-3，该表展示 GA-LLM 在 NYC/TKY/CA 上的主结果。相较于传统模型、图模型以及文本 LLM 基线，GA-LLM 在三座城市均获得最优 Acc@1/Acc@5/MRR@5，说明“地理注入 + 转移对齐”对 LLM 路线是稳定有效的。相对最强非 GA 基线，GA-LLM 在三城的 Acc@1 提升分别为 **18.27% (NYC)**、**14.73% (TKY)**、**16.69% (CA)**；Acc@5 提升最高达到 **24.10% (CA)**。

表 4-3 最后一行已汇总 GA-LLM 相对最强非 GA 基线的提升比例。三个城市

表 4-2 TSPM 与基线在 Gowalla/Foursquare 上的结果（相对最强非本文基线的提升经 paired t-test 检验达到显著水平， $p < 0.05$ ）

Table 4-2 Results of TSPM and baselines on Gowalla and Foursquare (improvements over the strongest non-ours baseline are significant under paired t-test, $p < 0.05$).

方法	Gowalla				Foursquare			
	Acc@1	Acc@5	Acc@10	MRR	Acc@1	Acc@5	Acc@10	MRR
PRME	0.0740	0.2146	0.2899	0.1503	0.0982	0.3167	0.4064	0.2040
STRNN	0.0900	0.2120	0.2730	0.1508	0.2290	0.4310	0.5050	0.3248
DeepMove	0.0625	0.1304	0.1594	0.0982	0.2400	0.4319	0.4742	0.3270
LBSN2Vec	0.0864	0.1186	0.1390	0.1032	0.2190	0.3955	0.4621	0.2781
STGN	0.0624	0.1586	0.2104	0.1125	0.2094	0.4734	0.5470	0.3283
LightGCN	0.0428	0.1439	0.2115	0.1224	0.0540	0.1790	0.2710	0.1574
Flashback	0.1158	0.2754	0.3479	0.1925	0.2496	0.5399	0.6236	0.3805
STAN	0.0891	0.2096	0.2763	0.1523	0.2265	0.4515	0.5310	0.3420
GETNext	0.1419	0.3270	0.4081	0.2294	0.2646	0.5640	0.6431	0.3988
Graph-Flashback	0.1512	0.3425	0.4256	0.2422	0.2805	0.5757	0.6514	0.4136
TSPM	0.1595	0.3520	0.4350	0.2509	0.2932	0.5978	0.6768	0.4301
提升 (%)	+5.49%	+2.77%	+2.21%	+3.59%	+4.53%	+3.84%	+3.90%	+3.99%

表 4-3 GA-LLM 在 NYC、TKY、CA 上的主结果（最佳加粗，次优下划线；相对最强非本文基线的提升经 paired t-test 检验达到显著水平， $p < 0.05$ ）

Table 4-3 Main results of GA-LLM on NYC, TKY, and CA (best in bold, second-best underlined; improvements over the strongest non-ours baseline are significant under paired t-test, $p < 0.05$).

模型	NYC			TKY			CA		
	Acc@1	Acc@5	MRR@5	Acc@1	Acc@5	MRR@5	Acc@1	Acc@5	MRR@5
FPMC	0.1003	0.2126	0.1701	0.0814	0.2045	0.1344	0.0383	0.0702	0.0911
LSTM	0.1305	0.2719	0.1857	0.1335	0.2728	0.1834	0.0665	0.1306	0.1201
PRME	0.1159	0.2236	0.1712	0.1052	0.2278	0.1786	0.0521	0.1034	0.1002
ST-RNN	0.1483	0.2923	0.2198	0.1409	0.3022	0.2212	0.0799	0.1423	0.1429
STGCN	0.1799	0.3425	0.2788	0.1716	0.3453	0.2504	0.0961	0.2097	0.1712
CLSPRec	0.1784	0.3830	0.2691	0.1453	0.3394	0.2340	0.0891	0.1815	0.1302
PLSPL	0.1917	0.3678	0.2806	0.1889	0.3523	0.2542	0.1072	0.2278	0.1847
STAN	0.2231	0.4582	0.3253	0.1963	0.3798	0.2852	0.1104	0.2348	0.1869
GETNext	0.2435	0.5089	0.3621	0.2254	0.4417	0.3262	0.1357	0.3278	0.2103
MTNext	0.2620	0.5381	0.3855	0.2575	0.4977	0.3659	0.1453	0.3419	0.2367
STHGCN	0.2734	0.5361	0.3915	0.2950	0.5207	0.3986	0.1730	0.3529	0.2558
ROTAN	<u>0.3106</u>	<u>0.5281</u>	<u>0.4104</u>	0.2458	0.4626	0.3475	<u>0.2199</u>	<u>0.3718</u>	<u>0.2931</u>
LLM4POI [†]	0.3372	—	—	0.3035	—	—	0.2065	—	—
GA-LLM	0.3988	0.6337	0.4663	0.3482	0.6207	0.4314	0.2566	0.4614	0.3340
提升 (%)	+18.27%	+17.77%	+12.62%	+14.73%	+19.20%	+8.23%	+16.69%	+24.10%	+13.95%

[†] LLM4POI 原文仅报告 Acc@1，未提供 Acc@5 与 MRR@5，故以“—”标记。

在 Acc@1、Acc@5、MRR@5 上均为正增益，说明提升不是偶然点状收益，而是跨数据分布的稳定趋势。在代表性差值抽样分析中，本文仅抽取代表性对照做细化分析。对于 GA-LLM（见表4-3），在 NYC 上相对最强图基线 ROTAN 的 Acc@1 绝对差值为 **+0.0882** (0.3988 vs 0.3106)；在 TKY 上相对最强图基线 STHGCN 的差值为 **+0.0532** (0.3482 vs 0.2950)；在 CA 上相对 LLM4POI 的差值为 **+0.0501** (0.2566 vs 0.2065)。这三组对照说明 GA-LLM 的优势同时覆盖“图基线强项场景”和“文本 LLM 场景”。对于 TSPM（见表4-2），在 Gowalla 上相对最强基线 Graph-Flashback 的 Acc@1 绝对差值为 **+0.0083** (0.1595 vs 0.1512)，对应 MRR 差值 **+0.0087** (0.2509 vs 0.2422)；在 Foursquare 上对应差值为 **+0.0127** (Acc@1) 与 **+0.0165** (MRR)。该结果表明 TSPM 在强基线条件下依然维持稳定正增益，且改进主要体现在“头部命中与排序质量同步提升”。从指标层面看，Acc@1 与 MRR 提升说明模型不仅“能命中”，且能把真实目标更稳定地排在前列；Acc@10 或 Acc@5 提升说明候选覆盖范围同步改进。这意味着两条路线并未以牺牲覆盖换取头部精度，而是在多指标上保持一致收益。从方法层面看，TSPM 与 GA-LLM 分别在“结构稳定性”和“语义泛化”上体现优势，表明“结构约束 + 语义推理”具备明确互补关系。该结论与第3章设计目标一致。需要指出的是，主结果表中的提升幅度应结合任务难度理解。Gowalla 和 Foursquare 母数据集包含更长时间跨度和更广泛用户行为，小模型路线在强图基线之上继续取得稳定提升，说明时间分槽和双向转移并非只对少数样本有效；NYC、TKY 和 CA 城市子集则更能检验 LLM 在地理稀疏、区域差异和长尾 POI 条件下的泛化能力，GA-LLM 在三类城市上均有正增益，说明 GCIM 与 PAM 不是针对单一城市调参得到的偶然结果。后续消融和诊断实验将进一步解释这些提升来自哪些模块，而不是只停留在结果表层。从使用场景看，小模型路线和大模型路线的主结果也各有含义。TSPM 在母数据集上的改进说明，轻量结构模型仍然适合资源受限或低延迟要求较高的场景；GA-LLM 在城市子集上的改进说明，当系统需要利用 POI 语义、跨区域泛化和复杂上下文时，大模型路线能够提供额外收益。本文并不主张所有场景都必须部署 GA-LLM，也不认为小模型已经被 LLM 替代。更合理的结论是，结构模型提供可靠归纳偏置，大模型提供语义泛化能力，二者可以通过训练期对齐形成互补。

4.5 机制验证与诊断分析（RQ2–RQ4）

在小模型分支消融与诊断（RQ2）中，针对 TSPM 进行逐项消融，重点比较“去除 TSDG”“去除双向转移”等变体。表4-4显示，去除任一关键模块均会降低性能，说明小模型增益并非单一组件造成。

表 4-4 TSPM 消融实验（Gowalla）
Table 4-4 Ablation study of TSPM on Gowalla.

方法	Acc@1	Acc@5	Acc@10	MRR
Flashback	0.1158	0.2754	0.3479	0.1925
TSPM w/o TSDG	0.1573	0.3488	0.4321	0.2482
TSPM w/o BTM	0.1587	0.3515	0.4338	0.2501
TSPM	0.1595	0.3520	0.4350	0.2509

该表揭示了两点。第一，TSDG 负责将时段异质信息显式结构化，去除后整体能力下降最明显；第二，双向转移建模虽增益幅度略小，但对 MRR 影响更敏感，说明其在“正确候选前置”上更关键。进一步按 Acc@1 计算相对提升，完整 TSPM 相比 w/o TSDG 为 **+1.40%** (0.1595 vs 0.1573)，相比 w/o BTM 为 **+0.50%** (0.1595 vs 0.1587)。这说明 TSDG 是主增益来源，BTM 是稳定排序质量的补充增益来源。消融幅度看似不大，但在强基线场景中具有实际意义。Next POI 任务的头部命中率通常受用户历史长度、POI 密度和候选规模共同限制，越接近强基线，单个结构模块能够带来的提升越有限。本文更关注的是消融方向是否稳定。去除 TSDG 后 Acc@1、Acc@5、Acc@10 和 MRR 均下降，说明时段建模不是只改善某个指标；去除 BTM 后 MRR 下降，说明双向转移确实影响正确候选的前置程度。该现象与第3章对时间异质性和转移方向性的分析一致。为了更直观地理解这一点，可以把 TSDG 看作对“何时发生转移”的约束，把 BTM 看作对“转移方向是否合理”的约束。前者决定模型是否能区分早高峰、午间和夜间的不同访问模式，后者决定模型是否能在多个语义相似候选之间识别真实路径方向。两者共同作用时，模型既不会把所有时段混为一个平均转移图，也不会只根据当前点的出边频率做单向判断。这种解释与表4-4中的结果一致。TSDG 带来更明显的整体增益，BTM 则对排序质量提供稳定补充。从错误类型看，TSDG 和 BTM 也具有不同作用。若缺少 TSDG，模型容易把同一地点在不同时段的出行分布混合，例如把午间餐饮转移、晚间休闲转移和通勤转移都压缩到同一个邻接权重中，导致候选排序受高频平均模式支配；若缺少 BTM，模型虽然知道当前点常见去向，却难以判断目标点本身是否具有被到达的合理性，尤其在多个

候选点地理相近或类别相似时更容易出错。完整 TSPM 同时约束时间条件和方向条件，因此在强基线场景中即使绝对提升不大，也能够保持稳定正增益。在大模型分支消融与诊断（RQ3）中，表4-5展示 GA-LLM 在三个数据集上的消融结果。去除 GCIM 带来最大性能回落，说明地理表示建模是 LLM 路线的基础；去除 PAM 同样造成稳定下降，说明转移先验注入不可或缺。

表 4-5 GA-LLM 消融实验 (Acc@1)
Table 4-5 Ablation study of GA-LLM (Acc@1).

变体	NYC	TKY	CA
Full Model	0.3988	0.3482	0.2566
w/o CSE	0.3800	0.3435	0.2467
w/o HDE	0.3813	0.3453	0.2423
w/o GCIM	0.3729	0.3370	0.2402
w/o PAM	0.3901	0.3468	0.2499

该结果与机制解释一致，CSE 更擅长刻画局部连续变化，HDE 更擅长编码稀疏场景下的层级归属，GCIM 融合二者后形成稳定地理约束；PAM 则负责把结构转移知识对齐到 LLM 语义空间。按 Acc@1 的相对提升计算，完整 GA-LLM 相比 w/o GCIM 在 NYC/TKY/CA 分别为 **+6.94%/+3.32%/+6.83%**；相比 w/o PAM 分别为 **+2.23%/+0.40%/+2.68%**。该结果表明 GCIM 负责主要地理一致性收益，PAM 负责稳定补充收益。从三座城市的差异看，GCIM 在 NYC 和 CA 上的相对收益更明显，说明高密度城市和稀疏广域区域都需要显式地理编码，但原因并不相同。NYC 中大量 POI 距离接近，模型需要在相邻候选之间做细粒度区分；CA 中地理跨度较大，模型更容易出现远距离偏移，地理一致性约束能显著减少不合理跳转。TKY 上的 PAM 收益较小，可能与其轨迹密度和城市功能分布有关。当文本上下文和地理编码已经提供较强信号时，结构对齐的边际收益会被压缩。本文保留这些差异，而不是只报告平均提升，是为了更真实地呈现模块作用边界。这种差异也提示我们，消融实验不应只看“去掉模块后平均下降多少”，还要看下降发生在哪些数据条件下。地理编码在广域和高密度场景都重要，但一个偏向减少远跳，一个偏向区分近邻；结构对齐在目标缺失和长尾候选中更重要，但在上下文已经足够强的样本上收益可能不显著。因此，第3章中将 GCIM 和 PAM 设计为可插拔模块，而不是把二者揉成不可分解的单一输入增强。可插拔设计使本文能够在实验中分别解释地理收益和结构收益。对于 GCIM 细粒度消融与参数实验，为进一步回答“GCIM 的有效性来自哪些设计”，表4-6给出 GCIM 内部消融结果。可以看到，移除测地对齐损失（Geodesic Alignment Loss, GAL）后性能显

著下降，说明仅有坐标编码而缺少显式距离一致性约束时，模型仍会出现“语义合理但地理偏离”的预测。

表 4-6 GCIM 内部消融 (Acc@1)
Table 4-6 Internal ablation of GCIM (Acc@1).

变体	NYC	CA
Full Model	0.3988	0.2566
w/o CSE	0.3800	0.2467
w/o HDE	0.3813	0.2423
w/o GAL	0.3809	0.2481
w/o GCIM	0.3729	0.2402

同时，表4-7展示了层级 n -gram 深度与 Quadkey 层级 L 的敏感性。结果表明， $n = 6$ 与 $L = 25$ 在 NYC 与 CA 上均取得最优折中；当 n 或 L 继续增大时，性能反而下降，说明过深层级会引入冗余与噪声，削弱泛化稳定性。

表 4-7 GCIM 关键超参数实验， n -gram 深度与 Quadkey 层级
Table 4-7 Key hyperparameter study of GCIM, n -gram depth and Quadkey level.

设置	NYC Acc@1	NYC Acc@5	NYC MRR@5	CA Acc@1	CA Acc@5	CA MRR@5
$n = 4$	0.3476	0.5249	0.4107	0.2198	0.3986	0.2924
$n = 5$	0.3794	0.5982	0.4451	0.2473	0.4327	0.3185
$n = 6$	0.3988	0.6337	0.4663	0.2566	0.4614	0.3340
$n = 7$	0.3763	0.5894	0.4386	0.2371	0.4213	0.3110
$L = 24$	0.3782	0.5965	0.4438	0.2423	0.4347	0.3191
$L = 25$	0.3988	0.6337	0.4663	0.2566	0.4614	0.3340
$L = 26$	0.3734	0.5851	0.4357	0.2408	0.4223	0.3116
$L = 30$	0.3546	0.5303	0.4220	0.2219	0.4012	0.2957

这一超参数现象说明，地理编码并不是越细越好。过浅的层级会把不同功能区混在一起，难以表达局部可达性；过深的层级又可能把相邻 POI 切分到过多离散单元中，使模型过度记忆训练城市的细节。 $n = 6$ 与 $L = 25$ 取得较好表现，说明该设置在“区域语义”和“局部连续”之间形成了较合理的折中。该结果也支持本文在方法章采用层级离散与连续频域双分支融合，而不是只依赖某一种坐标表达。坐标注入与空间误差分析如图所示。图4-1展示了“坐标注入方式”和“输入开销”对性能的联合影响。横轴为数据集 (NYC、CA)；左纵轴为 Acc@1 (柱状)，右纵轴为每次签到平均 token 数量 (红色折线)。柱状三组分别对应 LLM4POI (纯文本坐标基线)、GA-LLM text-geo (文本地理增强)、GA-LLM w/o PAM (启用 GCIM 但不启用 PAM)。从图中可读出两层对比关系。第一层是“同数据集内的




图 4-1 坐标注入方案对比分析。
Fig. 4-1 Comparison of coordinate injection strategies.

横向对比”，即比较三根柱子的高低；第二层是“性能-开销联合对比”，即比较柱高变化与红线变化是否同步。结果表明，结构化地理注入后 $Acc@1$ 提升明显，而 $token$ 开销增幅相对可控，说明性能提升并非主要来自“输入变长”，而来自地理表示的有效性提升。该图支持的机制结论是，GCIM 把连续坐标映射为更稳定的可学习地理表示，从而提高空间可分性；即使不启用 PAM，GA-LLM 也已显著优于纯文本坐标方案。这一证据直接回答 RQ3（坐标建模是否有效），并与第3章 GCIM 设计动机一致。




图 4-2 不同模型配置下的地理距离误差分布分析。
Fig. 4-2 Distribution analysis of geographic distance errors under different model configurations.

图4-2用于回答“模型到底减少了哪类空间错误”。横轴是预测误差的地理距离分桶（从近距离到远距离）；纵轴是每个距离区间的错误样本占比；不同颜色曲线表示不同模型配置（是否启用 GCIM/相关模块）。该图的关键不是看单个点，而是看整条分布曲线形态。启用 GCIM 后，近距离区间的占比上升，远距离区间占比下降，整体分布重心向左移动。也就是说，错误并未简单减少为“少数样本偶然改善”，而是系统性地把错误从“远跳失真”转为“近邻可达范围内误差”。这一分布变化直接对应第3章的测地一致性约束，模型在语义预测时同步学习空间连

续性，抑制不合理远跳。因而该图同时支撑 RQ3（GCIM 有效性）与 RQ4（模块协同的空间收益来源）。




图 4-3 平均地理误差距离对比。
Fig. 4-3 Comparison of mean geographic error distance.

图4-3是对图4-2分布结论的单值化验证。横轴为数据集/模型配置，纵轴为平均地理误差距离（km），用于直接比较不同方案的整体空间偏差水平。对比结果显示，加入地理增强模块后平均误差距离在多个数据集上均下降。以 CA 为例，平均误差由 61.38 km 降至 37.63 km，对应相对下降 **38.69%**；TKY 也呈同向下降。这说明改进不是只体现在 Acc@K 这类命中指标，而是实质性缩短了“预测位置到真实位置”的空间距离。从机制上看，图4-2给出“误差分布左移”，图4-3给出“均值同步下降”，两者共同说明 GCIM 收益具备分布层与统计量层的双重一致性。因此该图是 RQ3/RQ4 的重要量化补证。在跨城冷启动分析中，跨城冷启动是检验泛化能力的关键场景。表4-8显示，无论以 NYC、TKY 还是 CA 作为训练源，带 GCIM 的模型在跨城测试中均优于文本 LLM 基线，说明模型学习到可迁移的空间规律，而非城市特定记忆。

表 4-8 跨城冷启动结果，LLM4POI 与 GA-LLM w/o PAM（Acc@1）
Table 4-8 Cross-city cold-start results, LLM4POI vs. GA-LLM w/o PAM (Acc@1).

模型	训练城市	NYC 测试	TKY 测试	CA 测试
LLM4POI	NYC	0.3372	0.2594	0.1885
LLM4POI	TKY	0.3463	0.3035	0.1960
LLM4POI	CA	0.3344	0.2600	0.2065
GA-LLM w/o PAM	NYC	0.3901	0.3018	0.2053
GA-LLM w/o PAM	TKY	0.4059	0.3468	0.2273
GA-LLM w/o PAM	CA	0.3670	0.3065	0.2499

该表的关键现象是，以 TKY 为源域训练时对 NYC 泛化最佳，说明更复杂多样的源域可学到更强的地理迁移特征。进一步观察跨城失败样例可见，误差主要

集中在三类情形，稀疏区域样本不足、长尾类别语义歧义、以及城市功能分布差异导致的概念漂移（concept drift）。其中，稀疏广域场景会放大候选可达性判断难度；类别分布差异会削弱“语义近邻 = 空间可达”的假设。该现象解释了为何跨城迁移仍有性能回落，也说明后续应引入更强的域自适应机制。跨城实验还揭示了一个重要事实，即地理规律具有可迁移性，但不是完全城市无关。道路密度、商圈结构、公共交通分布和用户活动半径都会影响下一 POI 预测。GCIM 能够学习坐标连续性和区域层级，这部分规律可以迁移；但某些城市特有的功能布局，例如东京高密度铁路站点周边的复合商业结构，或加州广域出行中的长距离跳转模式，仍需要更多域内样本支持。因此，本文把跨城冷启动作为诊断实验，而不是宣称模型已经完全解决跨域泛化问题。它证明 GCIM 方向有效，同时也指出后续域自适应研究的必要性。从错误类型看，跨城迁移失败往往不是模型完全不理解地理距离，而是对“距离与活动目的之间的关系”估计不足。例如，在高密度城市中，短距离内可能包含多个功能完全不同的 POI，模型需要结合时间和类别才能判断；在广域区域中，用户可能愿意为特定活动跨越较长距离，单纯惩罚远距离并不总是正确。GCIM 提供的是地理连续性基础，PAM 提供的是迁移结构补充，但二者仍需要足够的城市上下文才能处理复杂活动意图。这也是本文后续展望中提出引入路网、交通和区域功能信息的原因。PAM 作用机制可通过图示进一步说明。图4-4聚焦“PAM 在困难场景是否真正有用”。横轴是不同评




图 4-4 PAM 模块作用分析。
Fig. 4-4 Analysis of the PAM module effect.

测场景（如目标 POI 缺失、语义冲突等）；纵轴是排序性能指标（Acc@1/Top-K 命中类）；不同柱或曲线对应“启用 PAM”与“不启用 PAM”两组配置。该图需要分场景读。在常规样本中两组差距有限，而在困难场景中差距显著扩大。以 CA 缺失目标场景为例，Acc@1 由 2.85% 提升至 4.36%，相对提升 **+52.98%**。这表明 PAM 不是“平均意义上的小幅增益模块”，而是在最容易失败的样本上提供关键

补偿。对应机制解释是，当输入中缺少直接目标线索时，纯语义 token 难以恢复可靠转移关系；PAM 通过注入 POI 结构先验，提升候选项在语义空间中的可检索性与可排序性。该图因此直接回答 RQ3 中“PAM 贡献来源”的问题，并为 RQ4 提供困难场景证据。表4-9进一步对比“新增 POI token”与“PAM 对齐”的差异。结论是，仅靠 token 扩展在稀疏数据上有一定收益，但在高密度城市中收益有限；PAM 在两类场景更稳定。

表 4-9 POI 表示方式对比，token 策略与 PAM 策略 (Acc@1)
Table 4-9 Comparison of POI representation methods, token strategy vs. PAM strategy (Acc@1).

方法	NYC	CA
LLM4POI	0.3372	0.2065
E4SRec (POI token)	0.3389	0.2226
only PAM	0.3729	0.2402

此外，表4-10显示 PAM 可作为大小模型联动接口，当 PAM 输入替换为不同小模型产生的 POI 嵌入（TSPM、MTNet、STHGCN、ROTAN）时，大模型侧性能整体保持稳定，其中与 TSPM 嵌入联动时效果最佳。这里的“联动/组合”指训练期的嵌入注入与对齐，并非推理期双模型联合打分。这说明 PAM 不仅“可兼容”，还能够把更强的时空结构先验有效传递到生成式分支。

表 4-10 不同 POI 嵌入来源在 PAM 中的表现 (NYC)
Table 4-10 Performance of different POI embedding sources in PAM (NYC).

模型变体	Acc@1	Acc@5
GA-LLM-TSPM	0.3988	0.6337
GA-LLM-MTNet	0.3988	0.6335
GA-LLM-STHGCN	0.3950	0.6256
GA-LLM-ROTAN	0.3921	0.6162

PAM 相关实验的重点不在于证明“新增一个模块必然提升”，而在于说明结构信息应当以何种方式进入 LLM。仅新增 POI token 可以提高部分样本的可识别性，但它本质上仍是离散符号扩展，无法保证 token 之间的距离关系与真实转移关系一致。PAM 则把结构嵌入投影到语义空间，使 POI 之间的迁移先验在注意力计算中具备连续可比较的表示。表4-10进一步说明，当结构嵌入来源更强时，PAM 能够传递的先验也更有效，这与本文“训练期知识协同”的定位一致。在双路线互补性分析（RQ4）中，互补性结论只基于可观测数据，不引入额外假设。第一，TSPM 在母数据集上的稳定提升（如 Gowalla Acc@1 **+5.49%**、Foursquare

Acc@1 **+4.53%**) 说明结构分支对时间异质迁移建模有效。第二, GA-LLM 在城市子集上的增益 (如 NYC Acc@1 **+18.27%**、TKY Acc@5 **+19.20%**、CA Acc@5 **+24.10%**) 说明语义分支在复杂城市分布下具备更强泛化。第三, GCIM 使平均地理误差显著下降、PAM 在缺失目标场景提升 **+52.98%**, 共同证明“地理一致性 + 转移先验”是 GA-LLM 路线的关键来源。综合来看, 两条路线并非互相替代, TSPM 提供稳定时空结构约束, GA-LLM 提供跨场景语义泛化能力。该互补关系由表4-2、表4-3、表4-5、图4-3与图4-4共同支持。这种互补关系也解释了为什么本文没有把 TSPM 和 GA-LLM 简单合并成一个推理期集成模型。若在线阶段同时运行两个模型并融合分数, 确实可能在部分样本上继续提升指标, 但会引入额外时延、候选对齐和权重调参问题, 且难以判断收益来自结构建模还是后处理融合。本文选择让 TSPM 在训练期提供结构先验, 让 GA-LLM 在推理期独立输出, 是为了把协同收益内化到模型参数和输入表示中。这样得到的系统更简洁, 也更容易部署和解释。互补性还体现在错误修正方式上。TSPM 更擅长减少由时间和路径方向造成的错误, 例如早晚高峰转移模式混淆、目标点入流特征不明显等; GA-LLM 更擅长处理语义上下文复杂、类别信息重要或跨城市分布变化较大的样本。GCIM 进一步约束 GA-LLM 不要产生地理上不合理的远跳, PAM 则把结构侧迁移关系传递给语义分支。由此可见, 本文框架中的互补不是抽象概念, 而是对应到不同错误来源的针对性修正。

4.6 效率与可扩展性分析 (RQ5)




图 4-5 效率与资源开销对比分析。
Fig. 4-5 Comparison of efficiency and resource overhead.

图4-5用于验证“提升是否依赖高成本”。图中联合展示效果指标 (如 Acc@1) 与资源指标 (如训练/推理开销、参数或显存), 不同点或柱代表不同模型配置。读图时重点看“帕累托位置”, 若某配置在相近开销下精度更高, 或在相近精度下降

低开销，则说明其效率更优。实验中 GA-LLM 协同方案位于“较高精度且开销可控”区域，表明其并非依赖全参数微调或超长输入带来的暴力增益。该结果对应第3章复杂度分析，LoRA 降低可训练参数规模，结构化注入减少无效文本冗余，共同带来“精度提升-资源可控”的工程可部署性。这一证据直接回答 RQ5。为增强可量化对比，表4-11归纳了效率研究中的关键现象，GA-LLM 相较 LLM4POI 在保持更高准确率的同时，凭借更紧凑输入与参数高效微调实现更低推理时延。

表 4-11 效率研究关键结论汇总（定性 + 已报告趋势）
Table 4-11 Summary of key findings in efficiency study (qualitative trends with reported observations).

维度	LLM4POI	GA-LLM
输入开销	依赖更长历史文本，token 消耗高	结构化地理/POI 注入，token 更紧凑
训练阶段	全流程文本驱动，微调时长较长	LoRA + 模块化注入，训练效率更高
推理阶段	单次查询时延较高	在多数设置下保持更低时延
部署可行性	对资源要求偏高	在精度与效率间更平衡

在模型规模与训练策略实验中，除效率曲线外，我们进一步补充不同 LLM 规模与训练策略的实验。表4-12显示，GA-LLM 在较小参数规模下仍保持稳定优势，说明本文改进并不依赖“更大模型”才能生效。进一步地，GA-LLM-TSPM、GA-LLM-MTNet、GA-LLM-STHGCN、GA-LLM-ROTAN 四组结果表明，当 PAM 接入不同结构嵌入来源时，性能仍保持稳定提升，验证了 PAM 的接口兼容性。需要强调，这里的“组合”是训练期通过 PAM 注入结构嵌入，不是推理期 TSPM 与 GA-LLM 并行联合预测。

表 4-12 模型规模与 POI 骨干组合实验（NYC）
Table 4-12 Experiments on model scale and POI backbone combinations (NYC).

模型	Acc@1	Acc@5	MRR@5
GA-LLM(7B)	0.3988	0.6337	0.4663
GA-LLM(3B)	0.4070	0.6448	0.4994
E4SRec	0.3389	0.5534	0.4047
MTNet	0.2620	0.5381	0.3855
GA-LLM-TSPM	0.3988	0.6337	0.4663
GA-LLM-MTNet	0.3988	0.6335	0.4662
STHGCN	0.2734	0.5361	0.3915
GA-LLM-STHGCN	0.3950	0.6256	0.4558
ROTAN	0.3106	0.5281	0.4104
GA-LLM-ROTAN	0.3921	0.6162	0.4493

表4-13给出单阶段与两阶段训练对比。在 NYC 数据集上，单阶段训练略优于两阶段训练。分析其原因在于 NYC 数据量较大且 POI 分布集中，对齐预热阶段的收益被充分的端到端优化所覆盖；换言之，当训练样本足以支撑联合优化的稳定收敛时，额外的预热阶段引入的信息瓶颈反而限制了最终性能。然而，两阶段策略在数据更稀疏或分布更复杂的场景中仍具有优化稳定性优势（如 TKY 与 CA 的消融趋势所示）。因此，本文在方法章保留两阶段作为默认策略，以兼顾不同数据条件下的鲁棒性。

表 4-13 训练策略对比 (NYC)
Table 4-13 Comparison of training strategies (NYC).

训练策略	Acc@1	Acc@5
GA-LLM-One Stage	0.3988	0.6337
GA-LLM-Two Stage	0.3922	0.6167

这一结果提醒我们，训练策略不能只用单个数据集上的最优数值判断。单阶段训练在数据集中、模式相对稳定的场景下可能更充分地联合优化；两阶段训练则更强调稳健性，先让结构和地理表示进入可读空间，再让生成目标进行微调。本文最终采用两阶段作为默认流程，并不否认单阶段在特定数据上的优势，而是因为两阶段训练更容易复现、解释且适用于不同数据条件。实际部署时，可以根据验证集表现选择单阶段或两阶段，但核心仍是 GCIM 与 PAM 提供的结构化注入能力。效率分析部分的另一个结论是，参数高效微调并不是单纯为了节省显存，而是与本文“训练期协同、推理期简洁”的目标一致。LoRA 限制了需要更新的参数规模，使 GCIM 和 PAM 可以在较低成本下与 LLM 主干适配；同时，推理阶段不调用 TSPM 在线打分，避免了多模型服务链路。对于真实推荐系统而言，系统复杂度和延迟稳定性往往与离线准确率同样重要。本文把效率评估作为 RQ5 单独讨论，就是为了说明方法不仅能在表格上提升指标，也具备进入工程流程的基本条件。对于部署策略，以下内容属于工程落地可选方案，不属于本文离线实验协议。本文给出三条可实施策略。

- 1) 采用“GA-LLM 直推 + 解码规模控制”的主链路，稳定输出并控制时延；
- 2) 对热门区域建立缓存与增量更新机制，减少重复计算；
- 3) 在离线周期训练与在线小步更新之间建立联动，平衡新鲜度与稳定性。

4.7 本章小结

本章围绕 RQ1–RQ5 构建了完整证据链。

-
- 1) RQ1, 表4-2与表4-3表明 TSPM 与 GA-LLM 两条路线在不同任务设定下均取得稳定提升;
 - 2) RQ2, 表4-4验证小模型关键模块均具有独立贡献;
 - 3) RQ3, 表4-5、表4-8及图4-1至图4-4表明 GCIM 与 PAM 显著提升空间一致性与跨场景泛化;
 - 4) RQ4, 误差分解显示结构建模与语义建模具有可解释互补关系, 可针对性降低空间远跳与历史重复两类典型错误;
 - 5) RQ5, 图4-5与表4-11显示方法在效果与开销之间达到可部署平衡。

综合来看, 本章不仅验证了双路线方法在准确率与鲁棒性上的有效性, 也通过诊断图与效率分析解释了性能来源及工程代价, 形成了从“结果对比”到“机制解释”再到“部署可行性”的完整论证闭环。上述结论为第 5 章的总体总结与后续研究展望提供了直接实证依据。

结论

本文围绕下一兴趣点 (Next POI) 预测任务, 研究了时空结构先验与大语言模型语义推理能力如何协同的问题。全文的出发点并不是简单地把小模型和大模型叠加在一起, 而是针对 Next POI 任务中最突出的三类矛盾进行建模。传统序列与图模型能够刻画局部转移, 却难以覆盖复杂语义和跨场景泛化; 大语言模型具备较强语义理解能力, 却不天然保持经纬度连续性; POI 图中的高阶迁移关系对预测很有价值, 但若缺少映射通道, 难以被 LLM 稳定读取。围绕这些矛盾, 本文形成了“结构先验建模、地理语义增强、跨空间对齐训练”的统一框架。具体而言, 本文首先在绪论中统一梳理了国内外研究现状, 明确了序列模型、图模型和 LLM 推荐方法在 Next POI 任务中的能力边界, 并将文献评述收敛为时间异质性、空间连续性和转移先验注入三类关键问题。随后, 本文给出了统一的问题定义、符号体系和评价口径, 为后续方法和实验建立共同基准。在方法设计上, 本文在小模型侧构建时间增强序列动态图和双向转移建模机制, 通过时间分槽刻画同一 POI 在不同时段的迁移差异, 通过转出/转入双向表示缓解单向转移带来的路径偏置; 在大模型侧, 本文设计地理坐标注入模块 (Geographic Coordinate Injection Module, GCIM) 和 POI 对齐模块 (POI Alignment Module, PAM), 前者融合层级离散编码与连续频域编码, 将地理约束以结构化方式注入语义空间, 后者建立从图结构表征到 LLM 语义空间的可学习映射, 使高阶转移先验能够参与生成式预测。实验结果表明, 本文方法在公开签到数据及城市子集上取得稳定改进。小模型路线中, TSPM 在 Gowalla 上的 Acc@1 相对最强非本文基线提升 5.49%, 说明时间增强和双向转移机制能够提升结构建模质量; 大模型路线中, GA-LLM 在 NYC 上的 Acc@1 提升 18.27%, 并在 TKY、CA 等城市/区域子集上保持一致收益, 说明地理注入和 POI 对齐对 LLM 路线具有稳定贡献。消融实验进一步表明, GCIM 主要改善地理一致性并降低远距离偏移, PAM 则在目标 POI 未显式出现、候选稀疏或语义冲突的样本中提供补偿。效率分析显示, 本文采用参数高效微调和训练期对齐注入, 使推理阶段保持 GA-LLM 单路输出, 避免了在线双模型联合打分带来的额外时延。从实验结果看, 本文结论并不只依赖单一主结果表。TSPM 的提升对应时间异质性与双向转移问题, GCIM 的收益对应坐标连续性问题, PAM 的收益对应结构先验注入问题, 效率实验则对应协同框架能否落地的问题。具体而言, 本文并不是在一个复杂框架中堆叠多个模块,

而是围绕 Next POI 任务的具体缺口逐步补齐能力。进一步分析这些结果可以发现，模型增益具有较清晰的层次关系。TSPM 首先在结构侧改善候选排序，使模型能够更稳定地区分时间段、迁移方向和局部邻域；GCIM 随后在语义侧补足坐标连续性，使 LLM 不再只把经纬度视为普通字符串；PAM 则把结构侧已经学习到的 POI 关系压缩到可被语言模型读取的表示中，使生成式预测在目标 POI 缺失或候选语义相近时仍能参考迁移先验。三者的作用并非互相覆盖，而是分别对应“结构是否可靠”“空间是否一致”“语义能否吸收结构”三个层面。正因为这种层次关系存在，本文在实验章同时报告主结果、消融结果、地理误差和跨城迁移表现，而不是只用单一指标概括方法有效性。Next POI 任务涉及推荐系统、城市计算、图学习和大语言模型多个方向，若仅按模块逐项罗列，容易削弱问题之间的内在联系。本文从任务约束出发说明普通序列推荐为何难以同时处理时间节律、空间可达性和活动语义，再解释图结构为何能够提供高阶转移信息但难以直接进入 LLM，最后引出 GCIM 和 PAM 作为地理与结构注入通道。由此，每个模块都对应明确的问题来源，结论部分也能够回扣全文主线，而不是简单重复实验指标。从创新性看，本文的贡献可以概括为三点。第一，提出面向 Next POI 的大小模型协同学习框架，使结构归纳偏置和语言语义能力在同一任务中形成互补，而非相互替代。第二，设计时间增强序列动态图与双向转移建模，在较低额外成本下显式刻画时段差异和转移方向性。第三，提出 GCIM 与 PAM 两类大模型增强机制，分别解决 LLM 地理连续性不足和结构先验难注入的问题，并通过主结果、消融、跨城冷启动和空间误差分析验证其有效性。从模型行为角度看，本文工作还表明，Next POI 预测中的错误并不是单一来源造成的。部分错误来自时间建模不足，例如模型在工作日与周末之间混淆访问节律；部分错误来自空间建模不足，例如模型生成语义相近但距离过远的 POI；部分错误来自结构先验缺失，例如目标点虽然没有在提示文本中直接出现，却可以由历史路径中的高阶迁移关系推断出来。针对这些不同错误来源，TSPM、GCIM 和 PAM 分别提供了不同的修正路径。TSPM 通过时间增强动态图减少转移方向误判，GCIM 通过地理编码降低空间远跳，PAM 通过结构对齐改善困难候选的可检索性。这样的设计使本文方法不是简单追求平均指标提升，而是把提升来源具体拆解到任务约束上。这一点对理解消融实验尤为重要。如果只观察删除某个模块后的数值下降，容易把模块贡献理解为孤立增量；但从任务机制看，模块之间存在明显的依赖关系。GCIM 提供地理坐标进入 LLM 空间的基础，使生成分支能够识别距离连续性；PAM 提供结构嵌入进入 LLM 空间的接口，使候选 POI 之间的迁移关系不再

只依赖文本共现；TSPM 则提供更稳定的结构嵌入来源，使 PAM 注入的信息具有时空意义。若没有 GCIM，LLM 侧容易产生地理偏移；若没有 PAM，结构先验难以被语义分支利用；若结构嵌入本身质量不足，PAM 即使存在也难以提供可靠增益。因此，本文的协同框架强调的是“有质量的结构先验 + 可学习的跨空间映射 + 可控的生成式推理”，三者共同构成有效方法。从论文整体结论看，本文并不把大语言模型视为可以替代所有专门推荐模型的通用工具。相反，实验说明在具有强时空约束的任务中，LLM 只有在获得合适的结构和地理输入后，才能稳定发挥语义泛化优势。传统序列模型和图模型并未因为 LLM 出现而失去价值，它们仍然是学习稀疏轨迹中稳定迁移规律的重要工具；LLM 的价值在于把这些结构规律与更丰富的语义上下文结合起来，处理候选描述、类别语义和跨场景迁移。本文提出的训练期协同路线正是基于这一判断，让小模型在其擅长的结构空间中学习规律，让大模型在其擅长的语义空间中完成预测，再通过对齐模块把两者连接起来。此外，本文对工程部署的讨论也说明，推荐模型的有效性不能只由离线准确率决定。Next POI 系统面向的是真实用户的移动决策，模型输出需要在有限时间内给出，同时还要避免明显不合理的地理跳转。若一个方法依赖过长提示、全参数微调或推理期多模型复杂融合，即使离线指标较高，也可能难以进入在线服务链路。本文通过参数高效微调、结构化注入和推理期单路输出控制部署成本，使方法具备更清晰的工程边界。虽然本文尚未完成线上 A/B 验证，但离线效率分析已经表明，协同学习并不必然意味着推理复杂度同步增加，关键在于把协同尽量前移到训练阶段。本文仍存在若干不足。首先，实验主要基于公开签到数据集开展离线评估，数据均为历史静态轨迹，对线上实时反馈、动态 POI 变化和服务端延迟波动的适应能力仍需进一步验证。其次，跨域泛化评估主要集中在城市级迁移，对跨国家、跨文化、跨业态等更强分布漂移场景讨论不足。再次，天气、交通事件、节假日和道路拓扑等外部上下文尚未系统纳入建模，在极端天气、突发活动或交通管制等条件下，模型可能仍会出现可达性判断偏差。最后，负采样策略、困难样本构造和不同结构嵌入来源对 PAM 的影响仍有更细粒度的分析空间。此外，本文对大模型侧的讨论主要集中在地理编码和结构对齐，并未深入分析不同基座模型、不同 tokenizer 和不同上下文长度对最终表现的系统影响。对于 Next POI 任务而言，tokenizer 如何切分坐标、POI ID 和类别名称，会直接影响模型对空间信息和候选标识的理解；上下文长度越长，模型能够读取的历史越完整，但推理成本也越高。本文通过参数高效微调和结构化注入控制了主要开销，但仍有必要在后续工作中更细致地比较不同模型规

模、上下文预算和量化部署策略之间的关系。另一个值得进一步研究的问题是评价协议本身。离线 **Top-K** 指标能够反映模型是否命中真实下一 **POI**，但真实系统中的用户可能接受多个合理目的地，尤其在餐饮、购物和休闲场景中，语义相近且距离接近的 **POI** 未必是完全错误的推荐。本文补充了平均地理误差等指标，但仍未完整刻画“可接受替代地点”的评价方式。后续可以结合地理距离、类别相似度、路线成本和用户反馈构建更细粒度的软评价指标，使模型评估更贴近真实应用。从方法适用性看，本文提出的协同框架更适合存在明显时空结构约束、且候选 **POI** 具有语义描述的场景。如果应用环境中的 **POI** 缺少稳定类别、坐标噪声较大或用户轨迹极短，**GCIM** 和 **PAM** 能够提供的增益会受到限制；如果系统只需要极低延迟的局部召回，轻量结构模型可能比 **LLM** 路线更合适；如果系统需要解释复杂活动意图、处理跨城迁移或结合丰富上下文，大模型路线则更有优势。因此，本文结论不应被理解为“**LLM** 必然优于小模型”或“小模型只用于辅助”，而应理解为不同模型在不同约束下具有互补价值。训练期对齐提供了一种把这种互补性转化为统一预测能力的方式。从工程使用角度看，大小模型协同还需要区分训练收益和服务收益。训练阶段可以允许 **TSPM**、**GCIM** 和 **PAM** 共同参与表示学习，因为此时主要目标是把时空结构、地理连续性和语义生成目标对齐；但在线服务阶段若继续保留多模型联合打分，系统需要同时维护结构模型服务、**LLM** 服务和融合策略，候选延迟与故障面都会增加。本文选择将结构知识通过 **PAM** 迁移到 **GA-LLM** 输入表示中，并在推理阶段保持单路输出，实质上是在离线训练复杂度和在线服务复杂度之间作取舍。这样的设计并不意味着小模型作用减弱，而是把小模型最有价值的结构归纳偏置提前转化为可被 **LLM** 吸收的表示，使在线链路只承担必要的生成和排序任务。对于本地生活、文旅路线和城市出行等场景，这种取舍更接近真实系统需要模型既要有足够的空间判断能力，也要能在可控时延内返回稳定候选。在更一般的推荐系统语境下，本文也说明了一个重要问题，即当任务包含明显物理约束和结构规律时，语言模型的语义能力需要与专门的归纳偏置配合使用。**Next POI** 预测中的地理距离、时间节律、转移方向和候选可达性都不是普通文本语义能够完全覆盖的因素；它们既需要可解释的结构建模，也需要能够与 **LLM** 输入空间对齐的表示通道。**TSPM**、**GCIM** 和 **PAM** 分别对应这三类需求，使模型既能保留传统时空推荐方法的稳定性，又能利用大语言模型对类别语义、历史上下文和跨区域模式的理解。由此得到的启示是，面向强约束推荐任务时，模型设计不应只追求更长提示或更大参数规模，而应先识别任务中必须显式建模的约束，再决定这些约束以何种形式

进入语义模型。这一结论对后续位置推荐研究具有直接启发。若未来系统希望处理更复杂的城市环境，仅依赖轨迹文本和 **POI** 名称仍然不够，还需要把道路网络、实时交通、区域功能和用户即时意图作为可对齐的外部证据接入模型；若系统面向隐私敏感或资源受限场景，则需要进一步研究如何在不暴露原始轨迹、不增加过多推理成本的前提下保留结构先验。本文提出的训练期协同与推理期简化思路，为这两类方向提供了一个基础框架。后续研究可从三个方向推进。其一，引入多模态城市上下文，例如路网拓扑、实时交通状态、**POI** 图像和区域功能信息，使模型能够在复杂城市动态环境中获得更完整的证据。其二，研究在线自适应更新机制，使模型在新用户、新 **POI** 和概念漂移条件下持续学习，同时控制更新成本和稳定性风险。其三，进一步优化推理链路和模型压缩策略，在保证地理一致性和排序质量的同时降低端到端时延，推动该类方法从离线论文实验走向真实位置服务系统。总的来说，本文尝试回答的是一个具有现实约束的问题，即在下一兴趣点推荐中，如何让小模型学到的时空结构规律真正帮助大模型，同时又不牺牲推理阶段的简洁性。本文给出的答案是训练期协同、表示层对齐和推理期单路输出。实验结果说明这一思路具有可行性，也为后续在更复杂城市环境、更丰富上下文和更严格部署约束下继续研究提供了基础。因此，本文的价值不仅在于提出了 **TSPM**、**GCIM** 和 **PAM** 三个具体模块，也在于给出了一种处理强约束推荐任务的思路，即先识别任务中不能完全交给语言模型隐式学习的结构因素，再用专门模块把这些因素编码为可被 **LLM** 读取的表示，最后通过参数高效训练把能力保留在简洁的推理链路中。对于后续面向城市智能、移动推荐和位置服务的大模型研究，这一思路仍具有扩展空间。

参考文献

- [1] KOREN Y, BELL R, VOLINSKY C. Matrix factorization techniques for recommender systems[J]. Computer, 2009, 42(8): 30-37.
- [2] RENDLE S, FREUDENTHALER C, GANTNER Z, et al. Bpr: Bayesian personalized ranking from implicit feedback[C]//UAI. 2009: 452-461.
- [3] HE X, LIAO L, ZHANG H, et al. Neural collaborative filtering[C]//WWW. 2017: 173-182.
- [4] ZHANG S, YAO L, SUN A, et al. Sequential recommendation: A survey[J]. ACM Computing Surveys, 2023.
- [5] 刘鹏, 王斌, 张强. 推荐系统研究进展与趋势[J]. 计算机学报, 2022, 45(1): 1-23.
- [6] GAO S, JANOWICZ K, COUCLELIS H. A survey on spatio-temporal data mining and recommendation[J]. ACM Computing Surveys, 2022.
- [7] 赵颖, 孙浩, 刘畅. 时空轨迹挖掘研究进展[J]. 地理与地理信息科学, 2022, 38(3): 1-12.
- [8] 何军, 黄凯, 罗敏. 基于位置服务数据的用户移动行为建模综述[J]. 地球信息科学学报, 2021, 23(8): 1501-1518.
- [9] 刘畅, 张宁, 何宇. 城市时空行为分析与智能推荐研究[J]. 地理科学进展, 2023, 42(7): 1402-1418.
- [10] 郑薇, 孙晨, 刘峰. 位置推荐中的地理约束建模研究[J]. 测绘学报, 2024, 53(2): 220-235.
- [11] FENG S, LI X, ZENG Y, et al. Personalized ranking metric embedding for next new poi recommendation[C]//IJCAI. 2015: 2069-2075.
- [12] LIU Q, WU S, WANG L, et al. Predicting the next location: A recurrent model with spatial and temporal contexts[C]//AAAI. 2016: 194-200.
- [13] KONG D, WU F. Hst-ilstm: A hierarchical spatial-temporal long-short term memory network for location prediction[C]//IJCAI. 2018: 2341-2347.
- [14] LUO Y, LIU Q, LIU Z. Stan: Spatio-temporal attention network for next location recommendation[C]//WWW. 2021: 2177-2185.
- [15] YANG S, LIU J, ZHAO K. Getnext: Trajectory flow map enhanced transformer for next poi recommendation[C]//SIGIR. 2022: 1144-1153.
- [16] WU S, SUN F, ZHANG W, et al. Graph neural networks in recommender systems: A survey [J]. ACM Computing Surveys, 2022.
- [17] CAO Z, LIAN D, ZHAO P, et al. Trajectory reasoning with large language models: A survey: abs/2407.04441[J/OL]. 2024. <https://arxiv.org/abs/2407.04441>.
- [18] LI X, KE J, GONG H, et al. Spatial foundation models: A survey: abs/2405.17214[J/OL]. 2024. <https://arxiv.org/abs/2405.17214>.
- [19] GAO C, FAN W, ZHU Y, et al. Large language models for recommender systems: A survey:

-
- abs/2308.10837[J/OL]. 2023. <https://arxiv.org/abs/2308.10837>.
- [20] HIDASI B, KARATZOGLOU A, BALTRUNAS L, et al. Session-based recommendations with recurrent neural networks[C]//ICLR. 2016.
- [21] LI J, REN P, CHEN Z, et al. Neural attentive session-based recommendation[C]//CIKM. 2017: 1419-1428.
- [22] LIU Q, ZENG Y, MOKHOSI R, et al. Stamp: Short-term attention/memory priority model for session-based recommendation[C]//KDD. 2018: 1831-1839.
- [23] HIDASI B, KARATZOGLOU A. Recurrent neural networks with top-k gains for session-based recommendations[C]//CIKM. 2018: 843-852.
- [24] ZHOU K, WANG H, ET AL. Fmlp-rec: Filter-enhanced mlp is all you need for sequential recommendation[C]//WWW. 2022: 2388-2399.
- [25] YING R, HE R, CHEN K, et al. Graph convolutional neural networks for web-scale recommender systems[C]//KDD. 2018: 974-983.
- [26] WU S, TANG Y, ZHU Y, et al. Session-based recommendation with graph neural networks [C]//AAAI. 2019: 346-353.
- [27] HE X, DENG K, WANG X, et al. Lightgcn: Simplifying and powering graph convolution network for recommendation[C]//SIGIR. 2020: 639-648.
- [28] WANG X, HE X, WANG M, et al. Kgat: Knowledge graph attention network for recommendation[C]//KDD. 2019: 950-958.
- [29] YU J, YIN H, GAO M, et al. Are graph augmentations necessary? simple graph contrastive learning for recommendation[C]//SIGIR. 2022: 1294-1303.
- [30] WEI W, REN X, TANG J, et al. Llmrec: Large language models with graph augmentation for recommendation[C]//WSDM. 2024: 806-815.
- [31] ZHANG Y, FENG F, ZHANG J, et al. Collm: Integrating collaborative embeddings into large language models for recommendation: abs/2310.19488[J/OL]. 2023. <https://arxiv.org/abs/2310.19488>.
- [32] WU J, CHANG C C, YU T, et al. Coral: Collaborative retrieval-augmented large language models improve long-tail recommendation[C]//KDD. 2024: 3391-3401.
- [33] LIAO J, LI S, YANG Z, et al. Llara: Large language-recommendation assistant[C]//SIGIR. 2024: 1785-1795.
- [34] TANG J, YANG Y, WEI W, et al. Graphgpt: Graph instruction tuning for large language models[C]//SIGIR. 2024: 491-500.
- [35] WANG Q, LI M, SUN R, et al. Geo-llmrec: Geographic grounding for llm-based location recommendation: abs/2408.01993[J/OL]. 2024. <https://arxiv.org/abs/2408.01993>.
- [36] ZHENG Y, LUO Y, WANG J, et al. Large language models meet next poi recommendation: A benchmark and beyond: abs/2409.01327[J/OL]. 2024. <https://arxiv.org/abs/2409.01327>.
- [37] RENDLE S, FREUDENTHALER C, SCHMIDT-THIEME L. Factorizing personalized

-
- markov chains for next-basket recommendation[C]//WWW. 2010: 811-820.
- [38] KANG W C, MCAULEY J. Self-attentive sequential recommendation[C]//ICDM. 2018: 197-206.
- [39] SUN F, LIU J, WU J, et al. Bert4rec: Sequential recommendation with bidirectional encoder representations from transformer[C]//CIKM. 2019: 1441-1450.
- [40] SUN K, QIAN T, CHEN T, et al. Where to go next: Modeling long- and short-term user preferences for point-of-interest recommendation[C]//AAAI. 2020: 214-221.
- [41] RAO X, CHEN L, LIU Y, et al. Graph-flashback network for next location recommendation [C]//KDD. 2022: 1463-1471.
- [42] YAN X, SONG T, JIAO Y, et al. Spatio-temporal hypergraph learning for next poi recommendation[C]//SIGIR. 2023: 403-412.
- [43] YIN F, LIU Y, SHEN Z, et al. Next poi recommendation with dynamic graph and explicit dependency[C]//AAAI. 2023: 4827-4834.
- [44] FENG S, MENG F, CHEN L, et al. Rotan: A rotation-based temporal attention network for time-specific next poi recommendation[C]//KDD. 2024: 759-770.
- [45] HUANG T, PAN X, CAI X, et al. Learning time slot preferences via mobility tree for next poi recommendation[C]//AAAI. 2024: 8535-8543.
- [46] GENG S, LIU S, FU Z, et al. Recommendation as language processing (rlp): A unified pretrain, personalized prompt & predict paradigm (p5)[C/OL]//Proceedings of the 16th ACM Conference on Recommender Systems. 2022: 299-315. DOI: 10.1145/3523227.3546767.
- [47] BAO K, ZHANG J, ZHANG Y, et al. Tallrec: An effective and efficient tuning framework to align large language model with recommendation: abs/2305.00447[J/OL]. 2023. <https://arxiv.org/abs/2305.00447>.
- [48] JI J, LI Z, XU S, et al. Genrec: Large language model for generative recommendation: abs/2307.00457[J/OL]. 2023. <https://arxiv.org/abs/2307.00457>.
- [49] HUA W, XU S, GE Y, et al. How to index item ids for recommendation foundation models: abs/2305.06569[J/OL]. 2023. <https://arxiv.org/abs/2305.06569>.
- [50] RAJPUT S, MEHTA N, SINGH A, et al. Recommender systems with generative retrieval[C]//Advances in Neural Information Processing Systems: volume 36. 2023.
- [51] TAN J, XU S, HUA W, et al. Idgenrec: Llm-recsys alignment with textual id learning[C/OL]//Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2024: 355-364. DOI: 10.1145/3626772.3657821.
- [52] KIM S, KANG H, CHOI S, et al. Large language models meet collaborative filtering: An efficient all-round llm-based recommender system[C/OL]//Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2024: 1395-1406. DOI: 10.1145/3637528.3671931.
- [53] LI P, DE RIJKE M, XUE H, et al. Large language models for next point-of-interest recom-

-
- mendation[C]//SIGIR. 2024: 1463-1472.
- [54] WANG S, XIE B, DING L, et al. Secor: Aligning semantic and collaborative representations by large language models for next-poi recommendations[C]//RecSys. 2024: 1-11.
- [55] WU Z, SUN Z, WANG D, et al. Mrp-llm: Multitask reflective large language models for privacy-preserving next poi recommendation: abs/2412.07796[J/OL]. 2024. <https://arxiv.org/abs/2412.07796>.
- [56] WU Y, PENG Y, YU J, et al. Mas4poi: A multi-agents collaboration system for next poi recommendation: abs/2409.13700[J/OL]. 2024. <https://arxiv.org/abs/2409.13700>.
- [57] LI K, LIM K H. Rallm-poi: Retrieval-augmented llm for zero-shot next poi recommendation with geographical reranking: abs/2509.17066[J/OL]. 2025. <https://arxiv.org/abs/2509.17066>.
- [58] 张伟, 李明, 陈晓. 序列推荐方法综述[J]. 软件学报, 2023, 34(5): 1200-1230.
- [59] 王磊, 赵宁, 郭超. 图神经网络推荐算法研究综述[J]. 计算机研究与发展, 2023, 60(9): 2100-2125.
- [60] 李航, 周洋, 马宁. 大语言模型驱动推荐系统研究综述[J]. 中文信息学报, 2024, 38(2): 45-62.
- [61] 孙涛, 陈立, 杜鹃. 下一兴趣点推荐技术综述[J]. 计算机科学, 2022, 49(6): 12-28.
- [62] 杨帆, 郑凯, 谢强. 基于图学习的 POI 推荐方法综述[J]. 小型微型计算机系统, 2023, 44(9): 2081-2092.
- [63] 陈思, 刘颖, 张旭. 大模型时代的推荐系统: 机遇与挑战[J]. 计算机工程与应用, 2024, 60(1): 1-14.
- [64] 高飞, 田野, 许航. 生成式推荐模型研究综述[J]. 计算机工程, 2024, 50(3): 34-48.
- [65] 黄丽, 彭博, 谢婷. 检索增强生成在推荐系统中的应用进展[J]. 情报学报, 2024, 43(7): 987-1002.
- [66] 许晨, 卢伟, 郑琳. 大语言模型可解释推荐研究进展[J]. 数据分析与知识发现, 2024, 8(2): 20-35.
- [67] 钱亮, 罗涛, 魏杰. 面向冷启动场景的推荐系统研究综述[J]. 计算机应用研究, 2024, 41(10): 3001-3016.
- [68] ZHAO P, ZHU Y, LIU Y, et al. Where to go next: A spatio-temporal gated network for next poi recommendation[C]//AAAI. 2019: 5877-5884.
- [69] WANG E, JIANG Y, XU Y, et al. Spatial-temporal interval aware sequential poi recommendation[C]//ICDE. 2022: 2086-2098.
- [70] LIAN D, WU Y, GE Y, et al. Geography-aware sequential location recommendation[C]//KDD. 2020: 2009-2019.
- [71] LI X, CONG G, LI A, et al. Geographical and temporal graph convolutional networks for next poi recommendation[C]//AAAI. 2020.
- [72] ROBERTS J, LUEDDECKE T, DAS S, et al. Gpt4geo: How a language model sees the world's geography: abs/2306.00020[J/OL]. 2023. <https://arxiv.org/abs/2306.00020>.

-
- [73] CHEN W, HUANG H, ZHANG Z, et al. Next-poi recommendation via spatial-temporal knowledge graph contrastive learning and trajectory prompt[J]. IEEE Transactions on Knowledge and Data Engineering, 2025, 37(6): 3570-3582.
- [74] LIN J, SHAN R, ZHU C, et al. Rella: Retrieval-enhanced large language models for lifelong sequential behavior comprehension in recommendation[C]//WWW. 2024: 3497-3508.
- [75] WANG S, FAN W, FENG Y, et al. Knowledge graph retrieval-augmented generation for llm-based recommendation: abs/2501.02226[J/OL]. 2025. <https://arxiv.org/abs/2501.02226>.
- [76] WU Q, WANG X, LIN J, et al. Retrieval-augmented generation for recommendation: A review: abs/2406.13318[J/OL]. 2024. <https://arxiv.org/abs/2406.13318>.
- [77] ZHANG A, CHEN Y, SHENG L, et al. On generative agents in recommendation[C/OL]//SIGIR. 2024: 1807-1817. DOI: 10.1145/3626772.3657844.
- [78] RAO X, JIANG R, SHANG S, et al. Next point-of-interest recommendation with adaptive graph contrastive learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2025, 37(3): 1366-1379.
- [79] CHEN J, SANG Y, ZHANG P F, et al. Enhancing long-and short-term representations for next poi recommendations via frequency and hierarchical contrastive learning[C]//AAAI. 2025: 11472-11480.
- [80] QU L, LIU H, LI P, et al. Onerec: Unifying retrieval and ranking with large language models for recommendation: abs/2403.05430[J/OL]. 2024. <https://arxiv.org/abs/2403.05430>.
- [81] YU Q, FU K, LV Z, et al. Thinkrec: Thinking-based recommendation via llm: abs/2505.15091 [J/OL]. 2025. <https://arxiv.org/abs/2505.15091>.
- [82] LIU Z, LIU W, ZHU H, et al. Next poi recommendation based on time slot preferences and bidirectional transformation modeling[C]//WISE. 2024: 337-352.
- [83] LIU W, LIU Z, XIE M, et al. Geography-aware large language model for next poi recommendation[C]//ICDE. 2026.
- [84] SUN Z, DENG Z, NIE J, et al. Rotate: Knowledge graph embedding by relational rotation in complex space[C]//ICLR. 2019.
- [85] BELKIN M, NIYOGI P. Laplacian eigenmaps for dimensionality reduction and data representation[J]. Neural Computation, 2003, 15(6): 1373-1396.
- [86] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [87] LI X, CHEN C, ZHAO X, et al. E4srec: An elegant effective efficient extensible solution of large language models for sequential recommendation: abs/2312.02443[J/OL]. 2023. <https://arxiv.org/abs/2312.02443>.

附录

(一) 已发表的学术论文

- 1) Zhao Liu, Wei Liu, Huaijie Zhu, Jianxing Yu, Jian Yin. *Next POI Recommendation Based on Time Slot Preferences and Bidirectional Transformation Modeling* (Time-enhanced Sequential Prediction Model, TSPM)。 **WISE 2024 (CCF B)** .
- 2) Wei Liu*, Zhao Liu, Muzu Xie, Huaijie Zhu, Jianxing Yu, Jian Yin, Wang-Chien Lee. *Geography-Aware Large Language Model for Next POI Recommendation* (Geography-Aware Large Language Model, GA-LLM)。 **ICDE 2026 (CCF A)** .

上述两项工作分别对应本文的两条技术主线。TSPM 工作主要围绕时间分槽和双向转移建模展开，强调在轻量结构模型中显式表达时段差异、转出偏好和转入偏好；GA-LLM 工作则进一步讨论大语言模型在 Next POI 任务中的地理连续性不足和结构先验注入问题，强调通过地理编码与 POI 对齐增强生成式推荐的空间可靠性。二者共同服务于同一研究目标，即小模型分支用于学习稳定的时空结构，大模型分支用于吸收地理和转移先验，训练期通过对齐模块完成知识迁移，推理期保持 GA-LLM 单路输出。TSPM 与 GA-LLM 并非两条彼此割裂的工作线，而是围绕同一 Next POI 任务在不同建模层面展开的连续研究。TSPM、GCIM 和 PAM 分别解决时间异质性、空间连续性和转移先验注入三个问题，并共同服务于训练期协同、表示层对齐和推理期单路输出这一技术路线。从复现角度看，本文涉及的实验可分为两类。第一类是小模型路线实验，主要依赖用户签到序列、时间槽划分、POI 转移图和负采样策略，核心输出为候选 POI 排序分数。复现时需要保证数据按时间顺序切分，避免随机划分导致未来信息泄露；同时需要记录时间槽数量、负样本来源和随机种子，因为这些因素会影响动态图边权和最终排序。第二类是大模型路线实验，主要依赖城市/区域子集、结构化轨迹模板、GCIM 地理编码、PAM 结构嵌入注入和 LoRA 微调配置。复现时需要保证训练与推理阶段使用同一模板字段顺序，并明确 $MRR@5$ 等生成式评价口径，避免与传统全候选排序指标混用。本文主实验保持“GA-LLM 直接生成 Top-K 候选”的推理口径，不采用在线 TSPM 打分融合、候选约束解码或额外重排序。这

一点对理解实验结果很重要。文中报告的 **GA-LLM** 收益主要来自训练期的地理编码和结构对齐，而不是推理阶段的规则后处理。若后续工程系统希望进一步加入缓存、规则过滤或多模型召回，可以作为部署层优化，但不应与本文主实验结论混为一谈。**TSPM**、**GCIM** 和 **PAM** 的关系需要从任务边界、模块关系、评价口径和工程部署四个层面理解。**TSPM** 负责提供时间敏感的结构归纳偏置，**GCIM** 负责把坐标连续性注入 **LLM** 输入空间，**PAM** 负责把图结构先验映射到语义空间；三者共同服务于“在 **Next POI** 预测中实现结构先验与语义推理协同”的研究目标，而不是彼此独立的技术片段。在复现实验时，还需要特别注意数据切分与候选构造的一致性。**Next POI** 任务很容易因为随机切分、候选集合泄漏或时间戳处理不一致而产生虚高结果，因此本文采用时间顺序划分，并在小模型和大模型路线中分别说明评价口径。小模型路线更接近全候选排序，强调结构模型对真实下一点的排序能力；大模型路线更接近生成式候选输出，强调 **LLM** 在有限 **Top-K** 候选中的命中与排序质量。二者指标名称相近，但计算流程不同，因此不能把不同口径下的数值直接混为同一结论。后续研究可以继续展开若干具体方向。例如，不同时间槽数量对 **TSPM** 的影响能够进一步揭示时间粒度与样本稀疏之间的权衡，不同城市分布下 **GCIM** 的空间误差变化能够帮助分析地理编码对密集城区和广域区域的适应性，不同结构嵌入来源对 **PAM** 的影响能够说明结构先验注入是否依赖特定小模型，单阶段与两阶段训练在更多数据集上的稳定性差异则有助于评估协同训练策略的普适性。这些方向均与本文提出的研究问题直接相关，也能够继续扩展大小模型协同学习在位置推荐任务中的适用边界。

后记

三年的研究生学习即将结束，从入学时对“做科研”只有模糊认识，到今天能够较为独立地完成问题定义、方法设计、实验验证与论文写作，这一过程远比我最初想象的更漫长，也更珍贵。回顾这段经历，自己真正收获的不只是论文结果本身，更是面对复杂问题时的耐心、面对失败实验时的韧性，以及在反复修改中逐步接近严谨表达的能力。

读研初期，我花了大量时间补齐推荐系统、时空建模和大模型相关基础。很多看似“懂了”的内容，在真正动手复现和推导时又会暴露理解盲区。进入课题后，围绕 Next POI 推荐这一方向，我经历了从传统序列方法到图建模，再到大语言模型增强方案的不断尝试。期间有过实验长期不收敛、结果波动难以解释、写作结构反复推翻重来的阶段，也正是在这些具体而琐碎的困难里，我逐渐理解了研究工作的核心不是追求“看起来漂亮”的结果，而是对问题边界、方法假设和证据链条保持诚实与清醒。

本文最终形成的两条主线工作（TSPM 与 GA-LLM）并非一蹴而就，而是在多轮讨论、验证和修正中逐步沉淀出来的。前者让我更深刻地认识到时空行为中的结构规律与时间异质性；后者让我意识到大模型能力的边界，以及结构先验注入在实际任务中的必要性。无论结果大小，这些探索过程都成为我研究训练中最重要的部分。

衷心感谢导师在选题把关、方法路线、实验设计和论文写作上的持续指导。导师严谨务实的科研态度、对细节的高标准要求和对学成长耐心投入，使我在每一个关键节点都能及时校正方向、稳步推进。导师不仅教会我“怎么做研究”，也让我理解了“为什么要这样做研究”。这份影响将长期伴随我今后的学习与工作。

感谢课题组各位老师和同学在数据处理、代码复核、论文讨论中的帮助。每一次组会交流和问题争论，都在推动我把模糊想法变成可验证命题。感谢学院与学校提供的学习平台与研究条件，感谢家人和朋友在读研阶段给予的理解、支持与鼓励，使我能够专注地走完这段旅程。

谨以此文，向所有在研究生阶段给予我指导、帮助和陪伴的人致以最诚挚的感谢。