

中山大学人工智能学院

研究生学位论文

面向出行位置点预测的大小模型协同学习研究

**Collaborative Learning of Large and Small Models for Next POI Prediction in
Mobility Scenarios**

学位申请人：刘钊
专业名称：人工智能
导师姓名及职称：刘威（副教授）
学位：硕士

答辩委员会主席（签名）：_____

委员（签名）：_____

论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究作出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：

日期： 年 月 日

学位论文使用授权声明

本人完全了解中山大学有关保留、使用学位论文的规定，即：学校有权保留学位论文并向国家主管部门或其指定机构送交论文的电子版和纸质版；有权将学位论文用于非赢利目的的少量复制并允许论文进入学校图书馆、院系资料室被查阅；有权将学位论文的内容编入有关数据库进行检索；可以采用复印、缩印或其他方法保存学位论文；可以为建立了馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。

保密论文保密期满后，适用本声明。

学位论文作者签名：

导师签名：

日期： 年 月 日

日期： 年 月 日

论文题目：面向出行位置点预测的大小模型协同学习研究

专 业：人工智能

硕 士 生：刘钊

指导教师：刘威（副教授）

摘要

随着位置服务与移动互联网的发展，下一个兴趣点（Point-of-Interest, POI）预测已成为智能出行与个性化推荐的重要问题。传统序列模型和图神经网络在时空依赖建模方面表现良好，但在冷启动与数据稀疏场景中仍存在局限；大语言模型具备更强的语义理解能力，却难以直接刻画细粒度时空转移规律。针对上述问题，本文围绕“大小模型协同学习”开展研究，构建融合传统时空建模能力与大模型语义推理能力的统一框架。

本文首先基于时间偏好构建时间增强的序列动态图，对用户在不同时段的访问行为进行建模，并通过双向转移机制刻画 POI 的转入与转出偏好；随后通过多层感知器实现传统模型嵌入与大模型语义空间对齐，结合参数高效微调策略将全局时空信息注入大模型，从而提升推荐模型在短轨迹与稀疏数据场景下的鲁棒性与泛化能力。本文进一步给出面向 Gowalla 与 Foursquare 数据的实验设计与评测方案，为后续完整实验与论文写作提供可复用的研究基础。

关键词：下一个兴趣点推荐；大小模型协同；时空建模；大语言模型；参数高效微调

**Title: Collaborative Learning of Large and Small Models for
Next POI Prediction in Mobility Scenarios**

Major: Artificial Intelligence

Name: Zhao Liu

Supervisor: Wei Liu (Associate Professor)

Abstract

Next point-of-interest (POI) prediction is a key task for intelligent mobility and personalized recommendation. Traditional sequential models and graph neural networks are effective at modeling spatio-temporal dependencies, but they often suffer from cold-start and sparse-data scenarios. In contrast, large language models provide strong semantic understanding, yet they are less capable of modeling fine-grained mobility transitions directly. To address this gap, this thesis studies a collaborative learning framework between small task-specific models and large foundation models for next POI prediction.

The proposed framework first introduces a time-enhanced sequence-based dynamic graph to capture user behaviors across different time slices, together with bidirectional transition modeling for in-flow and out-flow POI preferences. Then, a multilayer perceptron is used to align embeddings from traditional POI models with the semantic space of the large model, and parameter-efficient fine-tuning is applied to inject global spatio-temporal information into the large model. This design aims to improve robustness and generalization under short trajectories and sparse observations. Finally, we present an experiment protocol on Gowalla and Foursquare as the basis for full empirical evaluation in the final thesis.

Keywords: Next POI Recommendation; Collaborative Learning; Spatio-temporal Modeling; Large Language Models; Parameter-efficient Fine-tuning

目录

摘 要	I
ABSTRACT	II
本文常用缩写对照表	VII
第一章 绪论	1
1.1 研究背景	1
1.2 问题定义与符号约定	1
1.3 推荐系统与序列建模基础	2
1.3.1 矩阵分解与隐反馈学习基础	2
1.3.2 时序与注意力建模基础	2
1.3.3 图神经网络基础	3
1.4 大语言模型引入与核心挑战	3
1.5 研究思路与技术路线	4
1.6 主要研究内容与创新点	4
1.7 论文结构安排	4
第二章 相关研究与问题分析	6
2.1 下一兴趣点推荐任务概述	6
2.2 推荐系统基础与评价指标	6
2.2.1 从静态推荐到序列推荐	6
2.2.2 典型优化目标	7
2.2.3 常用评价指标	7
2.3 小模型路线：序列与图方法	7
2.3.1 序列建模方法	7
2.3.2 图建模方法	8
2.4 大模型路线：LLM 驱动推荐	9
2.4.1 LLM 在推荐系统中的应用	9
2.4.2 LLM 在 Next POI 任务中的进展	10
2.4.3 现阶段主要瓶颈	10

2.5	研究空白与本文问题建模	10
2.6	本章小结	11
第三章	大小模型协同学习方法	12
3.1	任务定义与总体框架	12
3.2	小模型分支: TSPM	12
3.2.1	时间增强序列动态图 (TSDG)	12
3.2.2	双向转移建模	13
3.2.3	序列偏好建模与动态图权重	13
3.2.4	TiRNN 预测头	13
3.3	大模型分支: GA-LLM	14
3.3.1	问题动机	14
3.3.2	GCIM: 地理坐标注入模块	14
3.3.3	PAM: POI 对齐模块	14
3.3.4	结构化提示构造	15
3.4	融合策略: 大小模型协同训练	15
3.4.1	两阶段训练流程	15
3.4.2	推理机制	15
3.5	本章小结	15
第四章	实验设计与结果分析	16
4.1	实验目标与研究问题	16
4.2	数据集与评价指标	16
4.2.1	数据集	16
4.2.2	评价指标	16
4.3	小模型实验: TSPM 结果分析	16
4.3.1	总体对比结果	16
4.3.2	消融实验结论	17
4.4	大模型实验: GA-LLM 结果分析	17
4.4.1	核心发现	17
4.4.2	GCIM 作用分析	17
4.4.3	PAM 作用分析	18
4.4.4	效率与可扩展性	18
4.5	融合模型的综合讨论	18
4.6	实验小结	18
	结论与展望	19
	参考文献	20

Contents

Abstract (Chinese)	I
Abstract	II
List of Abbreviations	VII
Chapter 1 Introduction	1
1.1 Research Background	1
1.2 Problem Definition and Notations	1
1.3 Fundamentals of Recommender Systems and Sequential Modeling	2
1.3.1 Matrix Factorization and Implicit Feedback Learning	2
1.3.2 Temporal and Attention-based Modeling	2
1.3.3 Fundamentals of Graph Neural Networks	3
1.4 LLM Introduction and Core Challenges	3
1.5 Research Idea and Technical Route	4
1.6 Main Contributions and Innovations	4
1.7 Thesis Organization	4
Chapter 2 Related Work and Problem Analysis	6
2.1 Overview of the Next POI Recommendation Task	6
2.2 Recommender System Fundamentals and Evaluation Metrics	6
2.2.1 From Static Recommendation to Sequential Recommendation	6
2.2.2 Typical Optimization Objectives	7
2.2.3 Common Evaluation Metrics	7
2.3 Small-model Route: Sequential and Graph Methods	7
2.3.1 Sequential Modeling Methods	7
2.3.2 Graph Modeling Methods	8
2.4 Large-model Route: LLM-driven Recommendation	9
2.4.1 LLM Applications in Recommender Systems	9
2.4.2 Progress of LLMs in Next POI Recommendation	10
2.4.3 Current Major Bottlenecks	10
2.5 Research Gaps and Problem Formulation	10
2.6 Chapter Summary	11
Chapter 3 Collaborative Learning with Small and Large Models	12
3.1 Task Definition and Overall Framework	12
3.2 Small-model Branch: TSPM	12
3.2.1 Time-enhanced Sequential Dynamic Graph (TSDG)	12

3.2.2 Bidirectional Transition Modeling	13
3.2.3 Sequential Preference Modeling and Dynamic Graph Weights	13
3.2.4 TiRNN Prediction Head	13
3.3 Large-model Branch: GA-LLM	14
3.3.1 Problem Motivation	14
3.3.2 GCIM: Geographic Coordinate Injection Module	14
3.3.3 PAM: POI Alignment Module	14
3.3.4 Structured Prompt Construction	15
3.4 Fusion Strategy: Small-Large Model Collaborative Training	15
3.4.1 Two-stage Training Procedure	15
3.4.2 Inference Mechanism	15
3.5 Chapter Summary	15
Chapter 4 Experimental Design and Results Analysis	16
4.1 Experimental Objectives and Research Questions	16
4.2 Datasets and Evaluation Metrics	16
4.2.1 Datasets	16
4.2.2 Evaluation Metrics	16
4.3 Small-model Experiments: TSPM Results	16
4.3.1 Overall Comparison Results	16
4.3.2 Ablation Study Results	17
4.4 Large-model Experiments: GA-LLM Results	17
4.4.1 Key Findings	17
4.4.2 GCIM Analysis	17
4.4.3 PAM Analysis	18
4.4.4 Efficiency and Scalability	18
4.5 Comprehensive Discussion on the Fusion Model	18
4.6 Experimental Summary	18
Conclusion and Future Work	19
References	20

本文常用缩写对照表

英文缩写	英文全称	中文释义
LBSN	Location-Based Social Network	基于位置的社交网络
POI	Point of Interest	兴趣点
GNN	Graph Neural Network	图神经网络
LLM	Large Language Model	大语言模型
TSDG	Time-enhanced Sequence-based Dynamic Graph	时间增强序列动态图
MLP	Multilayer Perceptron	多层感知器
LoRA	Low-Rank Adaptation	低秩适配微调

第一章 绪论

1.1 研究背景

随着智能手机、移动互联网和位置服务平台的普及，用户在日常生活中不断产生大规模时空行为数据。以签到记录为代表的轨迹数据不仅包含“去过哪里”，还隐含“何时去、从哪里来、下一步去哪”的动态规律。这类数据为个性化推荐、出行规划、城市计算和商业选址提供了重要支撑。下一兴趣点推荐（Next Point-of-Interest Recommendation, Next POI）正是在这一背景下形成的关键任务，其目标是根据用户历史轨迹预测下一时刻最可能访问的 POI。

从应用层面看，Next POI 推荐直接服务于智慧出行、文旅推荐、生活服务平台和城市治理等场景。对于用户而言，高质量推荐可以缩短决策时间并提升体验；对于平台而言，可提升转化效率与用户粘性；对于城市管理者而言，可为交通组织、商圈活力评估和公共资源配置提供数据支持。因此，研究高精度、强鲁棒、可泛化的 Next POI 推荐方法具有显著理论意义与工程价值。

1.2 问题定义与符号约定

设用户集合为 $\mathcal{U} = \{u_1, u_2, \dots, u_M\}$ ，POI 集合为 $\mathcal{L} = \{\ell_1, \ell_2, \dots, \ell_N\}$ 。用户 u 的第 i 条签到记为

$$x_i = (u, \ell_i, t_i, g_i, c_i), \quad (1-1)$$

对应式 (1-1)，其中 ℓ_i 为 POI 标识， t_i 为时间戳， $g_i = (lat_i, lon_i)$ 为地理坐标， c_i 为类别语义。用户历史轨迹表示为

$$\mathcal{T}_u = \{x_1, x_2, \dots, x_n\}, \quad t_1 < t_2 < \dots < t_n. \quad (1-2)$$

式 (1-2) 给出时间有序的行为序列定义。

Next POI 推荐任务可表示为学习映射函数

$$f : \mathcal{T}_u \mapsto \hat{\ell}_{n+1}, \quad \hat{\ell}_{n+1} \in \mathcal{L}, \quad (1-3)$$

即在式 (1-3) 框架下，使真实下一 POI ℓ_{n+1} 在候选列表中排名尽可能靠前。若

输出 Top- K 列表，则记为 $\hat{\mathbf{y}}_u = [\hat{\ell}^{(1)}, \hat{\ell}^{(2)}, \dots, \hat{\ell}^{(K)}]$ 。

与传统静态推荐不同，Next POI 任务需同时建模：

- 1) 时间依赖：工作日/周末、早晚高峰等时段模式；
- 2) 空间依赖：邻近可达性、区域功能分布与路径连续性；
- 3) 语义依赖：POI 类别、场景语义与用户个体偏好；
- 4) 结构依赖：跨用户共享的 POI 转移图与高阶关系。

1.3 推荐系统与序列建模基础

为便于后文展开，本节简要给出本文涉及的核心建模基础。

1.3.1 矩阵分解与隐反馈学习基础

在推荐系统中，常以用户-项目交互矩阵 $\mathbf{R} \in \mathbb{R}^{M \times N}$ 建模偏好。矩阵分解方法将其近似为

$$\mathbf{R} \approx \mathbf{P}\mathbf{Q}^\top, \quad (1-4)$$

式 (1-4) 中， $\mathbf{P} \in \mathbb{R}^{M \times d}$ 为用户潜向量， $\mathbf{Q} \in \mathbb{R}^{N \times d}$ 为 POI 潜向量。对应目标函数可写为

$$\min_{\mathbf{P}, \mathbf{Q}} \sum_{(u, \ell) \in \Omega} (r_{u\ell} - \mathbf{p}_u^\top \mathbf{q}_\ell)^2 + \lambda (\|\mathbf{P}\|_F^2 + \|\mathbf{Q}\|_F^2). \quad (1-5)$$

式 (1-5) 刻画了重构误差与参数正则化的平衡。

在隐反馈场景中，常采用 BPR 排序损失：

$$\mathcal{L}_{\text{BPR}} = - \sum_{(u, i, j)} \log \sigma(\hat{y}_{u, i} - \hat{y}_{u, j}) + \lambda \|\Theta\|_2^2, \quad (1-6)$$

见式 (1-6)，其中 i 为正样本， j 为负样本。FPMC^[1] 与 PRME^[2] 均可视为这一路线在时序推荐中的代表。

1.3.2 时序与注意力建模基础

基于 RNN 的方法通过递归更新隐状态：

$$\mathbf{h}_t = \phi(\mathbf{W}_x \mathbf{x}_t + \mathbf{W}_h \mathbf{h}_{t-1} + \mathbf{b}), \quad (1-7)$$

其形式见式 (1-7)，并以 \mathbf{h}_t 预测下一项。LSTM^[3] 通过门控机制缓解长依赖梯度问题，ST-RNN^[4]、HST-LSTM^[5] 在此基础上引入时空上下文。

Transformer 注意力机制将序列表示为

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d}}\right)\mathbf{V}, \quad (1-8)$$

如式 (1-8) 所示，用于捕获长程依赖。GETNext^[6] 将轨迹流图与 Transformer 结合，显著提升了复杂迁移场景下的预测能力。

1.3.3 图神经网络基础

对于图 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ ，GNN 典型消息传递过程为

$$\mathbf{h}_v^{(l+1)} = \psi\left(\mathbf{h}_v^{(l)}, \bigoplus_{u \in \mathcal{N}(v)} \phi(\mathbf{h}_u^{(l)}, \mathbf{h}_v^{(l)}, \mathbf{e}_{uv})\right), \quad (1-9)$$

即式 (1-9)，其中 \bigoplus 表示聚合算子。基于归一化邻接矩阵的 GCN 形式可写为

$$\mathbf{H}^{(l+1)} = \sigma\left(\tilde{\mathbf{D}}^{-1/2} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-1/2} \mathbf{H}^{(l)} \mathbf{W}^{(l)}\right). \quad (1-10)$$

见式 (1-10)。

Next POI 场景中，图结构可来自 POI 转移、用户-POI 交互或超图关系。STHGCN^[7]、GraphFlashback^[8] 和 SNPM^[9] 证明了图结构对稀疏场景和跨用户迁移的显著价值。

1.4 大语言模型引入与核心挑战

LLM 在语义理解和上下文推理方面表现突出，推动了推荐系统从“结构拟合”向“语义推理 + 结构约束”转变。LLM4POI^[10] 率先将 Next POI 任务转化为提示学习与生成问题，验证了大模型在冷启动与语义泛化方面的潜力。GraphGPT^[11]、LLaRA^[12]、E4SRec^[13]、CoLLM^[14]、LLMRec^[15] 等研究进一步说明，大模型可有效吸收图结构与协同信号。

然而，LLM 直接用于 Next POI 仍面临两类关键难题：

挑战 C1：空间感知能力不足。高精度经纬度在 LLM 分词后常形成长 token 序列，既增加计算成本，又破坏地理邻近性表达。由于语义空间与地理空间缺乏天然同构，模型可能出现“语义相近但地理很远”的误判，甚至生成不合理 POI。

相关城市基础模型研究也指出，地理连续空间建模需要专门编码机制^[16,17]。

挑战 **C2**: **POI** 转移先验注入不足。纯文本提示对“轨迹中的图结构转移规律”刻画有限。当目标 **POI** 未显式出现在历史输入时，模型容易回退到高频历史点，难以恢复真实转移关系。**GeoSAN**^[18]、**ROTAN**^[19]、**MTNet**^[20] 和 **CFPRec**^[21] 表明，显式引入转移结构对提升预测稳定性至关重要。

1.5 研究思路与技术路线

为应对上述问题，本文采用“大小模型协同学习”路线：

- 1) 在小模型侧构建时间增强序列动态图与双向转移建模，学习高质量时空表示；
- 2) 在大模型侧构建地理坐标注入模块与 **POI** 对齐模块，将空间连续性与转移先验注入 LLM；
- 3) 通过两阶段训练与参数高效微调，实现结构知识与语义知识协同优化。

该路线并非简单模型拼接，而是“结构归纳偏置”与“语义生成能力”的互补融合：小模型提供稳定时空先验，大模型提供语义泛化与上下文推理能力，共同提升准确率、鲁棒性与可迁移性。

1.6 主要研究内容与创新点

围绕上述技术路线，本文工作可归纳为以下三点：

- 1) 提出面向 Next **POI** 任务的大小模型协同框架，统一时空结构建模与语义推理；
- 2) 提出时间槽偏好与双向转移建模机制，提升小模型对复杂出行规律的表达能力；
- 3) 设计地理坐标注入与 **POI** 对齐机制，缓解 LLM 空间幻觉并增强跨城冷启动泛化。

1.7 论文结构安排

全文共五章，具体安排如下：

- 1) 第 1 章为绪论，介绍研究背景、问题定义、核心挑战与研究路线；
- 2) 第 2 章为相关研究与问题分析，系统梳理小模型与大模型方法并明确研究空白；

- 3) 第 3 章为方法章，详细介绍小模型分支、大模型分支及协同训练机制；
- 4) 第 4 章为实验章，从总体性能、消融、鲁棒性与效率角度验证方法有效性；
- 5) 第 5 章为结论与展望，总结工作贡献并讨论未来研究方向。

第二章 相关研究与问题分析

2.1 下一兴趣点推荐任务概述

下一兴趣点推荐 (Next Point-of-Interest Recommendation, Next POI) 任务通常定义为：给定用户历史签到序列，预测其下一时刻最可能访问的 POI。该任务本质上同时依赖三类信息：

- 1) 序列依赖：近期访问行为对下一跳具有强约束；
- 2) 空间依赖：地理邻近性与城市功能分区影响候选分布；
- 3) 语义依赖：POI 类别、时间上下文与用户意图决定可达性与偏好。

经典工作将该问题视为序列建模任务，Where You Like to Go Next^[22] 和 Latent Behavior Patterns^[23] 具有代表性。后续研究逐渐扩展到时空序列深度网络与图结构建模框架，例如 HST-LSTM^[5]、LSTPM^[24]、STAN^[25]、GETNext^[6]、STHGCN^[7] 和 GraphFlashback^[8]。此外，随着城市计算与地理建模发展，学界开始关注多尺度区域结构、跨模态语义特征与地理知识融合，代表工作包括 TSPN-RA^[26]、M3PA^[27] 和 City Foundation Models^[16]。

2.2 推荐系统基础与评价指标

2.2.1 从静态推荐到序列推荐

传统推荐系统通常学习用户 u 与项目 i 的偏好函数 $\hat{y}_{ui} = f(u, i)$ 。在 POI 场景中，项目集合对应地点集合 \mathcal{L} ，而用户状态还受历史轨迹影响，因此预测函数应写为

$$\hat{y}_{u,t,i} = f(u, \mathcal{T}_{u,1:t-1}, i), \quad (2-1)$$

如式 (2-1) 所示，其中 $\mathcal{T}_{u,1:t-1}$ 表示截至时刻 $t-1$ 的签到序列。与静态推荐相比，Next POI 推荐更强调条件分布 $p(\ell_t | \ell_{1:t-1}, u, \text{context})$ 的建模。

2.2.2 典型优化目标

点式学习 (point-wise) 常以交叉熵最小化为目标:

$$\mathcal{L}_{\text{CE}} = - \sum_{(u,t)} \log p(\ell_t \mid \ell_{1:t-1}, u). \quad (2-2)$$

式 (2-2) 对应概率分类目标。对式学习 (pair-wise) 常采用 BPR^[1]:

$$\mathcal{L}_{\text{BPR}} = - \sum_{(u,i,j)} \log \sigma(\hat{y}_{u,i} - \hat{y}_{u,j}) + \lambda \|\Theta\|_2^2, \quad (2-3)$$

见式 (2-3), 其中 i 为真实下一 POI, j 为负采样 POI。PRME^[2] 进一步将排序学习与度量空间结合, 在新地点推荐中具有较强表现。

2.2.3 常用评价指标

为衡量排序质量, 本文后续采用 Accuracy@K、MRR 和 NDCG@K:

$$\text{Acc@K} = \frac{1}{|\mathcal{D}|} \sum_{n=1}^{|\mathcal{D}|} \mathbf{1}(r_n \leq K), \quad (2-4)$$

$$\text{MRR} = \frac{1}{|\mathcal{D}|} \sum_{n=1}^{|\mathcal{D}|} \frac{1}{r_n}, \quad (2-5)$$

$$\text{NDCG@K} = \frac{1}{|\mathcal{D}|} \sum_{n=1}^{|\mathcal{D}|} \frac{\mathbf{1}(r_n \leq K)}{\log_2(r_n + 1)}, \quad (2-6)$$

三项指标分别由式 (2-4)、式 (2-5) 和式 (2-6) 定义, 其中 r_n 为第 n 个样本中真实 POI 的排名。Acc@K 反映命中能力, MRR 强调首个正确结果的位置, NDCG@K 则更关注头部排序质量。

2.3 小模型路线: 序列与图方法

2.3.1 序列建模方法

早期方法以马尔可夫链与矩阵分解为主, 代表模型 FPMC^[1] 与 PRME^[2] 强调“用户偏好 + 转移模式”的联合建模。深度学习阶段中, RNN/LSTM 成为主流, ST-RNN^[4] 显式引入时空上下文, HST-LSTM^[5] 在层级结构中建模短期与长期

偏好，LSTPM^[24] 通过非局部操作增强长依赖建模，STAN^[25] 进一步结合时空注意力提高表达能力。近年来，针对长期兴趣漂移、频率偏置与行为稀疏问题，CLSPRec^[28] 与 FHCRec^[29] 采用对比学习强化表征鲁棒性。

在数学形式上，序列方法一般遵循以下状态更新：

$$\mathbf{h}_t = \Phi(\mathbf{x}_t, \mathbf{h}_{t-1}; \Theta), \quad (2-7)$$

其形式见式 (2-7)，其中 \mathbf{x}_t 是当前 POI 及上下文嵌入， Φ 可实例化为 RNN 或 LSTM 单元。若引入注意力机制，常写为

$$\alpha_{t,k} = \frac{\exp(\mathbf{q}_t^\top \mathbf{k}_k)}{\sum_{j=1}^{t-1} \exp(\mathbf{q}_t^\top \mathbf{k}_j)}, \quad \mathbf{c}_t = \sum_{k=1}^{t-1} \alpha_{t,k} \mathbf{v}_k. \quad (2-8)$$

如式 (2-8) 所示。最终预测分布通常由

$$p(\ell_{t+1} \mid \mathcal{T}_{u,1:t}) = \text{Softmax}(\mathbf{W}_o[\mathbf{h}_t \parallel \mathbf{c}_t] + \mathbf{b}_o) \quad (2-9)$$

给出，对应式 (2-9)。该范式能够刻画短期转移，但当轨迹跨度增长、空间约束增强时，单序列编码难以充分表达跨用户共享结构。

序列方法在中短序列预测上表现稳定，但普遍存在以下不足：

- 1) 在稀疏轨迹和冷启动场景下，参数学习依赖充足监督信号；
- 2) 对“时间段差异”与“转入/转出双向偏好”刻画不充分；
- 3) 对跨用户高阶关系利用有限，难以吸收群体迁移知识。

2.3.2 图建模方法

图神经网络通过构建 POI 转移图、用户-POI 二部图、超图或动态图显式学习高阶关系。代表方法包括 GETNext^[6]、GraphFlashback^[8]、STHGCN^[7]、SNPM^[9]、AGCL^[30] 与 DCPR^[31]。这类方法可跨用户传播结构信息，在稀疏场景中显著提升表示质量。为增强时间建模能力，ROTAN^[19] 引入旋转时序注意力，MTNet^[20] 采用 mobility tree 学习时间槽偏好。

图模型的核心可抽象为消息传递：

$$\mathbf{h}_i^{(l+1)} = \sigma \left(\mathbf{w}_0^{(l)} \mathbf{h}_i^{(l)} + \sum_{j \in \mathcal{N}(i)} \beta_{ij}^{(l)} \mathbf{w}_1^{(l)} \mathbf{h}_j^{(l)} \right), \quad (2-10)$$

其形式见式 (2-10)，其中 $\beta_{ij}^{(l)}$ 为归一化邻接权重或注意力权重。若考虑时空边特征 $\mathbf{e}_{ij} = [\Delta t_{ij}, d_{ij}]$ ，可进一步写为

$$\beta_{ij}^{(l)} \propto \exp(\text{MLP}([\mathbf{h}_i^{(l)} \parallel \mathbf{h}_j^{(l)} \parallel \mathbf{e}_{ij}])). \quad (2-11)$$

如式 (2-11) 所示。这使模型同时编码“谁与谁相连”与“何时、隔多远发生转移”。

在 POI 任务中，动态图通常记为 $\mathcal{G}_t = (\mathcal{V}, \mathcal{E}_t)$ ，并基于滑动窗口更新边集：

$$\mathcal{E}_t = \{(\ell_k, \ell_{k+1}) \mid t - k \leq w\}. \quad (2-12)$$

式 (2-12) 刻画了局部时间窗内的转移更新规则。该建模可反映近期行为变化，但随时间推移会带来图更新成本上升、训练不稳定和邻居爆炸问题。

图方法尽管性能强，但仍面临以下挑战：

- 1) 图结构通常静态，难以反映不同时间段转移动态；
- 2) 多源异构信息（文本语义、类别语义、空间连续坐标）融合成本高。

2.4 大模型路线：LLM 驱动推荐

2.4.1 LLM 在推荐系统中的应用

在通用推荐领域，研究者已探索将 LLM 与协同信号、检索机制和图结构结合。CoLLM^[14] 将协同嵌入注入语言模型语义空间；CoRAL^[32] 通过检索增强改善长尾推荐；LLMRec^[15] 采用图增强提升结构感知；ReLLa^[33] 面向长历史行为引入检索式记忆。面向序列推荐，SeCor^[34] 与 LLaRA^[12] 分别从语义-协同对齐和助理式推理角度验证了 LLM 在行为建模中的潜力。

若将推荐任务表述为条件生成，LLM 目标可写为

$$\max_{\Theta} \sum_{(x,y)} \log p_{\Theta}(y \mid x), \quad (2-13)$$

见式 (2-13)，其中 x 是由用户历史、候选集合和外部上下文构成的提示词， y 为下一 POI 或其标识。参数高效微调常采用 LoRA 形式

$$\Delta \mathbf{W} = \mathbf{B} \mathbf{A}, \quad \mathbf{W}' = \mathbf{W} + \Delta \mathbf{W}, \quad (2-14)$$

对应式 (2-14)，在保持主干参数冻结的前提下降低训练成本。

2.4.2 LLM 在 Next POI 任务中的进展

在 Next POI 方向，LLM4POI^[10] 通过轨迹提示将任务转化为生成问题，展现了冷启动潜力。GraphGPT^[11] 与 E4SRec^[13] 虽非专门针对 POI 场景，但其“结构指令化”和“高效序列适配”思路对 POI 任务有重要启发。GA-LLM^[35] 进一步指出文本 LLM 存在空间幻觉、长距离误判与目标 POI 缺失时泛化不足问题，并提出地理坐标注入模块与 POI 对齐模块缓解缺陷。

针对空间信息编码，一个关键思想是将连续坐标 $g = (lat, lon)$ 映射到离散地理单元 $q = \text{Quadkey}(g, z)$ ，再学习嵌入

$$\mathbf{e}_g = \text{Emb}(q) + \text{PE}_{\text{geo}}(g). \quad (2-15)$$

对应式 (2-15)。其中 PE_{geo} 可采用可学习傅里叶特征，形式为

$$\text{PE}_{\text{geo}}(g) = [\sin(2\pi \mathbf{B}g), \cos(2\pi \mathbf{B}g)]. \quad (2-16)$$

如式 (2-16) 所示。该方案能缓解高精度坐标分词导致的序列膨胀问题，并增强空间邻近可分性。

2.4.3 现阶段主要瓶颈

综合现有 LLM-POI 研究，仍有三类关键瓶颈：

- 1) 坐标稀疏语义问题：经纬度被分词后难以保持几何邻近关系；
- 2) 转移先验缺失问题：纯文本 LLM 难以隐式恢复 POI 图转移规律；
- 3) 空间幻觉问题：可能生成地理上不合理或超出合理活动范围的候选。

2.5 研究空白与本文问题建模

综合上述文献，当前研究的关键矛盾可归纳为：

- 1) 小模型时空结构建模强，但语义泛化能力不足；
- 2) 大模型语义理解强，但地理连续性与转移结构建模弱。

由此产生本文的核心研究问题：如何在统一框架中同时保持小模型对时空转移的精细刻画能力，以及大模型对异构语义的泛化推理能力，并在实际可部署约束下实现性能与效率平衡。

为解决该问题，本文采用“小模型增强时空结构 + 大模型增强语义推理 + 融合对齐训练”的技术路线：

- 1) 在小模型侧构建时间增强序列动态图与双向转移建模，学习高质量时空表示；
- 2) 在大模型侧引入地理坐标注入模块（GCIM）与 POI 对齐模块（PAM），增强空间一致性与转移先验；
- 3) 通过嵌入对齐与两阶段训练，将小模型知识稳定注入 LLM，实现协同优化。

上述融合框架可形式化为联合优化问题：

$$\mathcal{L} = \mathcal{L}_{\text{small}} + \lambda_1 \mathcal{L}_{\text{align}} + \lambda_2 \mathcal{L}_{\text{llm}} + \lambda_3 \mathcal{L}_{\text{reg}}, \quad (2-17)$$

即式 (2-17)，其中 $\mathcal{L}_{\text{small}}$ 学习时空结构先验， $\mathcal{L}_{\text{align}}$ 约束小模型与 LLM 语义空间对齐， \mathcal{L}_{llm} 对应生成或分类目标， \mathcal{L}_{reg} 控制参数复杂度。该路线既保留了小模型对局部时空依赖的刻画能力，又利用了 LLM 的上下文语义推理优势，并通过结构化注入与参数高效微调降低工程成本，更适合真实出行场景下的可部署需求。

2.6 本章小结

本章围绕“方法演进脉络与现实瓶颈”对 Next POI 研究进行了系统梳理。整体来看，FPMC^[1]、PRME^[2] 所代表的早期范式在可解释性和训练稳定性方面具有优势，但对复杂时空上下文的表达能力有限；ST-RNN^[4]、HST-LSTM^[5]、STAN^[25] 所代表的序列深度模型显著提升了时序建模能力，但对跨用户高阶迁移知识利用不足；GETNext^[6]、SNPM^[9]、GraphFlashback^[8] 所代表的图方法在结构关系学习上更具优势，但在动态更新和异构融合方面存在工程复杂度偏高的问题。

在大模型方向，LLM4POI^[10]、LLaRA^[12]、SeCor^[34]、CoLLM^[14] 展现了语义泛化与冷启动潜力，但空间连续性建模和转移先验注入仍是核心短板。GA-LLM^[35] 提供了具有针对性的改进思路，说明“地理编码增强 + 结构先验对齐”是提升 LLM 在时空推荐任务中可靠性的关键路径。

基于以上分析，本文后续章节将以“结构先验与语义推理协同优化”为主线，分别从小模型分支的时间增强动态图建模、大模型分支的地理坐标注入与 POI 对齐机制、以及端到端协同训练策略三个维度展开，目标是在准确率、鲁棒性与部署效率之间实现更优平衡。

第三章 大小模型协同学习方法

3.1 任务定义与总体框架

设用户集合为 \mathcal{U} ，POI 集合为 \mathcal{L} 。用户 $u \in \mathcal{U}$ 的签到序列记为

$$\mathcal{T}_u = \{(p_1, t_1, g_1, c_1), \dots, (p_n, t_n, g_n, c_n)\},$$

其中 p_i 为 POI ID， t_i 为时间戳， $g_i = (lat_i, lon_i)$ 为经纬度， c_i 为类别。目标是学习函数

$$\hat{p}_{n+1} = f(\mathcal{T}_u), \quad \hat{p}_{n+1} \in \mathcal{L},$$

使真实下一 POI 在候选排序中尽可能靠前。

本文框架由三部分组成：

- 1) 小模型分支：TSPM (Time-enhanced Sequential Prediction Model)；
- 2) 大模型分支：GA-LLM (Geography-Aware LLM)；
- 3) 融合分支：嵌入对齐与两阶段协同训练。

3.2 小模型分支：TSPM

3.2.1 时间增强序列动态图 (TSDG)

传统连续序列默认不同时间段共享同一转移机制，难以刻画“早高峰通勤”与“夜间娱乐”行为差异。为此，将一天划分为 z 个时间槽 $\{T_1, \dots, T_z\}$ ，在每个时间槽内构建 POI 转移子图。对当前 POI 嵌入 \mathbf{e}_i 与时间槽嵌入 \mathbf{t}_i ，定义时间感知的转出向量：

$$\boldsymbol{\xi}_{i,T_i}^{out} = \sigma([\mathbf{e}_i \parallel \mathbf{t}_i] \mathbf{W}_{out}^t + \mathbf{b}_{out}^t),$$

对应地定义转入向量：

$$\boldsymbol{\xi}_{j,T_i}^{in} = \sigma([\mathbf{e}_j \parallel \mathbf{t}_i] \mathbf{W}_{in}^t + \mathbf{b}_{in}^t).$$

3.2.2 双向转移建模

为同时建模“从哪里来”和“将去哪里”，采用双向对比损失：

$$\mathcal{L}_{time} = - \sum_t \log \sigma \left(\|\boldsymbol{\xi}_{i,T}^{out} - \boldsymbol{\xi}_{-,T}^{in}\|_2^2 - \|\boldsymbol{\xi}_{i,T}^{out} - \boldsymbol{\xi}_{+,T}^{in}\|_2^2 \right),$$

其中 + 与 - 分别表示正负样本 POI。该损失鼓励当前 POI 在给定时间槽下更接近真实下一跳的转入表示。

3.2.3 序列偏好建模与动态图权重

将最近 k 个访问拼接后得到序列表示：

$$\boldsymbol{\xi}_{seq} = \sigma \left([\mathbf{e}_t \| \mathbf{e}_{t-1} \| \cdots \| \mathbf{e}_{t-k}] \mathbf{W}^s + \mathbf{b}^s \right).$$

对应序列对比损失为：

$$\mathcal{L}_{seq} = - \sum_t \log \sigma \left(\|\boldsymbol{\xi}_{seq} - \mathbf{e}_t^-\|_2^2 - \|\boldsymbol{\xi}_{seq} - \mathbf{e}_{t+1}^+\|_2^2 \right).$$

综合损失：

$$\mathcal{L}_{TSPM} = \alpha \mathcal{L}_{time} + \beta \mathcal{L}_{seq}.$$

学习完成后，定义动态边权：

$$s_{i,j}^d = \exp \left(-\rho_1 \|\boldsymbol{\xi}_{seq} - \mathbf{e}_j\|_2^2 - \rho_2 \|\boldsymbol{\xi}_{i,T}^{out} - \boldsymbol{\xi}_{j,T}^{in}\|_2^2 \right),$$

并据此构建时间增强动态图进行邻域聚合。

3.2.4 TiRNN 预测头

为显式建模多步历史影响，TiRNN 将过去 K 个隐状态加权融合：

$$\mathbf{c}_t = \sum_{k=1}^K \alpha_k (\mathbf{h}_{t-k} \circ \mathbf{r}_k),$$

$$\mathbf{h}_t = \sigma(\kappa \mathbf{v}_t + \mathbf{c}_t), \quad \hat{\mathbf{y}}_t = \text{Softmax}(\mathbf{W}_f [\hat{\mathbf{h}}_t \| \mathbf{E}_u]).$$

训练目标采用交叉熵与 L_2 正则。

3.3 大模型分支：GA-LLM

3.3.1 问题动机

基于 LLM 的 POI 推荐虽具语义优势，但存在“空间连续性缺失”和“转移先验不足”两类核心问题：

- 1) 经纬度离散分词后，近邻点可能映射到语义距离较远的 token 空间；
- 2) 仅依赖文本提示时，模型倾向重复历史出现 POI，难以推断未显式出现但转移概率高的目标 POI。

3.3.2 GCIM：地理坐标注入模块

GCIM 由双分支组成：

- 1) 层级离散分支 (Quadkey n-gram)：编码多尺度地理网格结构；
- 2) 连续频域分支 (Fourier)：编码平滑地理距离变化。

连续频域分支写作：

$$\mathbf{E}_{fourier} = \frac{1}{\sqrt{M}} [\cos(\mathbf{g}\mathbf{W}_s^T) \parallel \sin(\mathbf{g}\mathbf{W}_s^T)],$$

其中 $\mathbf{g} = (lat, lon)$ 。双分支融合后通过投影映射至 LLM 语义空间：

$$\mathbf{E}_{GPS} = \mathbf{W}_{GPS}[\mathbf{E}_{quad} \parallel \mathbf{E}_{fourier}].$$

为保持语义空间中的地理一致性，引入测地一致性损失，约束嵌入距离与真实地理距离单调一致，从而降低空间幻觉预测。

3.3.3 PAM：POI 对齐模块

PAM 将图模型产生的低维 POI 向量 $\mathbf{e}_{poi} \in \mathbb{R}^d$ 投影至 LLM 空间：

$$\mathbf{E}_{poi} = \text{PAM}(\mathbf{e}_{poi}) = \mathbf{W}_p \mathbf{e}_{poi} + \mathbf{b}_p.$$

与仅将 POI 当作独立 token 的策略不同，PAM 显式引入跨 POI 转移先验，使模型能在目标 POI 未出现在输入历史时仍基于结构化关系完成预测。

3.3.4 结构化提示构造

采用“轨迹文本 + 专用 token”混合提示：

This is the historical trajectory of user u : ... $\langle \text{POI } p_i \rangle, \langle \text{GPS } g_i \rangle$... Which
POI will user u visit next?

其中 ‘ $\langle \text{GPS} \rangle$ ’ 由 GCIM 编码，‘ $\langle \text{POI} \rangle$ ’ 由 PAM 编码。该策略在不显著增加上下文长度的前提下注入关键地理与转移信息。

3.4 融合策略：大小模型协同训练

3.4.1 两阶段训练流程

阶段一（对齐阶段）：冻结 LLM 主体，仅训练 GCIM/PAM 与跨模型映射层，获得稳定空间与 POI 对齐表征。阶段二（协同阶段）：采用 LoRA 微调 LLM 注意力层，联合优化序列目标与生成目标。

总目标可写为：

$$\mathcal{L}_{total} = \lambda_1 \mathcal{L}_{gen} + \lambda_2 \mathcal{L}_{geo} + \lambda_3 \mathcal{L}_{align} + \lambda_4 \mathcal{L}_{TSPM}.$$

其中 \mathcal{L}_{gen} 为自回归生成损失， \mathcal{L}_{geo} 为地理一致性损失， \mathcal{L}_{align} 为 POI 语义对齐损失。

3.4.2 推理机制

推理时，将用户近期轨迹编码为结构化提示，GCIM 与 PAM 分别注入地理与转移信息，LLM 输出候选 POI 分布；同时可利用小模型输出进行重排序，得到最终 Top- K 推荐列表。

3.5 本章小结

本章构建了从“小模型时空建模”到“大模型语义增强”再到“统一协同训练”的完整方法体系。该体系针对 POI 推荐中的时间异质性、空间连续性与转移先验三类核心难题给出统一解决方案，为下一章实验验证奠定基础。

第四章 实验设计与结果分析

4.1 实验目标与研究问题

围绕提出的协同框架，本文设计以下研究问题：

- 1) RQ1：相比主流序列/图/LLM 基线，本文方法是否稳定提升推荐性能？
- 2) RQ2：时间增强、双向转移、GCIM、PAM 等关键模块是否均有独立贡献？
- 3) RQ3：在冷启动与跨城迁移场景中，方法是否仍具有鲁棒性？

4.2 数据集与评价指标

4.2.1 数据集

与前期工作一致，实验采用 Gowalla 与 Foursquare 用于小模型验证；采用 NYC、TKY、CA 用于 LLM 路线与跨城泛化分析。各数据集均包含用户 ID、POI ID、时间戳、经纬度与类别信息。

4.2.2 评价指标

采用准确率与排序质量指标：Acc@1、Acc@5、Acc@10、MRR（或 MRR@5）。记第 i 个样本中真实 POI 排名为 $rank_i$ ，则

$$\text{Acc}@k = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(rank_i \leq k), \quad \text{MRR} = \frac{1}{N} \sum_{i=1}^N \frac{1}{rank_i}.$$

4.3 小模型实验：TSPM 结果分析

4.3.1 总体对比结果

表 4-1 给出了你前期小模型稿件中的核心结果。TSPM 在 Gowalla 与 Foursquare 上均达到最优，说明“时间槽偏好 + 双向转移 + 动态图”对下一 POI 预测有稳定增益。

表 4-1 TSPM 与基线在 Gowalla/Foursquare 上的结果（来自前期工作）

方法	Gowalla				Foursquare			
	Acc@1	Acc@5	Acc@10	MRR	Acc@1	Acc@5	Acc@10	MRR
PRME	0.0740	0.2146	0.2899	0.1503	0.0982	0.3167	0.4064	0.2040
STRNN	0.0900	0.2120	0.2730	0.1508	0.2290	0.4310	0.5050	0.3248
DeepMove	0.0625	0.1304	0.1594	0.0982	0.2400	0.4319	0.4742	0.3270
LBSN2Vec	0.0864	0.1186	0.1390	0.1032	0.2190	0.3955	0.4621	0.2781
STGN	0.0624	0.1586	0.2104	0.1125	0.2094	0.4734	0.5470	0.3283
LightGCN	0.0428	0.1439	0.2115	0.1224	0.0540	0.1790	0.2710	0.1574
Flashback	0.1158	0.2754	0.3479	0.1925	0.2496	0.5399	0.6236	0.3805
STAN	0.0891	0.2096	0.2763	0.1523	0.2265	0.4515	0.5310	0.3420
GETNext	0.1419	0.3270	0.4081	0.2294	0.2646	0.5640	0.6431	0.3988
Graph-Flashback	0.1512	0.3425	0.4256	0.2422	0.2805	0.5757	0.6514	0.4136
TSPM	0.1595	0.3520	0.4350	0.2509	0.2932	0.5978	0.6768	0.4301

4.3.2 消融实验结论

在小模型稿件中，去除 TSDG 或去除双向转移建模（BTM）均会造成性能下降，验证了：

- 1) 时间槽建模能够显著缓解“同一 POI 在不同时段行为模式不同”的问题；
- 2) 转入/转出双向偏好比单向转移更能刻画真实出行路径。

4.4 大模型实验：GA-LLM 结果分析

4.4.1 核心发现

依据 ICDE 二轮稿与修订说明，GA-LLM 通过 GCIM 和 PAM 在三个方面取得改进：

- 1) 精度提升：相对 LLM4POI 与多种基线，在 Acc@1/Acc@5/MRR@5 上取得明显优势（文中报告最高可达 24.10% 相对提升）；
- 2) 空间幻觉缓解：错误预测与真实 POI 的平均地理距离显著下降，说明 GCIM 有效约束了地理不合理生成；
- 3) 跨城冷启动增强：在训练城市与测试城市不一致时，GA-LLM 仍优于文本 LLM 基线，显示更强可迁移性。

4.4.2 GCIM 作用分析

GCIM 的贡献可概括为“离散层级结构 + 连续频域结构 + 地理一致性约束”三者协同：

- 1) Quadkey 层级编码保留区域-子区域多尺度信息；

- 2) Fourier 连续映射补足平滑空间变化；
- 3) 测地约束将真实地理距离引入表示学习，减少语义空间扭曲。

4.4.3 PAM 作用分析

PAM 将图模型 POI 表示映射到 LLM 语义空间，在目标 POI 未显式出现在输入历史时仍可通过转移先验进行推断。对比“仅 token 学习 POI”的策略，PAM 在复杂城市分布下更稳定。

4.4.4 效率与可扩展性

GA-LLM 采用结构化坐标注入而非原始长文本坐标描述，减少了上下文冗余；同时 LoRA 微调降低了训练参数开销，具有较好的工程可部署性。

4.5 融合模型的综合讨论

将小模型与大模型能力融合后，模型具备如下互补机制：

- 1) 小模型提供可解释时空结构先验（时间槽、转移图、双向偏好）；
- 2) 大模型提供强语义建模与跨场景泛化能力；
- 3) 对齐模块将二者映射到统一语义空间，缓解结构信息在生成模型中的丢失。

从误差类型看，融合模型可同时降低两类错误：

- 1) 由文本语义偏置导致的“空间远跳错误”；
- 2) 由局部历史过拟合导致的“重复历史 POI 错误”。

4.6 实验小结

本章实验表明：

- 1) 在小模型路线中，TSPM 通过时间增强与双向转移显著提升基础预测能力；
- 2) 在大模型路线中，GA-LLM 通过 GCIM/PAM 显著提升空间一致性与冷启动鲁棒性；
- 3) 二者融合后能够在精度、鲁棒性和可解释性之间取得更优平衡。

结论与展望

结论

本文围绕“面向出行位置点预测的大小模型协同学习”展开研究，形成了较完整的论文方案：一是基于时间增强序列动态图与双向转移建模，强化传统模型对时空依赖的刻画；二是通过 MLP 对齐与 LoRA 微调，将传统模型全局信息注入 LLM，提升稀疏场景下的推荐鲁棒性。当前已完成论文结构重构、方法描述与实验方案设计，为后续实证结果补充和终稿撰写打下基础。

展望

后续工作将重点推进三个方向：

- 1) 完成大规模实验与统计显著性检验，形成可复现结果；
- 2) 探索多模态上下文信息（如地理文本描述）对推荐效果的增益；
- 3) 研究协同框架在跨城市、跨平台迁移场景中的泛化能力。

参考文献

- [1] RENDLE S, FREUDENTHALER C, SCHMIDT-THIEME L. Factorizing personalized markov chains for next-basket recommendation[C]//WWW. 2010: 811-820.
- [2] FENG S, LI X, ZENG Y, et al. Personalized ranking metric embedding for next new poi recommendation[C]//IJCAI. 2015: 2069-2075.
- [3] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [4] LIU Q, WU S, WANG L, et al. Predicting the next location: A recurrent model with spatial and temporal contexts[C]//AAAI. 2016: 194-200.
- [5] KONG D, WU F. Hst-lstm: A hierarchical spatial-temporal long-short term memory network for location prediction[C]//IJCAI. 2018: 2341-2347.
- [6] YANG S, LIU J, ZHAO K. Getnext: Trajectory flow map enhanced transformer for next poi recommendation[C]//SIGIR. 2022: 1144-1153.
- [7] YAN X, SONG T, JIAO Y, et al. Spatio-temporal hypergraph learning for next poi recommendation[C]//SIGIR. 2023: 403-412.
- [8] RAO X, CHEN L, LIU Y, et al. Graph-flashback network for next location recommendation [C]//KDD. 2022: 1463-1471.
- [9] YIN F, LIU Y, SHEN Z, et al. Next poi recommendation with dynamic graph and explicit dependency[C]//AAAI. 2023: 4827-4834.
- [10] LI P, DE RIJKE M, XUE H, et al. Large language models for next point-of-interest recommendation[C]//SIGIR. 2024: 1463-1472.
- [11] TANG J, YANG Y, WEI W, et al. Graphgpt: Graph instruction tuning for large language models[C]//SIGIR. 2024: 491-500.
- [12] LIAO J, LI S, YANG Z, et al. Llara: Large language-recommendation assistant[C]//SIGIR. 2024: 1785-1795.
- [13] LI X, CHEN C, ZHAO X, et al. E4srec: An elegant effective efficient extensible solution of large language models for sequential recommendation[A]. 2023.
- [14] ZHANG Y, FENG F, ZHANG J, et al. Collm: Integrating collaborative embeddings into large language models for recommendation[A]. 2023.
- [15] WEI W, REN X, TANG J, et al. Llmrec: Large language models with graph augmentation for recommendation[C]//WSDM. 2024: 806-815.
- [16] BALSEBRE P, HUANG W, CONG G, et al. City foundation models for learning general purpose representations from openstreetmap[C]//CIKM. 2024: 87-97.
- [17] ROBERTS J, LUEDDECKE T, DAS S, et al. Gpt4geo: How a language model sees the world's

- geography[A]. 2023.
- [18] LIAN D, WU Y, GE Y, et al. Geography-aware sequential location recommendation[C]//KDD. 2020: 2009-2019.
 - [19] FENG S, MENG F, CHEN L, et al. Rotan: A rotation-based temporal attention network for time-specific next poi recommendation[C]//KDD. 2024: 759-770.
 - [20] HUANG T, PAN X, CAI X, et al. Learning time slot preferences via mobility tree for next poi recommendation[C]//AAAI. 2024: 8535-8543.
 - [21] ZHANG L, SUN Z, WU Z, et al. Next point-of-interest recommendation with inferring multi-step future preferences[C]//IJCAI. 2022: 3751-3757.
 - [22] CHENG C, YANG H, LYU M R, et al. Where you like to go next: Successive point-of-interest recommendation[C]//IJCAI. 2013: 2605-2611.
 - [23] HE J, LI X, LIAO L, et al. Inferring a personalized next point-of-interest recommendation model with latent behavior patterns[C]//AAAI. 2016: 137-143.
 - [24] SUN K, QIAN T, CHEN T, et al. Where to go next: Modeling long- and short-term user preferences for point-of-interest recommendation[C]//AAAI. 2020: 214-221.
 - [25] LUO Y, LIU Q, LIU Z. Stan: Spatio-temporal attention network for next location recommendation[C]//WWW. 2021: 2177-2185.
 - [26] JIANG N, YUAN H, SI J, et al. Towards effective next poi prediction: Spatial and semantic augmentation with remote sensing data[C]//ICDE. 2024: 5061-5074.
 - [27] ZHANG D, CHEN M, HUANG W, et al. Exploring urban semantics: A multimodal model for poi semantic annotation with street view images and place names[C]//IJCAI. 2024: 2533-2541.
 - [28] DUAN C, FAN W, ZHOU W, et al. Clsprec: Contrastive learning of long and short-term preferences for next poi recommendation[C]//CIKM. 2023: 473-482.
 - [29] CHEN J, SANG Y, ZHANG P F, et al. Enhancing long-and short-term representations for next poi recommendations via frequency and hierarchical contrastive learning[C]//AAAI. 2025: 11472-11480.
 - [30] RAO X, JIANG R, SHANG S, et al. Next point-of-interest recommendation with adaptive graph contrastive learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2025, 37(3): 1366-1379.
 - [31] LONG J, YE G, CHEN T, et al. Diffusion-based cloud-edge-device collaborative learning for next poi recommendations[C]//KDD. 2024: 2026-2036.
 - [32] WU J, CHANG C C, YU T, et al. Coral: Collaborative retrieval-augmented large language models improve long-tail recommendation[C]//KDD. 2024: 3391-3401.
 - [33] LIN J, SHAN R, ZHU C, et al. Rella: Retrieval-enhanced large language models for lifelong sequential behavior comprehension in recommendation[C]//WWW. 2024: 3497-3508.
 - [34] WANG S, XIE B, DING L, et al. Secor: Aligning semantic and collaborative representations

- by large language models for next-poi recommendations[C]//RecSys. 2024: 1-11.
- [35] LIU Z, XIE M, LIU W, et al. Geography-aware large language models for next poi recommendation[J]. IEEE ICDE 2026 (second-round submission), 2026.