

中山大学人工智能学院
研究生学位论文

面向出行位置点预测的大小模型协同学习研究

Collaborative Learning of Large and Small Models for Next POI Prediction in
Mobility Scenarios

学 位 申 请 人： 刘钊

专 业 名 称： 人工智能

导 师 姓 名 及 职 称： 刘威（副教授）

答辩委员会主席（签名）： _____

委员（签名）： _____

论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究作出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：

日期： 年 月 日

学位论文使用授权声明

本人完全了解中山大学有关保留、使用学位论文的规定，即：学校有权保留学位论文并向国家主管部门或其指定机构送交论文的电子版和纸质版；有权将学位论文用于非赢利目的的少量复制并允许论文进入学校图书馆、院系资料室被查阅；有权将学位论文的内容编入有关数据库进行检索；可以采用复印、缩印或其他方法保存学位论文；可以为建立了馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。

保密论文保密期满后，适用本声明。

学位论文作者签名：

导师签名：

日期： 年 月 日

日期： 年 月 日

论文题目：面向出行位置点预测的大小模型协同学习研究

专 业：人工智能

硕 士 生：刘钊

指导教师：刘威（副教授）

摘要

随着位置服务与移动互联网的发展，下一个兴趣点（Point-of-Interest, POI）预测已成为智能出行与个性化推荐的重要问题。现有方法在该任务上面临三方面不足：其一，传统序列与图模型通常采用统一转移机制，难以刻画同一 POI 在不同时段的行为差异，且仅建模”当前点去哪里”而忽略”目标点从哪里来”的方向性信息，导致路径预测存在偏置；其二，大语言模型（LLM）将经纬度作为文本 token 处理，地理上相邻的坐标在离散 token 空间中可能被映射为差异较大的符号序列，致使空间连续性被破坏，容易产生地理不一致的预测；其三，POI 之间的高阶转移关系蕴含在图结构中，仅依赖文本上下文难以将这类结构先验有效注入 LLM 语义空间，制约了模型对未显式出现候选的推断能力。针对上述问题，本文围绕”大小模型协同学习”展开研究，构建融合时空结构先验与语义推理能力的统一框架。

方法上，针对时间异质性与转移方向性不足，本文在小模型侧构建时间增强序列动态图与双向转移建模，按时段划分转移子图并同时学习”转出-转入”关系；针对 LLM 空间连续性缺失，设计地理坐标注入模块（GCIM），通过层级离散编码与连续频域编码的融合将地理约束以结构化方式注入语义空间；针对转移先验难以注入 LLM，设计 POI 对齐模块（PAM），建立从图结构表征到 LLM 语义空间的可学习映射通道，使高阶转移关系在语义侧可被读取和利用；在训练策略上采用”先对齐、后协同”的两阶段流程，以参数高效微调控制开销。在公开签到数据及其城市子集上的实验表明，所提方法在 Acc@1、MRR 等核心指标上均优于现有序列、图与大语言模型基线；其中，TSPM 在 Gowalla 上的 Acc@1 相对最强非本文基线提升 5.49%，GA-LLM 在 NYC 上的 Acc@1 提升 18.27%。消融实验与诊断分析进一步验证了各模块的独立贡献，并显示该框架在精度提升与工程可部署性之间取得了稳定平衡。

关键词：下一个兴趣点推荐；大小模型协同；时空建模；大语言模型；参数高效
微调

Title: Collaborative Learning of Large and Small Models for Next POI Prediction in Mobility Scenarios

Major: Artificial Intelligence

Name: Zhao Liu

Supervisor: Wei Liu (Associate Professor)

Abstract

Next point-of-interest (POI) prediction is a key task for intelligent mobility and personalized recommendation. Existing methods suffer from three limitations. First, conventional sequential and graph-based models adopt a unified transition mechanism that fails to capture the behavioral differences of the same POI across time periods, and model only “where the current point leads to” while ignoring “where the target point is typically reached from,” introducing directional bias in path prediction. Second, large language models (LLMs) tokenize geographic coordinates as plain text, so that spatially adjacent locations may be mapped to dissimilar token sequences, breaking spatial continuity and causing geographically inconsistent predictions. Third, high-order transition patterns are embedded in graph structures and cannot be effectively injected into the LLM semantic space through text context alone, limiting the model’s ability to infer candidates that do not explicitly appear in the input. To address these issues, this thesis develops a unified small-large collaborative learning framework that integrates spatio-temporal structural priors with semantic reasoning.

On the methodology side, to address temporal heterogeneity and insufficient transition directionality, a time-enhanced sequence-based dynamic graph with bidirectional transfer modeling is introduced on the small-model branch, which partitions transition sub-graphs by time slot and jointly learns outgoing and incoming preferences. To tackle the lack of spatial continuity in LLMs, a Geographic Coordinate Injection Module (GCIM) is designed to fuse hierarchical discrete encoding with continuous Fourier encoding and inject geographic constraints into the semantic space in a structured manner. To bridge the gap in transfer-prior injection, a POI Alignment Module (PAM) establishes a learnable mapping from graph-based structural representations to the LLM

semantic space, enabling high-order transition knowledge to be accessed and utilized on the semantic side. A two-stage training strategy (“alignment first, collaboration second”) with parameter-efficient fine-tuning is adopted to control computational overhead. Experiments on public check-in datasets and their city-level subsets show that the proposed method consistently outperforms sequential, graph-based, and LLM baselines on Acc@1, MRR, and related metrics. In particular, TSPM improves Acc@1 by 5.49% on Gowalla, and GA-LLM improves Acc@1 by 18.27% on NYC over the strongest non-ours baselines. Ablation and diagnostic studies further verify the independent contribution of each module and confirm a stable trade-off between predictive accuracy and deployment cost.

Keywords: Next POI Recommendation; Collaborative Learning; Spatio-temporal Modeling; Large Language Models; Parameter-efficient Fine-tuning

目录

摘 要	I
ABSTRACT	III
本文常用缩写对照表	IX
第 1 章 绪论	1
1.1 研究背景与研究意义	1
1.2 国内外研究现状与评述	2
1.3 研究问题与核心挑战	4
1.4 研究思路与主要贡献	6
1.5 论文组织结构	7
第 2 章 问题定义与建模原则	8
2.1 任务定义与符号约定	8
2.2 建模边界与评价协议	9
2.3 研究空白与建模原则	10
2.4 研究问题映射	11
第 3 章 大小模型协同学习方法	13
3.1 本章引言	13
3.2 总体框架与设计动机	13
3.3 关键模块设计	15
3.3.1 小模型分支: TSPM	15
3.3.2 大模型分支: GA-LLM	21
3.4 对齐与协同训练策略	28
3.5 方法对照与讨论	32
3.6 本章小结	33
第 4 章 实验设计与结果分析	34
4.1 本章引言	34
4.2 实验目标与研究问题	34

4.3	实验设置	34
4.4	主结果：双路线模型与基线对比 (RQ1)	37
4.5	机制验证与诊断分析 (RQ2–RQ4)	40
4.6	效率与可扩展性分析 (RQ5)	47
4.7	本章小结	49
结论		51
参考文献		56
附录		61
后记		63

Contents

Abstract (In Chinese)	I
Abstract (In English)	III
List of Abbreviations	IX
Chapter 1: Introduction	1
Section 1.1: Research Background and Significance	1
Section 1.2: Domestic and International Research Status	2
Section 1.3: Research Questions and Core Challenges	4
Section 1.4: Research Route and Main Contributions	5
Section 1.5: Thesis Organization	6
Chapter 2: Problem Definition and Modeling Principles	8
Section 2.1: Task Definition and Notation	8
Section 2.2: Modeling Boundaries and Evaluation Protocol	9
Section 2.3: Research Gaps and Modeling Principles	10
Section 2.4: Research Question Mapping	11
Chapter 3: Collaborative Learning Method of Large and Small Models	13
Section 3.1: Chapter Introduction	13
Section 3.2: Overall Framework and Design Motivation	13
Section 3.3: Key Module Design	15
Subsection 3.3.1: Small-model Branch: TSPM	15
Subsection 3.3.2: Large-model Branch: GA-LLM	21
Section 3.4: Alignment and Collaborative Training Strategy	28
Section 3.5: Method Comparison and Discussion	32
Section 3.6: Chapter Summary	33
Chapter 4: Experimental Design and Result Analysis	34
Section 4.1: Chapter Introduction	34
Section 4.2: Experimental Objectives and Research Questions	34
Section 4.3: Experimental Setup	34
Section 4.4: Main Results: Dual-route Models vs Baselines (RQ1)	37
Section 4.5: Mechanism Verification and Diagnostic Analysis (RQ2–RQ4) ...	40
Section 4.6: Efficiency and Scalability Analysis (RQ5)	47
Section 4.7: Chapter Summary	49
Conclusion	51
References	56

Appendix	61
Postscript	63